

IQL Tabanlı Sepsis Tedavi Politikası Değerlendirmesi İçin Yeniden Üretilabilir Bir Offline Pekiştirmeli Öğrenme İş Akışı

Furkan Nezh Üzmez
230202073

Özet—Bu rapor, retrospektif sepsis tedavi politikası değerlendirilmesi için Implicit Q-Learning (IQL) tabanlı yeniden üretilabilir bir final tarama iş akışını sunar. Çalışma, yoğun bakım tedavi kararlarını dört saatlik klinik pencerelerden oluşan sonlu ufuklu bir Markov karar süreci olarak modeller; her aksiyon intravenöz sıvı ve vazopresör şiddetinin ayrı bir kombinasyonunu temsil eder. Geliştirilen iş akışı, daha önce belirlenen orkestrasyon, ön tarama denetimi, finalist seçimi, çoklu tohum doğrulaması ve rapor artifact üretimi eksiklerini giderir. Aşama 0 denetimi artifact varlığını, hasta-düzei split ayrımını, zamansal geçiş hizalamasını, train-only fit sözleşmelerini ve belirgin outcome leakage bulunmadığını doğrular. Aşama 1, iki ödül varyantı, üç learning-rate rejimi ve üç expectile-temperature ayarından oluşan on sekiz IQL konfigürasyonunu değerlendirir. Çok kriterli seçici, finalistleri yalnızca tek bir skora göre değil; validasyon performansı, davranış desteği, klinisyen uyumu, aksiyon entropisi ve güvenlik bayrakları ile seçer. Aşama 2, seçilen altı konfigürasyonu üç tohumlu doğrulama düzeninde değerlendirir. Güncel sonuçlar, final seçili politikanın SOFA-shaped ödül, konservatif learning-rate ve safe IQL ayarını kullanan ‘iql_sofa_shaped_conservative_safe’ konfigürasyonu olduğunu gösterir. Bu aday üç tohum ortalamasında FQE=2.848, WIS=8.203, bootstrap WIS 95% CI=4.963–10.817, ESS=29.410, destek kütle=0.991 ve klinisyen exact-bin uyumu=0.414 elde etmiştir. Bununla birlikte ESS 50 eşliğinin altında kaldığından sonuç klinik üstünlük kanıtı olarak değil, destek kısıtı açıkça raporlanan retrospektif off-policy değerlendirme kanıtı olarak yorumlanmalıdır.

Index Terms—offline pekiştirmeli öğrenme, implicit Q-learning, sepsis, MIMIC-IV, off-policy evaluation, yeniden üretilirlik, klinik karar desteği

I. GİRİŞ

Sepsis tedavisi, belirsizlik altında ardışık kararlar, gecikmeli sonuçlar ve klinik şiddete bağlı confounding içeren bir yoğun bakım problemidir. Offline pekiştirmeli öğrenme, hasta üzerinde yeni denemeler yapmadan tarihsel klinik trajektorilerden politika öğrenmeyi sağlar. Bu özellik tıbbi ortamda kritiktir; çünkü çevrimiçi keşif etik olarak kabul edilemez. Ancak offline öğrenme, desteklenmeyen aksiyonlara kayma, yüksek varyanslı off-policy estimatorler ve validasyon artifactlerine aşırı uyum gibi riskler taşır.

Bu proje, MIMIC-IV tabanlı sepsis kohortunda dört saatlik karar pencereleriyle retrospektif politika değerlendirmesi yapar. Aksiyon uzayı, vazopresör ve intravenöz sıvı şiddetinin 5×5 ayrı bir kombinasyonudur. Final deneyin amacı IQL konfigürasyonlarını iki ödül varyantı altında karşılaştırmak, güvenilir finalistleri yalnız validasyon kanıtıyla seçmek ve raporlanabilir bir artifact bundle üretmektir. Bu çalışmada

protokol, açık denetim kapıları, deterministik konfigürasyon genişletmesi, çoklu tohum birleştirmesi ve grafik raporlama ile çalışır hale getirilmiştir.

II. İLGİLİ ÇALIŞMALAR

Offline pekiştirmeli öğrenme sabit veri kümelerinden politika öğrenme problemine odaklanır. IQL, veri dışı aksiyonları doğrudan maksimize etmek yerine expectile value learning ve advantage-weighted behavioral cloning kullanarak konservatif offline ortamlara uygun bir yaklaşım sunar [1]. Bu tercih CQL gibi açık Q-cezası kullanan yöntemlere göre daha sade bir seçimdir: CQL extrapolation error riskini doğrudan cezalandırır, fakat ceza ağırlığı yanlış seçildiğinde klinik olarak makul ama nadir aksiyonları aşırı bastırabilir [2]. IQL ise veri içi Q yedekleriyle ve davranış klonlamasına yakın politika çıkarımıyla destek dışına taşmayı azaltır; bunun bedeli, veri dağılımında hiç temsil edilmeyen tedavi stratejilerini keşfedememesidir.

Sepsis alanında RL çalışmalarının temel örnekleri, sıvı ve vazopresör dozlarını ayrı tedavi aksiyonları olarak modelleyen AI Clinician çalışması ve sürekli durum temsiliyle optimal sepsis tedavisi öğrenmeye çalışan derin RL yaklaşımıdır [3], [4]. Bu çizgideki sonuçlar klinik karar desteği için umut verici olsa da, sağlıkta RL rehberleri gözlemsel veriden öğrenilen politikaların confounding, destek eksikliği, estimator varyansı ve prospektif doğrulama eksikliği nedeniyle doğrudan tedavi önerisi sayılamayacağını vurgular [5]. Bu nedenle bu raporun amacı da klinik üstünlük iddiası üretmek değil, raporlanabilir ve yeniden üretilir bir offline değerlendirme kanıtı oluşturmaktır. Veri temeli, de-identified kritik bakım kayıtları sağlayan MIMIC-IV veri tabanıdır [6]; tedavi aksiyonlarının sıvı ve vazopresör eksenlerinde kurulması ise sepsis ve septik şok yönetiminde bu iki müdahalenin merkezi rol oynadığı güncel kılavuzlarla uyumludur [7].

III. YÖNTEM

A. Klinik Karar Süreci

Problem $M = (S, A, P, R, \gamma)$ biçiminde sonlu ufuklu bir Markov karar süreci olarak ele alınır. Her episode dört saatlik pencerelere ayrılır. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger [3], [4]. Daha kısa pencere seçilseydi ölçüm eksikliği ve gürültülü aksiyon tekrarları artacak, davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde

tahmin edilecekti. Daha uzun pencere seçilseydi de sıvı ve vazopresör değişimlerinin akut fizyolojik etkileri ortalamaya karışacak, ardışık karar yapısı zayıflayacaktı.

Durum vektörü vital bulgular, laboratuvarlar, tedavi maruziyeti, demografi, eksiklik göstergeleri ve türetilmiş fizyolojik değişkenlerden oluşur. Bu geniş temsil, yalnız ham ölçümlere dayanmak yerine klinik şiddet, tedavi geçmişi ve ölçüm eksikliği sinyali birlikte taşır. Eksiklik göstergeleri eklenmeseydi model, ölçülmeyen laboratuvarı normal değerle karıştırabilir ve hekimlerin “ölçme kararı” üzerinden dolaylı olarak taşıdığı risk bilgisini kaybedebilirdi. Discount factor $\gamma = 0.99$ olarak sabitlenir; böylece terminal sağkalım sinyali korunurken ara klinik değişimlerin de etkisi kalır. Daha küçük bir γ kısa vadeli SOFA değişimlerini fazla öne çıkarabilir, $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilirdi.

İki ödül varyantı kullanılır. Sparse ödül yalnız terminal mortalite/sağkalım utility’sini kullanır. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir. SOFA-shaped ödül terminal utility’yi korur ve SOFA değişimine küçük bir ara sinyal ekler; SOFA’nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara sinyali klinik olarak gerekçelendirir [8]. SOFA shaping kullanılsaydı eğitim yalnız terminal sonuca dayanacak ve ara fizyolojik iyileşmeleri ayırt etmek zorlaşacaktı. Tersine, shaping ağırlığı çok güçlü seçilseydi ajan mortalite yerine kısa vadeli skor oynamalarını optimize edebilirdi; bu nedenle terminal utility korunmuş ve seçim ortak terminal değerlendirmeye bağlanmıştır.

B. Leakage-Safe Veri Sözleşmeleri

Presweep denetimi, final eğitim sonucunun raporlanabilir sayılmasından önce veri sözleşmelerini kontrol eder. Bu kapı özellikle sağlıkta RL için gereklidir; çünkü küçük bir split sızıntısı veya outcome leakage, gözlemsel klinik veride gerçek politika kalitesinden çok daha büyük görünen kazançlar üretebilir [5]. Denetim; sparse ve SOFA-shaped replay artifactlerinin train, validation ve test splitlerinde mevcut olduğunu; hasta kimliklerinin splitler arasında çakışmadığını; replay artifactlerinin split, aksiyon, preprocessing, indeksleme ve terminal outcome sözleşmelerini paylaştığını; ve geçiş tuple’larında durum, aksiyon, sonraki durum, ödül ve terminal bayrakların hizalı olduğunu doğrular. Bu adım atlanmış olsaydı Aşama 2 sonucu sayısal olarak üretilebilir görünse bile, aynı hastanın farklı splitlere düşmesi veya terminal bilginin özelliklere sızması nedeniyle metodolojik olarak geçersiz hale gelebilirdi.

C. IQL Tarama Tasarımı

Final tarama iki ödül varyantı, üç learning-rate rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Learning-rate rejimleri actor, critic ve value optimizasyonunu ayrı olarak kontrol eder. Konservatif learning-rate rejimi finalde öne çıkarılmıştır; çünkü offline RL’de agresif critic güncellemeleri veri dışı Q tahminlerini büyütebilir ve politika çıkarımı bu hataları

Tablo I
PRESWEEP DENETİM ÖZETİ.

Kanıt kalemi	Train	Validation	Test
Split manifest satırı	12063	2585	2585
SOFA-shaped replay satırı	140635	30539	30046
Sparse replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage taraması		Başarılı	

Tablo II
IQL FINAL TARAMA TASARIMI.

Boyut	Değerler
Ödül varyantı	sparse, SOFA-shaped
Learning-rate rejimi	konservatif, baseline, actor-konservatif
IQL ayarı	safe, baseline, optimistic
Aşama 1 tohumu	42
Aşama 2 ek tohumları	123, 456
Sabit discount	0.99
Aksiyon uzayı	25 ayrı tedavi bini

çoğaltabilir [1], [2]. Baseline rejim yalnızca referans anchor olarak tutulmuştur; hiç denenmeseydi konservatif seçimin gerçekten gerekli olup olmadığı gözlenemezdi. Actor-konservatif rejim ise politika güncellemelerini yavaşlatmanın, critic/value öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.

IQL ayarları expectile ve temperature değerlerini değiştirerek value optimism ve advantage ağırlıklı politika keskinliğini ayarlar. Safe ayar, daha ölçülü expectile-temperature kombinasyonu ile yüksek avantajlı ama seyrek aksiyonlara aşırı yığılmayı sınırlamak için seçilmiştir. Optimistic ayar hiç denenmeseydi daha yüksek getiri potansiyeli olan konfigürasyonlar dışlanabilirdi; ancak tek başına final seçilseydi düşük destekli aksiyonları fazla önerebilir ve WIS/ESS diagnostiklerinde güvenilirliği azaltabilirdi. Bu nedenle grid küçük tutulmuş, fakat her ekseninde alternatifleri sınyacak kadar geniş bırakılmıştır.

IV. FINALIST SEÇİM SONUÇLARI

Aşama 1 seçici altı finalist üretmiştir. En yüksek iki aday SOFA-shaped ödül ve konservatif learning-rate kullanırken, diğer slotlar sparse ödül temsili, güvenlik-destek dengesini, baseline anchor seçimini ve çeşitlilik backfill kuralını korur. Tablo III, seçilen adayları ve ana validasyon diagnostiklerini gösterir.


Seçilen küme, protokolün tek skorlu sıralama yerine çok kriterli ve çeşitlilik koruyan seçim hedefiyle uyumludur. Klinik offline öğrenmede bu önemlidir; çünkü yüksek value tahmini, zayıf davranış desteği veya aşırı dağılım kayması durumunda güvenilir olmayabilir [5]. Eğer yalnız en yüksek FQE veya WIS değerine göre seçim yapılsaydı, düşük ESS ya da düşük clinician agreement taşıyan bir politika final rapora girebilirdi. Çeşitlilik slotları korunmasaydı ise Aşama 2 yalnız birbirine çok benzeyen SOFA-konservatif adayları tekrarlar,

Tablo III
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.

Sıra	Slot	Ödül	LR	IQL	FQE	WIS	Destek	Uyum
1	top composite	SOFA	konservatif	safe	3.169	8.616	0.965	0.418
2	top composite	SOFA	konservatif	baseline	2.280	7.009	0.973	0.401
3	best sparse	sparse	konservatif	safe	1.954	8.740	0.971	0.411
4	safety support	sparse	baseline	baseline	1.421	6.768	0.973	0.410
5	baseline anchor	sparse	baseline	safe	2.345	8.125	0.963	0.416
6	diversity backfill	sparse	konservatif	baseline	2.012	7.782	0.969	0.407

Algorithm 1 Final IQL Tarama ve Raporlama İş Akışı

- 1: Replay, split, preprocessing ve zamansal sözleşmeleri doğru-
rula
- 2: Ödül, learning-rate ve IQL ayarlarını genişlet
- 3: **for** her Aşama 1 adayı **do**
- 4: Tarama tohumu ile politikayı eğit
- 5: Validasyon metriklerini ve destek diagnostiklerini he-
sapla
- 6: **end for**
- 7: Güvenlik veya destek kapılarını geçemeyen adayları ele
- 8: Composite, ödül dengesi, güvenlik ve çeşitlilik slotlarıyla
altı finalist seç
- 9: **for** her finalist ve her doğrulama tohumu **do**
- 10: Politika artifactini eğit veya yeniden kullan
- 11: Çoklu tohum değerlendirme kanıtını topla
- 12: **end for**
- 13: Tekrarlanan tohum kanıtıyla final konfigürasyonu seç
- 14: Baseline karşılaştırmaları, grafikler ve yeniden üretilebi-
lirlik artifactleri üret




Şekil 1. Validasyon value tahmini ile davranış desteği diagnostiklerinin birlikte gösterimi. Yüksek value yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.

sparse ödülün ve baseline ayarların başarısızlık/başarı sınırları raporlanamazdı.

V. AŞAMA 2 VE BASELINE DEĞERLENDİRMESİ

Aşama 2, altı finalist ve üç tohumdan oluşan on sekiz satırlık bir tekrarlı-tohum özeti üretmiştir. Her finalist için seed 42,



Şekil 2. Final seçili IQL politikası ve referans baseline gösterimi. Seçili IQL değeri gerçek Aşama 2 değerlendirmesinden, referans baseline çubukları ise rapor artifactinde kullanılan karşılaştırma gösteriminden gelir.

123 ve 456 checkpointleri test replay üzerinde yeniden değerlendirilmiştir. Tek tohumlu seçim yapılmış olsaydı rastgele başlatma, minibatch sırası veya erken eğitim dalgalanması final politika kararını belirleyebilirdi. Üç tohum, hesaplama maliyetini sınırlı tutarken bu varyansı görünür yapar; daha fazla tohum istatistiksel güveni artırır, fakat final tarama maliyetini doğrusal olarak büyütürdü.

Final skor; FQE, WIS, ESS, destek kütleleri, klinisyen uyumu, low-support cezası ve güvenlik bayraklarını birleştiren tekrarlı-tohum ortalamasına dayanır. FQE model tabanlı değer tahmini sağlarken WIS davranış politikasına göre ağırlıklandırılmış gözlemsel kanıt verir; ikisinin birlikte kullanılması tek estimatorün yanlılık-varyans profilini tek başına final kararına dönüştürmemek içindir [5]. ESS ve destek kütleleri eklenmeseydi yüksek WIS değeri, birkaç yüksek ağırlıklı trajectory tarafından taşınsa bile güvenilir görünürdü. Klinisyen uyumu eklenmeseydi politika davranış verisinden çok uzaklaşabilir, bu da offline değerlendirme desteğini azaltabilirdi. Bu kurala göre final seçili konfigürasyon SOFA-shaped, konservatif learning-rate ve safe IQL ayarına sahip 'iql_sofa_shaped_conservative_safe' modelidir.

VI. AKSIYON VE GÜVENLİK DIAGNOSTİKLERİ


Aksiyon dağılımı diagnostikleri zorunludur; çünkü öğrenilen klinik politika iyi value tahminleri üretirken observational veride nadir veya desteklenmeyen aksiyonlara kayabilir. Bu

Tablo IV
AŞAMA 2 ÜÇ-TOHUM FINALIST DEĞERLENDİRMESİ. SKOR, FQE/WIS/ESS/DESTEK/UYUM VE LOW-SUPPORT BİLEŞİK SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	Destek	Uyum
1	SOFA konservatif safe	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif baseline	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif safe	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif baseline	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline safe	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline baseline	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo V
FINAL SEÇİLİ IQL POLİTİKASININ AŞAMA 2 TEST DIAGNOSTİKLERİ. WIS GÜVEN ARALIĞI 50 HASTA-DÜZEYİ BOOTSTRAP RESAMPLE İLE HESAPLANMIŞTIR.

Politika	FQE	WIS	WIS 95% CI	ESS	Destek	Uyum
Seçili IQL	2.848	8.203	4.963–10.817	29.41	0.991	0.414




Şekil 3. Aşama 2 finalistleri için tekrarlı-tohum FQE değişkenliği. Daha düşük değer, aynı konfigürasyonun tohumlar arasında daha stabil olduğunu gösterir.

nedenle action heatmap, support mass, low-support rate, klinisyen uyumu ve aksiyon entropisiyle birlikte yorumlanmalıdır.


Aşama 2 finalistlerinde destek kütlesi yaklaşık 0.990–0.991, klinisyen exact-bin uyumu ise yaklaşık 0.401–0.418 aralığındadır. Bu değerler, seçilen adayların tamamen desteksiz politikalar olmadığını gösterir. Buna karşın ESS değerleri tüm finalistlerde 50 eşliğinin altındadır; bu nedenle WIS tabanlı sıralama yüksek varyans riskiyle birlikte raporlanmalıdır. ESS uyarısı saklansaydı rapor, gözlemsel veride yalnız az sayıda etkili trajectory ile desteklenen bir tahmini kesin sonuç gibi sunma riski taşırdı. Bu yüzden final karar “klinik üstünlük” değil, destek kısıtı belirtilmiş retrospektif OPE sonucu olarak ifade edilmiştir.

VII. YENİDEN ÜRETİLEBİLİRLİK VE TAMAMLANMA DURUMU

Tamamlanan iş akışı, protokol incelemesinde belirlenen ana eksikleri karşılar: final IQL sweep runner, on sekiz konfigürasyonlu grid, workflow seviyesinde orkestrasyon, presweep audit, final-altı seçim mantığı, tekrarlı-tohum Aşama 2 birleştirilmesi, baseline karşılaştırma artifactleri ve final grafik raporları. Üretilen artifact seti presweep audit sonucunu, Aşama 1



Şekil 4. Final politika analizi için üretilmiş aksiyon dağılımı heatmap'i. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.



Şekil 5. Final seçili IQL politikasının üç tohum için hasta-düzeyi bootstrap WIS güven aralıkları. Güven aralıkları 50 bootstrap resample ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.

seçim tablosunu, Aşama 2 seed özetini, final metrics bundle'ı, baseline karşılaştırmasını ve beş grafik çıktısını içerir. Güncel Aşama 2 değerlendirme sonuçlarında on sekiz finalist-tohum satırı olarak saklanmıştır.

Kalan temel sınır, estimator belirsizliğidir. Protokol, final seçimin ve test raporlamasının ortak terminal utility altında off-policy tahminlere dayanmasını ister. Mevcut yeniden değerlendirme FQE, WIS, ESS, destek ve uyum metriklerini üretmiş;

final seçili model için 50 hasta-düzeyi bootstrap resample ile WIS güven aralığı eklenmiştir. Dolayısıyla sistem deneysel iş akışı olarak yeniden üretilebilir durumdadır; ancak ESS değerinin 50 eşliğinin altında kalması ve bootstrap resample sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.

VIII. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve observational niteliktedir. Öğrenilen politika yatak başı tedavi önerisi olarak yorumlanmamalıdır. Durum temsili gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen confounding etkilerini tam olarak kapsayamaz. MIMIC-IV verisi de-identified olsa da credentialing ve data-use yükümlülüklerine tabidir. Son olarak FQE ve WIS istatistiksel estimatorlerdir; prospektif klinik kanıt yerine geçmez.

IX. SONUÇ

Geliştirilen IQL final tarama iş akışı, protokol düzeyindeki deney tasarımı sepsis tedavi politikası değerlendirilmesi için yeniden üretilebilir bir offline pekiştirmeli öğrenme pipeline'ına dönüştürür. Veri sözleşmesi denetimleri kurulmuş, IQL grid'i genişletilmiş, finalistler çok kriterli kapılarla seçilmiş, tekrarlı tohumlar birleştirilmiş ve rapora hazır grafikler üretilmiştir. Aşama 0 denetimi başarılıdır ve Aşama 1 altı çeşitli, destek-duyarlı finalist belirlemiştir. Güncel Aşama 2 sonucuna göre final konfigürasyon 'iql_sofa_shaped_conservative_safe' olarak seçilmiştir. Bu model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 ile final konfigürasyon olarak raporlanmıştır; ancak ESS=29.41 ile destek eşliğinin altındadır. Bu nedenle sonuç klinik değil metodolojik ve retrospektif OPE kanıtı olarak raporlanmalıdır.

KAYNAKLAR

- [1] I. Kostrikov, A. Nair, and S. Levine, "Offline reinforcement learning with implicit q-learning," in *International Conference on Learning Representations*, 2022.
- [2] A. Kumar, A. Zhou, G. Tucker, and S. Levine, "Conservative q-learning for offline reinforcement learning," in *Advances in Neural Information Processing Systems*, 2020.
- [3] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, "The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care," *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [4] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, "Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach," in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [5] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, "Guidelines for reinforcement learning in healthcare," *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [6] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, "Mimic-iv, a freely accessible electronic health record dataset," *Scientific Data*, vol. 10, no. 1, p. 1, 2023.
- [7] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, "Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021," *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.

- [8] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Anane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, "The third international consensus definitions for sepsis and septic shock (sepsis-3)," *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.