

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Çevrimdışı Pekiştirmeli Öğrenme İş Akışı

Furkan Nezih Üzmez
230202073

Özet—Gözlemsel elektronik sağlık kayıtlarından elde edilen verilerle sepsis resüsitasyonunda optimal intravenöz sıvı ve vazopresör dozaj politikalarının belirlenmesi, politika dışı değerlendirme süreçlerinde ciddi ekstrapolasyon hataları barındırmaktadır. Sunulan çalışma, MIMIC-IV (sürüm 3.1) veri seti üzerinde sepsis dozaj politikalarının yeniden üretilebilir ve denetlenebilir biçimde değerlendirilmesini sağlayan, uçtan uca orkestre edilmiş bir çevrimdışı pekiştirmeli öğrenme (offline reinforcement learning) iş akışını yapılandırmaktadır [1]–[3]. Karar uzayındaki temel risk, modelin tarihsel veri dağılımında zayıf temsil edilen sıvı-vazopresör kombinasyonlarını asılsız şekilde yüksek değerli atfetmesidir. Metodolojik izolasyonu ve veri sızıntısını (data leakage) engellemek adına; Sepsis-3 kohort seçimi, 72 saatlik akut klinik gözlem penceresi, 62 boyutlu durum vektörü, 5×5 ayrık aksiyon uzayı, seyrek ve SOFA-biçimli ödül tasarımları, yalnızca eğitim verisine dayalı ön işleme (train-only preprocessing) ve hasta düzeyinde veri bölme (patient-level split) tek bir protokol altında entegre edilmiştir. Örtük Q-öğrenme (Implicit Q-Learning, IQL) hiperparametre uzayının sistematik taranması kapsamında; Aşama 1’de iki ödül varyantı, üç öğrenme oranı rejimi ve üç ekspektil-sıcaklık ayarından oluşan 18 konfigürasyon değerlendirilmiştir. Aşama 2’de ise en başarılı altı finalist üç farklı tohumla (seed) yeniden ölçümlenmiştir. Deney sonuçları, en dengeli adayın iql_sofa_shaped_conservative_safe konfigürasyonu olduğunu göstermektedir. Üç farklı tohumun ortalama test performansında; uydurulmuş Q-değerlendirmesi (FQE) =2.848, ağırlıklı önem örnekleme (WIS) =8.203, bootstrap WIS %95 güven aralığı =4.963–10.817, etkin örneklem büyüklüğü (ESS) =29.410, davranışsal destek kütlesi =0.991 ve klinisyen tam-kutu uyumu (exact-bin agreement) =0.414 olarak elde edilmiştir. ESS değerinin istatistiksel güvenilirlik sınırı olan 50 eşliğinin altında kalması, model için doğrudan bir klinik üstünlük iddiası kurulmasını engellemekte, ancak destek sınırları titizlikle tanımlanmış retrospektif politika dışı değerlendirme (off-policy evaluation, OPE) süreçleri için güçlü bir metodolojik kanıt teşkil etmektedir.

Index Terms—çevrimdışı pekiştirmeli öğrenme, örtük Q-öğrenme (implicit Q-learning), sepsis, MIMIC-IV, politika dışı değerlendirme, yeniden üretilebilirlik, klinik karar desteği

I. GİRİŞ

Sepsis, dünya genelinde her yıl yaklaşık 49 milyon insanı etkileyen ve 11 milyon ölüme yol açan, yoğun bakım ünitelerindeki en kritik mortalite nedenlerinden biridir [4]. Sepsis resüsitasyonu sürecinde, dinamik hemodinamik parametreler doğrultusunda hastaların intravenöz sıvı ve vazopresör ihtiyaçları saatler içinde değişkenlik göstermektedir. Klinik kararların gecikmeli mortalite sonuçlarıyla doğrudan ilişkili olması ve ağır durumdaki hastaların daha agresif müdahalelere maruz kalması, gözlemsel verilerde endikasyon karıştırmacılığı (con-

founding by indication) adı verilen kritik bir sapırmaya yol açar. Çevrimdışı pekiştirmeli öğrenme, klinik açıdan riskli ve etik dışı olan çevrimiçi keşif (online exploration) süreçlerini tamamen dışlayarak, yalnızca geçmiş yoğun bakım yörüngeleri (trajectories) üzerinden politika öğrenimini mümkün kılması nedeniyle bu alanda güçlü bir alternatif sunar [2], [3]. Ancak, öğrenilen politikanın veri desteği dışındaki aksiyonlara kayması durumunda, uydurulmuş Q-değerlendirmesi (FQE) veya ağırlıklı önem örnekleme (WIS) gibi tahminleyiciler sayısal olarak yapay bir iyimserlik gösterse bile klinik olarak güvensiz kararlar üretebilir. Önerilen iş akışı, yatak başı gerçek zamanlı bir tedavi modülü sunmaktan ziyade, retrospektif politika değerlendirme ve model karşılaştırmaları için metodolojik olarak izole edilmiş bir analiz ortamı teşkil eder. Model sınıfı modelsiz (model-free), politika dışı (off-policy) ve çevrimdışı pekiştirmeli öğrenmedir. Tasarım aşamasında, muhafazakar Q-öğrenme (CQL) ve davranış kısıtlı Q-öğrenme (BCQ) gibi alternatif aileler incelenmiş, nihai olarak veri dışı aksiyonların değerini sorgulamadan doğrudan veri içi dağılımdan politika çıkaran IQL algoritmasında karar kılınmıştır [5]–[7]. Donanımsal farklılıkların (CUDA veya MPS) deneysel kararları etkilemesini önlemek amacıyla, donanım agnostik bir yürütme katmanı kurgulanmıştır. Klinik karar süreçleri, literatürle uyumlu şekilde 4 saatlik pencereler halinde modellenmiş ve her karar vazopresör ile intravenöz sıvı şiddetinin 5×5 ayrık kombinasyonundan biriyle eşleştirilmiştir. Güvenilirliği artırmak adına, deterministik ızgara genişletmesi, çoklu tohum birleştirmesi ve kapsamlı teşhis grafikleri deneysel protokolün asli unsurları olarak entegre edilmiştir.

II. İLGİLİ ÇALIŞMALAR

Çevrimdışı pekiştirmeli öğrenme literatüründe, politika iyileştirmesinin veri desteği içinde tutulması temel bir zorunluluktur. IQL, veri dışı aksiyonları maksimize etmek yerine asimetric ekspektil değer öğrenimi ve avantaj ağırlıklı davranış klonlama mekanizmaları üzerinden bu sınırlamayı yönetmektedir [7]. CQL ise düşük destekli aksiyonların Q değerlerini açıkça cezalandırarak kötümser bir alt sınır kurar [5]. Bu yaklaşım ekstrapolasyon hatalarına karşı dayanıklı olsa da, parametre kalibrasyonundaki hassasiyet nedeniyle klinikte nadir fakat kritik kurtarma müdahalelerini (rescue therapies) baskı-lama riski barındırır. IQL’nin tercih edilmesi, veri dağılımında hiç gözlenmemiş radikal tedavi stratejilerinin keşfedilememesi pahasına, veri desteği dışına taşma riskini minimize eden

bilinçli bir metodolojik takastır. Sepsis RL alanındaki öncü çalışmalardan Komorowski ve ark. tarafından geliştirilen “AI Clinician”, sıvı ve vazopresör dozajlarını ayrı kutular halinde modellerken, Raghu ve ark. sürekli durum temsilleri üzerinden optimizasyon denemeleri yapmıştır [8], [9]. Bu çalışmalar klinik karar desteği açısından yol açıcı olmakla birlikte, gözlemsel verilerdeki confounding, veri desteği eksikliği (lack of support) ve tahminleyici varyansı gibi kronik sorunlar nedeniyle doğrudan klinik kullanım için yetersiz bulunmuştur. Bu doğrultuda, sunulan çalışma herhangi bir klinik üstünlük iddiası gütmeksizin, yeniden üretilebilir ve sızıntısız bir değerlendirme protokolü sunmaya odaklanmıştır. Veri kaynağı olarak, modern klinik pratikleri yansıtan ve geniş bir yoğun bakım hasta popülasyonuna sahip olan MIMIC-IV (sürüm 3.1) tercih edilmiştir. MIMIC-IV veri seti, HIPAA uyumluluğu ve de-identifikasyon protokolleri çerçevesinde geniş ölçekli ve kimliksizleştirilmiş kritik bakım kayıtlarını barındırmaktadır [1]. Bu veri tabanından Sepsis-3 kriterlerine göre türetilen ve 35.239 yoğun bakım yatışını kapsayan MIMIC-Sepsis kohortu, standartlaştırılmış tedavi birimleri ve zaman-hizalı fizyolojik seriler sunmaktadır [10], [11]. Gözlemsel verilerde antibiyotik kullanım oranının %66.3, mekanik ventilasyon ihtiyacının %35.1 ve vazopresör desteğinin %16.9 düzeyinde bulunması [10], tedavinin klinikteki dağılımının ne derece heterojen olduğunu ve ağır hastaların kaçınılmaz olarak daha erken müdahalelere maruz kaldığını doğrulamaktadır.

III. KURAMSAL ARKA PLAN VE ALGORİTMİK KONUMLANDIRMA

Çevrimdışı pekiştirmeli öğrenmede politika iyileştirmesi, veri desteği dışına taşmadığı sürece anlamlıdır [2], [3]. Klasik politika dışı değer öğrenimi (off-policy value learning) bir sonraki durumda $\max_{a'} Q(s', a')$ sorgusu yaptığında, veri setinde hiç görülmemiş aksiyonlara değer atar. Fonksiyon yaklaşımcı bu bölgelerde eğitim sinyali almadığı için ekstrapolasyon hatası oluşur; hata Bellman yedeklemeleriyle büyür ve klinik veride güvenilmez doz önerilerine dönüşebilir. Literatürde bu hataya verilen yanıtlar üç grupta toplanabilir. CQL gibi açık aksiyon-uzayı düzenliştirmesi yöntemleri veri dışı aksiyonların Q değerini düşürür ve kötümser bir alt sınır kurar. IQL gibi örtük ve veri-içi yöntemler (implicit, in-sample methods) gözlenmemiş aksiyonu sorgulamaz; veri içinde yüksek değerli görünen aksiyonların üst ekspektilini (expectile) öğrenir. Durum-uzayı manifoldu düzenliştirmesi (state-space manifold regularization) ise cezayı aksiyonlardan durum manifoldunun dışına taşır. Bu çalışmada IQL hattı seçilmiştir; çünkü ek ceza katsayısı kalibrasyonundan önce destek içinde kalma ve yorumlanabilir doğrulama protokolü temel öncelik olarak belirlenmiştir. Çok adımlı değer yayılımı (multi-step value propagation) bu çalışmanın doğrudan deney değişkeni değil, sonraki araştırma eksenidir. Tek adımlı yedeklemeler seyrek terminal mortalite (sparse terminal mortality) sinyalini 18 adımlık yörünge (trajectory) boyunca yavaş taşır; Peng’in $Q(\lambda)$ gibi uygunluk izi (eligibility trace) yaklaşımları bu gecikmeyi azaltabilir [12], [13]. Bu raporda önce destek güvenliği ve sızıntısız değerlendirme (leakage-free evaluation)

sabitlenmiştir. Multi-step operatör aynı anda değiştirilseydi, final IQL sonucunun reward/LR/expectile seçimi mi yoksa yedekleme operatörü mü nedeniyle değiştiği ayrıştırılamazdı.

IV. UÇTAN UCA PROJE MIMARISI

Proje, veri hazırlama hatalarının final politika değerlendirmesine taşınmasını engellemek amacıyla, katı bağımlılık zinciriyle ilerleyen on ana adımdan oluşmaktadır. Bu mimari tek bir eğitim betiği (training script) olarak değil, veri hazırlama, model eğitimi, değerlendirme ve raporlama katmanlarını birbirine bağlayan deney protokolü olarak ele alınır. Kohort tanımı, veri sözleşmesi, model eğitimi, politika dışı değerlendirme, güvenlik analizi ve raporlama çıktıları aynı deney protokolüne bağlanır. Bu entegre tasarım, bölme sızıntısı (split leakage), farklı ön işleme (preprocessing) veya hatalı geçiş indeksleme (transition indexing) kaynaklı yapay performans artışlarının model başarısı olarak yorumlanmasını engeller.

V. KOHORT, ZAMAN VE SPLIT TASARIMI

A. Kohort Seçimi

Kohort MIMIC-IV üzerinde Sepsis-3 kriterlerine göre oluşturulur. Dahil edilen popülasyon 18 yaş ve üzeri yetişkin, doğrudan yoğun bakım ünitesi izlemine sahip ve sepsis tanımıyla uyumlu hastalardır. Fizyolojik gelişim süreçlerindeki belirgin heterojenlik ve dozaj toleransı farklılıkları nedeniyle pediatrik popülasyon kohort dışı bırakılarak, modelin kararsız tedavi politikaları öğrenmesi engellenmiştir. Yoğun bakım ünitesi dışı veya yoğun gözlem verisi olmayan hastalar da dışlanır; çünkü 4 saatlik karar pencereleri için yeterli fizyolojik zaman serisi kurulamaz. Dışlama kuralları, karar penceresinin klinik ve zamansal tutarlılığını korumak amacıyla uygulanır. Sepsis onsets zamanı bulunamayan hastalar, 4 saatten kısa yoğun bakım ünitesi kalışı olanlar ve yaş/cinsiyet gibi temel demografisi eksik olanlar çıkarılır. Tekrar yatan hastalarda yalnız ilk yatış kullanılır. Örnek olarak, aynı hastanın bir yatışı eğitim setine, sonraki yatışı test setine düşerse model kronik profili dolaylı olarak ezberleyebilir; bu nedenle filtreleme sonucu ve dışlanan hasta sayıları denetim çıktılarında saklanır.

B. Zaman Çizelgesi

Her yoğun bakım ünitesi kalışı için ‘sepsis_onset_time’ hesaplanır. Analiz penceresi onset’ten 24 saat önce başlayıp 48 saat sonrasına kadar devam eder. Bu 72 saatlik pencere 4 saatlik karar adımlarına ayrıldığında tipik epizot (episode) yaklaşık 18 zaman adımı (timestep) içerir. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger. Karar penceresinin 4 saat olarak sabitlenmesi, daha kısa pencerelerin getireceği seyrek ölçüm gürültüsünü ve aksiyon tekrarlarını sınırlar; aksi takdirde davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde tahmin edilmeye zorlanacaktır. Benzer şekilde, daha uzun pencereler ise sıvı ve vazopresör değişimlerinin akut fizyolojik etkilerinin ortalamaya karışmasına ve ardışık karar yapısının zayıflamasına yol açar.

Tablo I
PROJENİN ON AŞAMALI UÇTAN UCA MIMARISI.

Adım	Bileşen	İçerik
1	Kohort seçimi	MIMIC-IV içinden Sepsis-3 kriterlerine uyan yetişkin yoğun bakım ünitesi (ICU) hastalarının seçilmesi; geçersiz onset, kısa yoğun bakım ünitesi kalışı, eksik temel demografi ve tekrar yatışların yönetilmesi.
2	Zaman çizelgesi	Sepsis onset'inden 24 saat önce başlayıp 48 saat sonrasına uzanan 72 saatlik pencerenin 4 saatlik karar adımlarına bölünmesi.
3	Sıfır sızıntı (zero leakage) bölme (split)	Hastaların eğitim/doğrulama/test (train/validation/test) olarak hasta-düzeyinde ayrılması ve ön işleme uyarılama işlemlerinin (preprocessing fit) yalnız eğitim verisi (train) üzerinde yapılması.
4	Durum (state) çıkarımı	Yaşamsal bulgu (vital), laboratuvar, tedavi geçmişi, demografi, eksiklik (missingness) ve türetilmiş değişkenlerden 62 boyutlu durum vektörü üretilmesi.
5	Aksiyon/ödül (action/reward)	Vazopresör ve IV sıvı dozlarının 25 ayrık aksiyona dönüştürülmesi; seyrek ve SOFA-biçimli ödüllerin (sparse and SOFA-shaped rewards) üretilmesi.
6	Geçiş/başlangıç çizgisi (transition/baseline)	Tekrar oynatma verisinin (replay data) $(s_t, a_t, r_t, s_{t+1}, done_t)$ formatında yazılması; klinisyen (clinician), tedavisiz (no-treatment) ve davranış klonlama (behavior cloning) başlangıç çizgilerinin (baselines) kurulması.
7-8	IQL eğitimi	Çevrimdışı veride (offline data) destek dışında çıkmadan ekspektik değer öğrenimi ve avantaj ağırlıklı aktör güncellemesi (advantage-weighted actor update) ile IQL politikalarının eğitilmesi.
9	Politika dışı değerlendirme (OPE) ve güvenlik	FQE, WIS, ESS, bootstrap güven aralığı (confidence interval, CI), destek kütlesi, klinisyen uyumu (clinician agreement), ısı haritası (heatmap) ve güvenlik teşhislerinin (diagnostics) hesaplanması.
10	Final tarama (final sweep)	18 konfigürasyonlu IQL taraması, finalist seçimi, çoklu tohum doğrulaması ve IEEE rapor çıktılarının (artifacts) üretilmesi.

C. Split Stratejisi

Varsayılan split hasta düzeyinde eğitim %70, doğrulama %15 ve test %15 olarak yapılır. Bölme tohumu (split seed) 42 olarak sabitlenir. Eğitim, doğrulama ve test özne kümelerinin (subject sets) kesişimi boş olmalıdır. Test seti yalnız final raporlama için kullanılır; hiperparametre, kontrol noktası veya metrik tasarımı test sonucuna göre değiştirilmez. Metodolojik izolasyonu ve veri sızıntısını engellemek adına test seti hiperparametre optimizasyon sürecinden tamamen soyutlanmıştır.

VI. MDP FORMÜLASYONU

Problem sonlu ufuklu bir Markov karar süreci olarak modellenir: $M = (S, A, P, R, \gamma)$ Burada S hasta durum uzayını, A ayrık tedavi aksiyonlarını, P geçiş dinamiklerini, R ödül fonksiyonunu ve γ iskonto faktörünü temsil eder. Her geçiş $(s_t, a_t, r_t, s_{t+1}, done_t)$ biçimindedir.

A. Durum Temsili

Durum vektörü, hastanın o andaki klinik durumunu özetleyen 62 sürekli ve ikili özellikten oluşur. Başlıca gruplar kalp hızı, MAP, sistolik/diyastolik tansiyon, solunum ve SpO_2 gibi yaşamsal bulgular; kan gazı, elektrolit, renal, hepatik, koagülasyon ve hemogram laboratuvarları; kümülatif sıvı, vazopresör maruziyeti ve idrar çıkışı gibi tedavi sinyalleri; yaş ve cinsiyet gibi demografik değişkenler; PaO_2/FiO_2 , şok indeksi ve onset sonrası saat gibi türetilmiş değişkenlerdir. Her 4 saatlik pencerede birden fazla ölçüm varsa özelliğe göre 'last', 'mean', 'min', 'max', 'sum' veya 'cumulative' agregasyon kuralı uygulanır. Örneğin, yaşamsal bulgularda son ölçüm klinik karar anına daha yakın bilgi taşıırken, toplam sıvı veya kümülatif vazopresör maruziyeti pencere içi tedavi yükünü temsil eder. Tek bir agregasyon kuralının tüm değişkenlere

Tablo II
VAZOPRESÖR VE IV SIVİ AKSİYON GRID'İ.

Vazo bini	Sıvı bini				
	0	1	2	3	4
0	0	1	2	3	4
1	5	6	7	8	9
2	10	11	12	13	14
3	15	16	17	18	19
4	20	21	22	23	24

dayatılması, klinik anlamı farklı sinyallerin aynı istatistiksel kalıba sıkıştırılmasına ve bilgi kaybına yol açacaktır. Eksik veriler için sıralı bir strateji uygulanır: epizot içinde forward-fill, eğitim bölmesi üzerinden hesaplanan medyan, klinik normal değer fallback ve gerekli durumda eksiklik göstergesi (missingness flag). Missingness göstergelerinin eklenmesi, modelin ölçülmeyen laboratuvar değerlerini normal değerlerle karıştırmasını engeller ve hekimin ölçüm kararıyla taşınan klinik risk bilgisini korur.

B. Aksiyon Uzayı

Aksiyon uzayı 25 ayrık tedavi kararından oluşur. Her aksiyon, vazopresör dozu ve IV sıvı miktarının 5×5 kombinasyonudur:

Aksiyon kimliği aşağıdaki formülle belirlenir: $action_{id} = vazo_{bin} \times 5 + fluid_{bin}$ Bin 0 tedavi yok anlamına gelir; sıfır dışı dozlar eğitim bölmesi üzerindeki çeyrekliklere göre Q1-Q4 olarak ayrılır. Sıfır dozu ayrı tutmak kritik önemdedir; çünkü hiç tedavi vermemek ile küçük ama sıfır dışı bir tedavi uygulamak aynı klinik anlama sahip değildir. Bin eşiklerinin yalnız eğitim bölmesi üzerinde öğrenilmesi, test doz dağılımının aksiyon kodlama aşamasına sızmasını engeller.

C. Ödül Tasarımı

İki ödül varyantı kullanılır. Seyrek ödül (sparse reward) yalnız terminal mortalite/sağkalım fayda değerini kullanır: 90 gün yaşayan hasta için +15, 90 gün içinde ölüm için -15. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir. SOFA-biçimli ödül, terminal faydayı korur ve ara adımlarda SOFA değişimine küçük bir şekillendirme sinyali ekler: $sofa_{shaping} = -0.025 \times (SOFA_{current} - SOFA_{previous})$ SOFA artışı kötüleşme olarak negatif, SOFA azalması iyileşme olarak pozitif sinyal üretir. SOFA'nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara sinyali klinik olarak gerekçelendirir. SOFA şekillendirmesinin dışarıda bırakılması, eğitimin yalnızca terminal sonuca dayanmasına ve ara fizyolojik iyileşmelerin ayırt edilememesine yol açacaktır. Ancak, şekillendirme ağırlığının çok güçlü seçilmesi de ajanın nihai mortalite yerine kısa vadeli skor oynamalarını optimize etmesi riskini doğurur; bu nedenle terminal fayda korunmuş ve seçim ortak terminal değerlendirilmeye bağlanmıştır.

D. İskonto Faktörü

İskonto faktörü $\gamma = 0.99$ olarak sabitlenir. Bu seçim, sepsis tedavisinde kısa vadeli hemodinamik kararların uzun vadeli mortalite sonucuyla ilişkili olması nedeniyle uygundur. Daha küçük bir γ değeri kısa vadeli SOFA değişimlerini fazla öne çıkarabilir; $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilir.

VII. ÖN İŞLEME VE SIZINTISIZ SÖZLEŞMELER

Temel kural “eğitime uydur, her yerde dönüştür” (fit on train, transform everywhere) şeklindedir. Ölçekleyici parametreleri, atayıcı medyanları, kırpma sınırları, aksiyon bini çeyreklik eşikleri, davranış politikası tahminleyicisi, FQE tahminleyicisi ve normalleştirme sabitleri eğitim verisi üzerinde uydurulur (fit). Doğrulama ve test üzerinde yalnız eğitim verisinde uydurulmuş dönüşümler uygulanır. Bu seçim, sağlık verisindeki sonuç sızıntısı ve tasarım sonrası model seçimi risklerine karşı önerilen raporlama ilkeleriyle uyumludur. Fizyolojik olarak makul olmayan değerler geçerli aralık dışında filtrelenir veya kırpılır (clip). Ön işleme parametrelerinin dondurulmuş eğitim istatistiklerine kilitlenmesi, doğrulama ve test dağılımlarının uç değer örüntülerinin ön işleme fazında eğitime sızmasını önlemektedir.

A. Aşama 0 Ön Tarama Denetimi

Ön tarama denetimi (presweep audit), eğitim başlamadan önce veri sözleşmelerini test eder. Sağlıkta RL için bu kapı zorunludur; küçük bir bölme sızıntısı veya sonuç sızıntısı (outcome leakage), gözlemsel veride gerçek politika kalitesinden çok daha büyük görünen yapay kazançlar üretebilir.

Denetim süreci; seyrek ve SOFA-biçimli tekrar oynatma dosyalarının aynı bölme, ön işleme, aksiyon bini ve geçiş tanımlarını kullanmasını kontrol eder. Ayrıca, aksiyon binlerinin

Tablo III
ÖN TARAMA DENETİM ÖZETİ (PRESWEEP AUDIT SUMMARY).

Kanıt kalemi	Eğitim	Doğrulama	Test
Split manifest satırı	12063	2585	2585
SOFA replay satırı	140635	30539	30046
Seyrek replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage taraması		Başarılı	

yalnız eğitim verisinde fit edilmesini, doğrulama FQE'sinin ortak terminal sağkalım/ölüm ödülüyle çalışmasını, hasta çakışması bulunmamasını ve mortalite gibi gelecek sonuç bilgisinin durum özelliklerine sızmasını güvence altına alır. Bu denetim kapısı, klinik yapay zeka çalışmalarında sık görülen geçerlilik ihlallerini deneysel süreç başlamadan önce sınırlar.

VIII. BAŞLANGIÇ ÇİZGİSİ POLİTİKALARI

Nihai test karşılaştırması üç referans politika içerir. Klinisyen tekrar oynatımı (clinician replay), tekrar oynatma veri setindeki gözlenen klinisyen aksiyonlarını değerlendirir ve davranış verisinin kendisini referans alır. Tedavisiz politika (no-treatment policy), uygun yerlerde vazopresör yok / sıvı yok bin'ini seçen basit kontrol politikasıdır. Davranış klonlama ise klinisyen aksiyonlarını gözetimli öğrenme ile taklit eder. Bu başlangıç çizgileri, IQL çıktısının davranış politikası ve basit kontrol stratejilerine göre bağlamlandırılmasını sağlar.

IX. IQL ALGORİTMASI

Örtük Q-öğrenme, veri seti dışındaki aksiyonları maksimize etmeden politika çıkarır. Model üç parça öğrenir: eleştirmen (critic), değer işlevi (value function) ve aktör (actor). Eleştirmen $Q_\theta(s, a)$ durum-aksiyon değerini tahmin eder. Değer işlevi, klasik maksimum operatörü yerine asimetrik ekspektıl kaybı (expectile loss) ile uydurulur:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim D} [L_2^\tau(Q_\theta(s, a) - V_\psi(s))] \quad (1)$$

$$L_2^\tau(u) = |\tau - \mathbb{I}(u < 0)|u^2. \quad (2)$$

Ekspektıl parametresi τ yükseldikçe, değer fonksiyonu davranış verisi içinde daha iyi görünen aksiyonların üst ekspektiline (upper expectile) odaklanır. Q fonksiyonu ise öğrenilen durum-değer hedefiyle güncellenir:

$$L_Q(\theta) = \mathbb{E}_D [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (3)$$

Aktör, veri seti içindeki aksiyonları avantaja (advantage) göre ağırlıklandırarak öğrenir:

$$A(s, a) = Q_\theta(s, a) - V_\psi(s) \quad (4)$$

$$L_\pi(\phi) = -\mathbb{E}_D [\exp(\beta A(s, a)) \log \pi_\phi(a|s)] \quad (5)$$

Burada β (sıcaklık) politika çıkarımının agresifliğini kontrol eder. Düşük sıcaklık davranış politikasına daha yakın ve konservatif bir politika çıkarırken; yüksek sıcaklık potansiyel getiriye artırabilir, fakat düşük destekli aksiyonlara kayma riskini de büyütür. Bu nedenle güvenli, referans ve iyimser ayarlar deneysel olarak karşılaştırılmıştır.

X. IQL FINAL TARAMA TASARIMI

Final tarama iki ödül varyantı, üç öğrenme oranı (LR) rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Öğrenme oranı rejimleri aktör, eleştirmen ve değer optimizasyonunu ayrı olarak kontrol eder. Konservatif öğrenme oranı rejimi finalde öne çıkarılmıştır; çünkü çevrimdışı RL’de agresif eleştirmen güncellemeleri veri dışı Q tahminlerini büyütülebilir ve politika çıkarımı bu hataları çoğaltabilir. Referans rejim (baseline regime) yalnızca referans çapa (baseline anchor) olarak tutulmuştur; bu kontrol mekanizmasının dışarıda bırakılması muhafazakar seçimin gerekliliğinin gözlenmesini engelleyecekti. Aktör-konservatif rejim ise politika güncellemelerini yavaşlatmanın, eleştirmen/değer öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.

XI. TOHUM STRATEJISI VE KARAR KURALI

Tek tohumlu değerlendirme, çevrimdışı RL modellerinde kararlı politika seçimi için yetersiz kanıt üretir. Başlatma, mini-yığın sırası ve stokastik optimizasyon aynı konfigürasyonun FQE/WIS değerini değiştirebilir. Aşama 1’de 18 konfigürasyon tohum 42 ile taranır; ardından altı finalist tohum 123 ve 456 ile yeniden değerlendirilir. Bu tasarım, tüm 54 çalıştırma yerine 30 çalıştırma yapılmasını sağlayarak hesaplama maliyetini düşürür, fakat final adayları çoklu tohum üzerinden raporladığı için tohum varyansı görünür kalır. Hiperparametre seçimi test set üzerinden yapılmaz. Seçim; doğrulama bölmesi üzerindeki FQE, WIS, ESS, klinisyen uyumu, aksiyon dağılımı makullüğü, düşük destekli aksiyon uyarıları, ödül eğrisi ve eğitim kararlılığı sinyallerine dayanır. Karar verme sürecinde tek bir metrikle yetinilmez; örneğin, yüksek WIS değerine sahip olmasına rağmen son derece düşük bir ESS gösteren modeller istatistiksel varyans nedeniyle elenir. Bir konfigürasyonun final aday olabilmesi için doğrulama performansı rekabetçi olmalı, ESS makul düzeyde kalmalı, FQE sonucu WIS ile çelişmemeli, aksiyon dağılımı klinik olarak kabul edilebilir sınırlar içinde bulunmalı ve farklı tohumlarda performans kararlılığı korunmalıdır.


XII. AŞAMA 1 FINALIST SEÇİM SONUÇLARI

Aşama 1 elemeleri sonucunda, çok kriterli seçim kuralları ve çeşitlilik slotları korunarak altı finalist belirlenmiştir. En yüksek skora sahip adaylar SOFA-biçimli ödül ve konservatif öğrenme oranı rejimini paylaşmaktadır.


Klinik çevrimdışı öğrenmede yüksek değer tahmini, düşük davranış desteğiyle birleştiğinde güvenilir değildir. Salt en yüksek FQE veya WIS değerine dayalı bir seçim, düşük ESS ya da zayıf klinisyen uyumu taşıyan bir politikanın Aşama 2’ye geçmesine neden olabilir. Çeşitlilik slotlarının korunması, Aşama 2’nin yalnızca SOFA-konservatif adayları tekrarlamasını önleyerek seyrek ödülün ve referans ayarların sınırlarını görünür kılmaktadır.

XIII. AŞAMA 2 VE BASELINE DEĞERLENDİRMESİ

Aşama 2, altı finalist ve üç tohumdan oluşan on sekiz satırlık bir tekrarlı-tohum özeti üretmiştir.



Şekil 1. Doğrulama değer tahmini ile davranış desteği teşhislerinin birlikte gösterimi. Yüksek değer yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.



Şekil 2. Final seçili IQL politikası ve referans politikalar için WIS ve ESS teşhisleri. Davranış klonlama WIS değeri yüksek görünse de ESS=1. olduğu için güvenilir politika üstünlüğü kanıtı olarak yorumlanmaz.

Her finalist için tohum 42, 123 ve 456 kontrol noktaları test tekrar oynatımı üzerinde yeniden değerlendirilmiştir. Çoklu tohum yaklaşımı, rastgele başlatma veya erken eğitim dalgalanmalarının final politika kararını belirlemesini önler. Üç tohum, hesaplama maliyetini sınırlı tutarken tohum varyansını görünür kılar.

XIV. AKSIYON VE GÜVENLİK TEŞHİSLERİ


Değer metriği tek başına klinik politika güvenliğini göstermez. Bir politika iyi FQE üretebilir, fakat gözlemsel veride nadir görülen sıvı-vazopresör kombinasyonlarına kayabilir. Bu yüzden aksiyon ısı haritası, destek kütle, düşük destek oranı, klinisyen uyumu ve aksiyon entropisi aynı anda okunur. Sepsis resüsitasyonunda klinik kılavuzlara bağlılık hayati önem taşır [14]. CPQ-IQL gibi gelişmiş kısıtlı pekiştirmeli öğrenme çerçeveleri, Lagrangian optimizasyonu yoluyla Surviving Sepsis Campaign yönergelerini doğrudan eğitim sürecine dahil edebilmektedir [14], [15]. Deneyisel çalışmalar, statik politikalara eklenen bir “güvenli aksiyon” (Safe Actions) çalışma

Tablo IV
FINAL IQL HIPERPARAMETRE IZGARASI (HYPERPARAMETER GRID).

Boyut	Seenek	Deęerler
Ödöl	seyrek	terminal sağkalım/ölüm faydası (terminal survival/death utility)
Ödöl	SOFA-biimli	terminal fayda + SOFA deęişim şekillendirmesi (shaping)
LR rejimi	konservatif (conservative)	aktör 3×10^{-5} , eleştirmen 1×10^{-4} , deęer 1×10^{-4}
LR rejimi	referans	aktör 1×10^{-4} , eleştirmen 3×10^{-4} , deęer 3×10^{-4}
LR rejimi	aktör-konservatif (actor-conservative)	aktör 3×10^{-5} , eleştirmen 3×10^{-4} , deęer 3×10^{-4}
IQL ayarı	güvenli	ekspektil 0.7, sıcaklık 1.0
IQL ayarı	referans	ekspektil 0.7, sıcaklık 3.0
IQL ayarı	iyimser	ekspektil 0.8, sıcaklık 3.0


Tablo V
SABIT EęİTİM PARAMETRELERİ.

Parametre	Deęer
Algoritma	IQL
Epoch	200
Yığın boyutu (batch size)	256
İskonto (discount)	0.99
Politika gizli katman boyutları (policy hidden sizes)	[256, 256]
Deęer gizli katman boyutları (value hidden sizes)	[256, 256]
Eleştirmen gizli katman boyutları (critic hidden sizes)	[256, 256]
Polyak tau	0.005
Hedef güncelleme sıklığı (target update freq)	10
Gradyan kırpmı (grad clip)	10.0
Cihaz (device)	auto




Şekil 3. Aşama 2 finalistleri için tekrarlı-tohum FQE deęişkenliği. Daha düşük deęer, aynı konfigürasyonun tohumlar arasında daha stabil olduğunu gösterir.

zamanı filtresinin politika kararlarının yaklaşık %21'ini modifiye ederek klinik kısıt ihlallerini %97. oranında azalttığını (ihlal oranını %22.88'den %0.41'e düşürdüğünü) ve %78. $\pm$ 1. düzeyinde rekabetçi sağkalım oranları sağladığını göstermektedir. Geliştirilen IQL modelinin ampirik analizinde ise klinisyen tam-kutu uyumu =0.414 düzeyinde gerçekleşmiştir; yani kararların 0.586'lık kısmı hekim davranışıyla birebir aynı değildir. Buna karşın, desteklenmeyen aksiyon sapmasının 0.009 gibi ihmal edilebilir bir seviyede kalması, modelin klinisyenden saptığı durumlarda bile veri desteęi bulunan makul komşu kutularda kaldığını göstermektedir. ESS deęerinin tüm finalistlerde 50 eşięinin altında kalması, politika dışı tahmin varyansının yüksek olduğunu teyit eder. Az sayıda yüksek ağırlıklı yörüngenin taşıdığı deęer tahminlerinin kesin klinik



Şekil 4. Aşama 2 finalistleri için deęer, destek ve güvenlik ödünleşimini gösteren Pareto görünümü. Final seçimi tek bir metrikten deęil, bu ödünleşimin destek-duyarlı yorumundan elde edilir.



Şekil 5. Politika dışı deęerlendirme metriklerine göre finalist sıralaması. Grafik, Tablo VII'deki bileşik skorun FQE, WIS, ESS ve destek göstergeleriyle birlikte okunması gerektiğini gösterir.

performans kanıtı gibi yorumlanmaması, bu istatistiksel sınırın açıkça belirtilmesiyle sağlanmıştır.

XV. YENİDEN ÜRETİLEBİLİRLİK VE TEKNOLOJİ YİĞİNİ

İş akışı protokoldeki ana boşlukları kapatır: final IQL tarama çalıştırıcısı, 18 konfigürasyonlu ızgara, iş akışı seviyesinde orkestrasyon, ön tarama denetimi, final-altı seçim mantığı, tekrarlı-tohum Aşama 2 birleştirmesi, başlangıç çizgisi karşılaştırması ve final grafik raporları. Çıktı seti; ön tarama denetimi sonucunu, Aşama 1 seçim tablosunu, Aşama 2 tohum özetini, final metrik paketini, referans politika gösterimini ve analiz grafiklerini kapsar. Teknoloji yığını; Python ve uv tabanlı ortam yönetimi, yüksek hızlı Polars ve PyArrow tabanlı Parquet veri dönüşümü, PyTorch ve özelleştirilmiş d3rlpy tabanlı RL eğitimi, Hydra konfigürasyon yönetimi, MLflow

Tablo VI
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.

Sıra	Yuva (slot)	Ödül	LR	IQL	FQE	WIS	Destek	Uyum
1	en iyi bileşik (top composite)	SOFA	konservatif	güvenli	3.169	8.616	0.965	0.418
2	en iyi bileşik	SOFA	konservatif	referans	2.280	7.009	0.973	0.401
3	en iyi seyrek (best sparse)	sparse	konservatif	güvenli	1.954	8.740	0.971	0.411
4	güvenlik desteği (safety support)	sparse	referans	referans	1.421	6.768	0.973	0.410
5	referans çapa	sparse	referans	güvenli	2.345	8.125	0.963	0.416
6	çeşitlilik tamamlama	sparse	konservatif	referans	2.012	7.782	0.969	0.407

Tablo VII
AŞAMA 2 ÜÇ-TOHUM FINALIST DEĞERLENDİRMESİ. SKOR; FQE, WIS, ESS, DESTEK, UYUM VE DÜŞÜK DESTEK CEZASINI BİRLEŞTİREN SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	Destek	Uyum
1	SOFA konservatif güvenli	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif referans	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif güvenli	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif referans	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline güvenli	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline referans	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo VIII
FINAL SEÇİLİ IQL POLİTİKASININ TOHUM-DÜZEYİ TEST SONUÇLARI. BU SATIRLAR TABLO X'DEKİ ÜÇ-TOHUM ORTALAMASININ KAYNAĞINI GÖSTERİR.

Tohum	FQE	WIS	ESS	Uyum
123	2.806	7.116	31.97	0.417
42	3.217	10.218	28.73	0.414
456	2.520	8.160	27.52	0.410
Ortalama	2.848	8.203	29.41	0.414

Tablo IX
REFERANS POLİTİKA WIS TEŞHİSLERİ. FQE YALNIZ ÖĞRENİLMİŞ IQL KONTROL NOKTASI İÇİN RAPORLANIR; REFERANS POLİTİKALAR İÇİN WIS/ESS VE KLİNİSYEN UYUMU AYNI TEST TEKRAR OYNATMA ÜZERİNDE HESAPLANMIŞTIR.

Politika	WIS	ESS	Uyum
Klinisyen tekrar oynatımı	8.774	2585.0	1.000
Tedavisiz	7.464	34.2	0.354
Davranış klonlama	9.194	1.6	0.405
Seçili IQL	8.203	29.4	0.414

deney takibi ve IEEE LaTeX raporlamasından oluşur. Cihaz-agnostik tasarım sayesinde eğitim kodu MPS, CUDA veya otomatik cihaz seçimiyle çalışabilir. Bu altyapı ayrıştırılmasaydı, deney sonuçları belirli bir donanıma veya elle değiştirilmiş konfigürasyonlara bağımlı hale gelirdi.

XVI. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve gözlemseldir; öğrenilen politika yatak başı tedavi önerisi niteliği taşımamaktadır. Durum vektörü gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen karıştırıcılık etkilerini tam kapsamaz. Yoğun bakım ortamındaki karar süreçleri, doğası gereği kısmi gözlemlenebilir Markov karar süreçlerine (POMDP) daha yakındır;


Tablo X
KAZANAN KONFIGÜRASYONUN TEST TEŞHİSLERİ (TEST DIAGNOSTICS). WIS GÜVEN ARALIĞI 50 HASTA-DÜZEYİ BOOTSTRAP YENİDEN ÖRNEKLEME (BOOTSTRAP RESAMPLE) İLE HESAPLANMIŞTIR.

Metrik	Sonuç
FQE	2.848
WIS	8.203
WIS 95% CI	4.963–10.817
ESS	29.410
Davranışsal destek kütleli	0.991
Klinisyen tam-kutu uyumu	0.414
Klinisyen uyumsuzluğu	0.586
Desteklenmeyen aksiyon sapması	0.009


model hekimin tüm yatak başı klinik gözlemlerini görememektedir. Klinisyen aksiyonları da endikasyon karıştırıcılığı taşıır; daha ağır hastalara daha agresif vazopresör verilmesi, tedaviyi istatistiksel olarak zararlı gösterebilir veya yanlış fayda atfı üretebilir. MIMIC-IV verisi PhysioNet credentialing, CITI eğitimi ve Veri Kullanım Sözleşmesi (DUA) kapsamındaki etik yükümlülüklerle tabidir. Hasta verileri kimliksizleştirilmiş olsa da, analizlerin akademik ve etik sınırlar içinde raporlanması zorunludur. FQE ve WIS prospektif klinik kanıt değildir; fonksiyon yaklaşımı kalitesine, davranış politikası tahmininin doğruluğuna ve varyans profiline doğrudan bağlıdır [3], [16]. ESS değerinin 50 eşiğinin altında kalması ve bootstrap yeniden örnekleme sayısının sınırlı olması nedeniyle ampirik sonuçlar doğrudan klinik performans kanıtı olarak yorumlanmamalıdır.

XVII. GELECEK ARAŞTIRMA YÖNLERİ

Bu çalışmanın sonraki adımı daha büyük bir hiperparametre ızgarası çalıştırmak değil, belirsizliği politika güncelleme mekanizmasına entegre etmektir. İlk yön, dinamik ekspektik kalibrasyonudur. Yoğun veri desteği içeren bölgelerde τ yükseltilerek daha agresif politika iyileştirmesi yapılabilir; seyrek ve




Şekil 6. Final politika analizi için üretilmiş aksiyon dağılımı ısı haritası. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.




Şekil 7. Final seçili IQL politikasının üç tohum için hasta-düzeyi bootstrap WIS güven aralıkları. Güven aralıkları 50 bootstrap yeniden örnekleme ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.

belirsiz bölgelerde ise $\tau = 0.5$ yaklaştırılarak daha güvenli, davranış klonlamasına yakın güncellemeler seçilebilir. İkinci yön, seyrek terminal mortalite sinyalini daha hızlı yaymak amacıyla uyarlanabilir çok adımlı iz harmanlama (adaptive multi-step trace blending) yaklaşımıdır. Peng'in $Q(\lambda)$ fikri, yüksek destekli yörünge bölümlerinde büyük λ , belirsiz geçişlerde ise küçük λ kullanacak şekilde klinik verilere uyarlanabilir. Üçüncü yön, durum-uzayı manifoldu düzenleştirmesi için üretici dünya modeli veya difüzyon tabanlı yörünge simülatorleridir. Bu tür simülatorler, veri setinde seyrek görülen ama klinik olarak gerçekçi sınır durumları sentezleyerek değer fonksiyonuna güvenli marjlar öğretebilir. Ek olarak, risk hassasiyetini artırmak amacıyla quantile ağırları kullanan risk dinamikleri modelleri (MOOR gibi) entegre edilerek, çevrimdışı verideki örtük risk bilgisi yakalanabilir ve yüksek riskli outlier verilerin yanlış kullanımı engellenebilir.



Şekil 8. Finalist politikalar için klinisyen tam-kutu uyumu. Uyum metriği politika davranış verisinden ne kadar uzaklaştığını gösterir; tek başına performans kanıtı değildir, destek ve OPE metrikleriyle birlikte yorumlanır.




Şekil 9. Yüksek riskli alt gruplarda klinisyen uyumu ve düşük destekli aksiyon oranı. Bu teşhis, final politikanın ortalama hasta dışındaki daha kırılgan alt gruplarda da destek sınırlarını koruyup korumadığını inceler.

XVIII. SONUÇ

IQL final tarama iş akışı, sepsis dozaj politikalarını tek seferlik bir model çıktısı olarak değil, denetlenebilir bir çevrimdışı değerlendirme protokolü olarak ele alır. Kohort seçimi, zaman penceresi, durum/aksiyon/ödül mühendisliği, sızıntısız ön işleme, IQL eğitimi, hiperparametre ızgarası, Aşama 1 finalist seçimi ve Aşama 2 çoklu-tohum değerlendirmesi aynı raporda izlenebilir hale getirilmiştir. Aşama 0 denetimi başarıyla geçilmiş, Aşama 1 ise destek-duyarlı 6 finalist üretmiştir. Aşama 2 değerlendirmesi sonucunda final konfigürasyon `iql_sofa_shaped_conservative_safe` olarak seçilmiştir. Model test kümesi üzerinde FQE=2.848, WIS=8.203 ve bootstrap WIS %95 CI=4.963–10.817 vermektedir; ancak ESS=29.410 ile güvenilirlik eşiğinin altındadır. Bu nedenle sonuç, prospektif bir klinik üstünlük kanıtı değil, metodolojik ve retrospektif bir politika dışı değerlendirme kanıtıdır.

KAYNAKLAR

- [1] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, “Mimic-iv, a freely accessible electronic health record dataset,” *Scientific Data*, vol. 10, no. 1, p. 1, 2023.



Şekil 10. Politika aksiyonlarının klinisyen aksiyonlarından sapma şiddeti. Sapma analizi, tam-kutu uyumsuzluğunun klinik grid üzerinde küçük komşu hareketlerden mi yoksa daha büyük dozaj değişimlerinden mi kaynaklandığını gösterir.

- [2] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” *arXiv preprint arXiv:2005.01643*, 2020.
- [3] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, “Guidelines for reinforcement learning in healthcare,” *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [4] K. E. Rudd, S. C. Johnson, K. M. Agesa, K. A. Shackelford, D. Tsoi, D. R. Kievlán, D. V. Colombara, K. S. Ikuta, N. Kissoon, S. Finfer *et al.*, “Global, regional, and national sepsis incidence and mortality, 1990–2017: analysis for the global burden of disease study,” *The Lancet*, vol. 395, no. 10219, pp. 200–211, 2020.
- [5] A. Kumar, A. Zhou, G. Tucker, and S. Levine, “Conservative q-learning for offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, 2020.
- [6] S. Fujimoto, D. Meger, and D. Precup, “Off-policy deep reinforcement learning without exploration,” in *Proceedings of the 36th International Conference on Machine Learning*, 2019, pp. 2052–2062.
- [7] I. Kostrikov, A. Nair, and S. Levine, “Offline reinforcement learning with implicit q-learning,” in *International Conference on Learning Representations*, 2022.
- [8] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, “The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care,” *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [9] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, “Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach,” in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [10] Y. Huang, Z. Yang, and A. Rahmani, “Mimic-sepsis: A curated benchmark for modeling and learning from sepsis trajectories in the icu,” *arXiv preprint arXiv:2510.24500*, 2025.
- [11] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Annane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, “The third international consensus definitions for sepsis and septic shock (sepsis-3),” *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.
- [12] J. Peng and R. J. Williams, “Incremental multi-step q-learning,” *Machine Learning*, vol. 22, no. 1–3, pp. 283–290, 1996.
- [13] D. Precup, R. S. Sutton, and S. P. Singh, “Eligibility traces for off-policy policy evaluation,” in *Proceedings of the Seventeenth International Conference on Machine Learning*, 2000, pp. 759–766.
- [14] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, “Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021,” *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.
- [15] B. Zhang and Y. Mi, “Safe offline reinforcement learning for sepsis treatment: A two-stage framework combining constraint-aware learning with runtime safety filtering,” *Transactions on Artificial Intelligence*, vol. 2, no. 1, 2026.
- [16] C. Voloshin, H. M. Le, N. Jiang, and Y. Yue, “Empirical study of off-policy policy evaluation for reinforcement learning,” in *NeurIPS Datasets and Benchmarks*, 2021.