

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Offline Reinforcement Learning İş Akışı

Furkan Nezih Üzmez
230202073

Özet—Bu çalışma, MIMIC-IV veri seti üzerinde sepsis dozaj politikalarının yeniden üretilebilir biçimde değerlendirilmesi için orkestre edilmiş bir Offline Reinforcement Learning (çevrimdışı pekiştirmeli öğrenme) iş akışı sunmaktadır. Temel risk, modelin tarihsel veride zayıf temsil edilen sıvı-vazopresör kombinasyonlarını güvenilir sanmasıdır. Bu nedenle iş akışı; Sepsis-3 kohort seçimini, 72 saatlik klinik pencereyi, 62 boyutlu durum vektörünü, 5×5 ayrık aksiyon uzayını, seyrek ödül (sparse reward) ve SOFA-biçimli ödül (SOFA-shaped reward) tasarımlarını, yalnız eğitim verisine dayalı ön işleme (train-only preprocessing), hasta düzeyi bölme (patient-level split), Implicit Q-Learning (IQL, örtük Q-öğrenme) sweep'ini, çok kriterli finalist seçimini ve multi-seed doğrulamasını aynı protokol içinde tutar. Aşama 1'de iki ödül, üç öğrenme oranı (learning rate) rejimi ve üç expectile-temperature ayarından oluşan 18 konfigürasyon değerlendirilir; Aşama 2'de altı finalist üç seed ile yeniden ölçülür. Final aday 'iql_sofa_shaped_conservative_safe' konfigürasyonudur. Üç seed ortalamasında Fitted Q Evaluation (FQE, öğrenilmiş Q-fonksiyonu üzerinden yapılan politika değerlendirmesi) = 2.848, Weighted Importance Sampling (WIS, ağırlıklı önem örnekleme) = 8.203, bootstrap WIS 95% confidence interval (CI) = 4.963–10.817, Effective Sample Size (ESS, etkin örneklem büyüklüğü) = 29.410, behavior support mass = 0.991 ve clinician exact-bin agreement = 0.414 elde edilmiştir. ESS değeri 50 eşişinin altında kaldığı için bu sonuç klinik üstünlük iddiası değil, destek sınırı açıkça belirtilmiş retrospektif Off-Policy Evaluation (OPE, politika dışı değerlendirme) kanıtıdır.

Index Terms—Offline Reinforcement Learning, Implicit Q-Learning (IQL), sepsis, MIMIC-IV, Off-Policy Evaluation (OPE), yeniden üretilebilirlik, klinik karar desteği

I. GİRİŞ

Sepsis resüsitasyonunda aynı hasta birkaç saat içinde farklı sıvı ve vazopresör dozlarına ihtiyaç duyabilir. Bu kararlar gecikmeli mortalite sonuçlarına bağlanır ve daha hasta bireylerin daha agresif tedavi alması karıştırıcılık (confounding) üretir. Offline Reinforcement Learning (Offline RL) bu nedenle uygundur: model yalnızca geçmiş yoğun bakım yörüngelerini (trajectories) kullanır, hastalar üzerinde çevrimiçi keşif (online exploration) yapmaz. Aynı özellik yöntemi kırılğan da yapar; politika desteklenmeyen aksiyonlara kayarsa, FQE veya WIS gibi off-policy tahminleyiciler (off-policy estimators) sayısal olarak düzgün görünse bile klinik olarak güvenilmez hale gelir [1], [2].

Önerilen iş akışı, yatak başı gerçek zamanlı bir tedavi modülü sunmaktan ziyade, retrospektif politika değerlendirmesi ve model karşılaştırmaları için metodolojik olarak izole edilmiş bir analiz ortamı teşkil eder. Model sınıfı modelsiz (model-free), off-policy ve offline RL'dir. Conservative Q-Learning

(CQL), Batch-Constrained Q-Learning (BCQ) ve Implicit Q-Learning (IQL) aileleri tasarım aşamasında değerlendirilmiştir [3]–[5]. Final rapor IQL'ye odaklanır; çünkü IQL veri dışı aksiyon maksimumu almadan politika çıkarır. Kodun MPS ve CUDA üzerinde aynı eğitim mantığıyla çalışması istenir; hardware-agnostic execution layer (donanımdan bağımsız yürütme katmanı) sayesinde donanım farkı deney kararına dönüşmemelidir.

Klinik zaman çizelgesi dört saatlik karar pencerelerine ayrılır; her karar, vazopresör ve intravenöz sıvı şiddetinin 5×5 kombinasyonlarından biridir. Final deney iki ödül varyantını aynı terminal değerlendirme altında karşılaştırır, finalistleri yalnız doğrulama kanıtıyla seçer ve raporlanabilir çıktı paketi (artifact bundle) üretir. Denetim kapıları, deterministik grid expansion (ızgara genişletmesi), multi-seed birleştirmesi ve grafik raporlama bu nedenle yardımcı ayrıntı değil, sonucun geçerlilik koşuludur.

II. İLGİLİ ÇALIŞMALAR

Offline Reinforcement Learning, politika öğrenimini sabit bir veri kümesinin davranış desteği içinde tutmaya çalışır. IQL bu amaçla veri dışı aksiyonları maksimize etmez; expectile değer öğrenimi (expectile value learning) ve avantaj ağırlıklı Behavior Cloning (BC, davranış klonlama) kullanır [5]. CQL ise low-support action'ların Q değerini açıkça cezalandırır [3]. Bu ceza ekstrapolasyon hatası (extrapolation error) riskine karşı güçlüdür, fakat yanlış ayarlandığında klinikte nadir ama gerekli kurtarma müdahalelerini de bastırabilir. IQL'nin tercih edilmesi bu yüzden bilinçli bir takastır: destek dışına taşıma azalır, ancak veri dağılımında hiç görülmeyen tedavi stratejileri keşfedilemez.

Sepsis RL literatüründe iki çalışma bu tasarımı doğrudan çerçeveler. AI Clinician, sıvı ve vazopresör dozlarını ayrık tedavi binleri (bins) olarak modellemiştir; Raghu ve arkadaşları aynı problemi sürekli durum temsilleriyle ele almıştır [6], [7]. Bu çalışmalar klinik karar desteği için yol açıcı olsa da, sağlıkta RL rehberleri gözlemsel politikaların confounding, destek eksikliği, estimator varyansı ve prospektif doğrulama eksikliği nedeniyle tedavi önerisi sayılamayacağını belirtir [8]. Bu rapor bu sınırı korur: amaç klinik üstünlük iddiası değil, yeniden üretilebilir offline evaluation kanıtıdır. Veri kaynağı kimliksizleştirilmiş (de-identified) kritik bakım kayıtları sunan MIMIC-IV'tür [9]; aksiyon eksenlerinin sıvı ve vazopresör

olarak seçilmesi güncel sepsis yönetiminde bu iki müdahalenin merkezi rolüyle uyumludur [10].

III. KURAMSAL ARKA PLAN VE ALGORİTMİK KONUMLANDIRMA

Offline RL kapsamında politika iyileştirmesi, veri desteği dışına taşmadığı sürece anlamlıdır. Klasik off-policy değer öğrenimi (off-policy value learning) bir sonraki durumda $\max_{a'} Q(s', a')$ sorgusu yaptığında, veri setinde hiç görülmemiş aksiyonlara değer atar. Fonksiyon yaklaşıtrıcı bu bölgelerde eğitim sinyali almadığı için ekstrapolasyon hatası oluşur; hata Bellman yedeklemeleriyle büyür ve klinik veride güvenilirmez doz önerilerine dönüşebilir.

Literatürde bu hataya verilen yanıtlar üç grupta toplanabilir. CQL gibi açık aksiyon-uzayı düzenlileştirilmesi (explicit action-space regularization) yöntemleri veri dışı aksiyonların Q değerini düşürür ve kötümser bir alt sınır kurar [3]. IQL gibi in-sample (veri-içi) yöntemler gözlenmemiş aksiyonu sorgulamaz; veri içinde yüksek değerli görünen aksiyonların üst expectile değerini (expectile) öğrenir [5]. Durum-uzayı manifoldu düzenlileştirilmesi (state-space manifold regularization) ise cezayı aksiyonlardan durum manifoldunun dışına taşır. Bu çalışmada IQL hattı seçilmiştir; çünkü ek ceza katsayısı kalibrasyonundan önce destek içinde kalma ve yorumlanabilir doğrulama protokolü temel öncelik olarak belirlenmiştir.

Çok adımlı değer yayılımı (multi-step value propagation) bu çalışmanın doğrudan deney değişkeni değil, sonraki araştırma eksenidir. Tek adımlı yedeklemeler seyrek terminal mortalite (sparse terminal mortality) sinyalini 18 adımlık yörünge (trajectory) boyunca yavaş taşır; Peng'in $Q(\lambda)$ gibi uygunluk izi (eligibility trace) yaklaşımları bu gecikmeyi azaltabilir [11]. Bu raporda önce destek güvenliği ve sızıntısız değerlendirme (leakage-free evaluation) sabitlenmiştir. Multi-step operatör aynı anda değiştirilseydi, final IQL sonucunun reward/LR/expectile seçimi mi yoksa yedekleme operatörü mü nedeniyle değiştiği ayrıştırılmazdı.

IV. UÇTAN UCA PROJE MIMARISI

Proje, katı bağımlılık zinciriyle ilerleyen on ana adımdan oluşur. Bu yapı, veri hazırlama hatalarının final politika değerlendirmesine taşınmasını engellemek için bilinçli olarak aşamalı tasarlanmıştır.

Bu mimari tek bir eğitim betiği (training script) olarak değil, veri hazırlama, model eğitimi, değerlendirme ve raporlama katmanlarını birbirine bağlayan deney protokolü olarak ele alınır. Kohort tanımı, veri sözleşmesi, model eğitimi, Off-Policy Evaluation (OPE), güvenlik analizi ve raporlama çıktıları aynı deney protokolüne bağlanır. Bu bağlantı, bölme sızıntısı (split leakage), farklı ön işleme (preprocessing) veya hatalı transition indexing kaynaklı yapay performans artışlarının model başarısı olarak yorumlanmasını engeller.

V. KOHORT, ZAMAN VE SPLIT TASARIMI

A. Kohort Seçimi

Kohort MIMIC-IV üzerinde Sepsis-3 kriterlerine göre oluşturulur [9], [12]. Dahil edilen popülasyon 18 yaş ve üzeri

yetişkin, doğrudan yoğun bakım ünitesi izlemine sahip ve sepsis tanımıyla uyumlu hastalardır. Çocuk hastalar farklı doz ve fizyoloji rejimlerine sahip oldukları için dışarıda bırakılır; bu karar verilmeseydi model tek bir aksiyon-doz anlamını heterojen yaş grupları için öğrenmeye zorlanırdı. Yoğun bakım ünitesi dışı veya yoğun gözlem verisi olmayan hastalar da dışlanır; çünkü 4 saatlik karar pencereleri için yeterli fizyolojik zaman serisi kurulamaz.

Dışlama kuralları, karar penceresinin klinik ve zamansal tutarlılığını korumak amacıyla uygulanır. Sepsis onset zamanı bulunamayan hastalar, 4 saatten kısa yoğun bakım ünitesi kalışı olanlar ve yaş/cinsiyet gibi temel demografisi eksik olanlar çıkarılır. Tekrar yatan hastalarda yalnız ilk yatış kullanılır. Aynı hastanın bir yatışı eğitim setine (train set), sonraki yatışı test setine düşerse model kronik profili dolaylı olarak ezberleyebilir; bu nedenle filtreleme sonucu ve dışlanan hasta sayıları denetim çıktılarında (audit artifacts) saklanır.

B. Zaman Çizelgesi

Her yoğun bakım ünitesi kalışı için 'sepsis_onset_time' hesaplanır. Analiz penceresi onset'ten 24 saat önce başlayıp 48 saat sonrasına kadar devam eder. Bu 72 saatlik pencere 4 saatlik karar adımlarına ayrıldığında tipik epizot (episode) yaklaşık 18 zaman adımı (timestep) içerir. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger [6], [7]. Daha kısa pencere seçilseydi ölçüm eksikliği ve gürültülü aksiyon tekrarları artacak, davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde tahmin edilecekti. Daha uzun pencere seçilseydi de sıvı ve vazopresör değişimlerinin akut fizyolojik etkileri ortalamaya karışacak, ardışık karar yapısı zayıflayacaktı.

C. Split Stratejisi

Varsayılan split hasta düzeyinde eğitim %70, doğrulama %15 ve test %15 olarak yapılır. Bölme seed'i (split seed) 42 olarak sabitlenir. Eğitim, doğrulama ve test özne kümelerinin (subject sets) kesişimi boş olmalıdır. Test seti yalnız final raporlama için kullanılır; hiperparametre (hyperparameter), kontrol noktası (checkpoint) veya metrik tasarımı test sonucuna göre değiştirilmez. Bu kural ihlal edilseydi final test metrikleri gerçek ayrılmış (held-out) kanıt olmaktan çıkar, doğrulamanın uzantısı haline gelirdi.

VI. MDP FORMÜLASYONU

Problem sonlu ufuklu bir Markov karar süreci olarak modellenir [13]:

$$M = (S, A, P, R, \gamma). \quad (1)$$

Burada S hasta durum uzayını, A ayrık tedavi aksiyonlarını, P geçiş dinamiklerini, R ödül fonksiyonunu ve γ iskonto faktörünü (discount factor) temsil eder. Her geçiş şu biçimdedir:

$$(s_t, a_t, r_t, s_{t+1}, done_t). \quad (2)$$

Tablo I
PROJENİN ON AŞAMALI UÇTAN UCA MIMARISI.

Adım	Bileşen	İçerik
1	Kohort seçimi	MIMIC-IV içinden Sepsis-3 kriterlerine uyan yetişkin yoğun bakım ünitesi (ICU) hastalarının seçilmesi; geçersiz onset, kısa yoğun bakım ünitesi kalışı, eksik temel demografi ve tekrar yatışların yönetilmesi.
2	Zaman çizelgesi	Sepsis onset'inden 24 saat önce başlayıp 48 saat sonrasında uzanan 72 saatlik pencerenin 4 saatlik karar adımlarına bölünmesi.
3	Sıfır sızıntı (zero leakage) bölme (split)	Hastaların eğitim/doğrulama/test (train/validation/test) olarak hasta-düzeyinde ayrılması ve ön işleme uyarılama işlemlerinin (preprocessing fit) yalnız eğitim verisi (train) üzerinde yapılması.
4	Durum (state) çıkarımı	Yaşamsal bulgu (vital), laboratuvar, tedavi geçmişi, demografi, eksiklik (missingness) ve türetilmiş değişkenlerden 62 boyutlu durum vektörü üretilmesi.
5	Aksiyon/ödül (action/reward)	Vazopresör ve IV sıvı dozlarının 25 ayrık aksiyona dönüştürülmesi; seyrek ve SOFA-biçimli ödüllerin (sparse and SOFA-shaped rewards) üretilmesi.
6	Geçiş/baseline	replay dataset'in $(s_t, a_t, r_t, s_{t+1}, done_t)$ formatında oluşturulması; clinician replay, no-treatment ve Behavior Cloning (BC) baselines kurulması.
7-8	IQL eğitimi	Offline data üzerinde destek dışına çıkmadan expectile değer öğrenimi ve avantaj ağırlıklı aktör güncellemesi (advantage-weighted actor update) ile IQL politikalarının eğitilmesi.
9	OPE ve güvenlik	FQE, WIS, ESS, bootstrap confidence interval (CI), behavior support mass, clinician agreement, heatmap ve safety diagnostics hesaplanması.
10	Final sweep	18 konfigürasyonlu IQL sweep'i, finalist seçimi, multi-seed doğrulaması ve IEEE rapor çıktılarının (artifacts) üretilmesi.

A. Durum Temsili

Durum vektörü (state vector) hastanın o andaki klinik durumunu özetleyen 62 sürekli/ikili özellikten oluşur. Başlıca gruplar kalp hızı, MAP, sistolik/diyastolik tansiyon, solunum ve SpO2 gibi yaşamsal bulgular (vital signs); kan gazı, elektrolit, renal, hepatik, koagülasyon ve hemogram laboratuvarları; kümülatif sıvı, vazopresör maruziyeti ve idrar çıkışı gibi tedavi sinyalleri; yaş ve cinsiyet gibi demografik değişkenler; PaO2/FiO2, shock index ve onset sonrası saat gibi türetilmiş değişkenlerdir.

Her 4 saatlik pencerede birden fazla ölçüm varsa özelliğe göre 'last', 'mean', 'min', 'max', 'sum' veya 'cumulative' agregasyon kuralı uygulanır. Örneğin bazı yaşamsal bulgularda son ölçüm klinik karar anına daha yakın bilgi taşıırken, toplam sıvı veya kümülatif vazopresör maruziyeti pencere içi tedavi yükünü temsil eder. Tek bir agregasyon kuralı tüm değişkenlere dayatılsaydı klinik anlamı farklı sinyaller aynı istatistiksel kalıba sıkıştırılmış olurdu.

Eksik veriler için sıralı strateji uygulanır: epizot içinde forward-fill, eğitim bölmesi (train split) üzerinden hesaplanan medyan, klinik normal değer fallback ve gerekli durumda eksiklik göstergesi (missingness flag). Missingness göstergeleri eklenmeseydi model, ölçülmeyen laboratuvarı normal değerle karıştırabilir ve hekimin ölçüm kararıyla taşınan risk bilgisini kaybedebilirdi. Yalnız eğitim medyanı (train-only median) kullanılsaydı doğrulama/test dağılım bilgisi ön işleme üzerinden eğitime sızardı.

B. Aksiyon Uzayı (Action Space)

Aksiyon uzayı 25 ayrık tedavi kararından oluşur. Her aksiyon, vazopresör dozu ve IV sıvı miktarının 5×5 kombinasyonudur:

$$action_id = vaso_bin \times 5 + fluid_bin. \quad (3)$$

Tablo II
VAZOPRESÖR VE IV SIVI AKSİYON GRID'İ.

Vasopressor bin	Fluid bin				
	0	1	2	3	4
0	0	1	2	3	4
1	5	6	7	8	9
2	10	11	12	13	14
3	15	16	17	18	19
4	20	21	22	23	24

Bin 0 tedavi yok anlamına gelir; sıfır dışı (non-zero) dozlar eğitim bölmesi üzerindeki çeyrekliklere göre Q1-Q4 olarak ayrılır. Sıfır doz (zero dose) ayrı tutulur, çünkü hiç tedavi vermemek küçük ama sıfır dışı tedaviyle aynı klinik anlamı taşımaz. Bin eşikleri yalnız eğitim bölmesi üzerinde öğrenilir ve doğrulama/test üzerinde dondurulmuş şekilde uygulanır. Eşikler tüm veri üzerinde hesaplınsaydı test doz dağılımı aksiyon kodlamasına sızardı.

C. Ödül Tasarımı (Reward Design)

İki ödül varyantı kullanılır. Seyrek ödül yalnız terminal mortalite/sağkalım fayda değerini (utility) kullanır: 90 gün yaşayan hasta için +15, 90 gün içinde ölüm için -15. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir.

SOFA-biçimli ödül terminal faydayı (terminal utility) korur ve ara adımlarda SOFA değişimine küçük bir şekillendirme sinyali (shaping signal) ekler:

$$sofa_shaping = -0.025 \times (SOFA_{current} - SOFA_{previous}). \quad (4)$$

SOFA artışı kötüleşme olarak negatif, SOFA azalması iyileşme olarak pozitif sinyal üretir. SOFA'nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara

sinyali klinik olarak gerekçelendirir [12]. SOFA şekillendirilmesi (SOFA shaping) kullanılmıyaydı eğitim yalnız terminal sonuca dayanacak ve ara fizyolojik iyileşmeleri ayırt etmek zorlaşacaktı. Tersine, shaping ağırlığı çok güçlü seçilseydi ajan mortalite yerine kısa vadeli skor oynamalarını optimize edebilirdi; bu nedenle terminal fayda korunmuş ve seçim ortak terminal değerlendirmeye bağlanmıştır.

D. İskonto Faktörü

İskonto faktörü $\gamma = 0.99$ olarak sabitlenir. Bu seçim, sepsis tedavisinde kısa vadeli hemodinamik kararların uzun vadeli mortalite sonucuyyla ilişkili olması nedeniyle uygundur. Daha küçük bir γ kısa vadeli SOFA değişimlerini fazla öne çıkarabilir, $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilirdi.

VII. ÖN İŞLEME VE SIZINTISIZ SÖZLEŞMELER (PREPROCESSING AND LEAKAGE-FREE CONTRACTS)

Temel kural ‘eğitime uydur, her yerde dönüştür (fit on train, transform everywhere)’ şeklindedir. Ölçekleyici (scaler) parametreleri, atayıcı (imputer) medyanları, kırpma sınırı (clip bound) veya yüzdelik (percentile) eşikleri, action bin çeyreklik eşikleri (action-bin quartiles), davranış politikası tahminleyicisi (behavior policy estimator), FQE tahminleyicisi (FQE estimator) ve normalleştirme (normalization) sabitleri eğitim verisi üzerinde uydurulur (fit). Doğrulama ve test üzerinde yalnız eğitim verisinde uydurulmuş dönüşümler (transforms) uygulanır. Bu seçim, sağlık verisindeki sonuç sızıntısı ve tasarım sonrası model seçimi risklerine karşı önerilen raporlama ilkeleriyle uyumludur [8], [14].

Fizyolojik olarak makul olmayan değerler geçerli aralık (valid range) dışında filtrelenir veya kırpılır (clip). Kırpma (clipping) ve normalleştirme parametreleri eğitim bölümü üzerinde uydurulur. Bu tercih yapılmasaydı doğrulama/test dağılımının uç değer bilgisi eğitim öncesi veri dönüşümlerine yansiyabilir ve raporlanan performans fazla iyimser olurdu.

A. Aşama 0 Presweep Audit

Presweep audit, eğitim başlamadan önce veri sözleşmelerini test eder. Sağlıkta RL için bu kapı zorunludur; küçük bir bölme sızıntısı veya sonuç sızıntısı (outcome leakage), gözlemsel veride gerçek politika kalitesinden çok daha büyük görünen kazançlar üretebilir [8]. Denetim seyrek replay dataset (sparse replay) üretimini, seyrek ve SOFA-biçimli replay dataset (SOFA-shaped replay) dosyalarının aynı split/preprocessing/action bin/transition indexing/terminal outcome tanımlarını kullanmasını, aksiyon binlerinin (action bins) yalnız eğitim verisi (train-only) fit edilmesini, atama/ölçekleme/kırpma/normalleştirme (imputation/scaling/clipping/normalization) istatistiklerinin yalnız eğitim verisi kalmasını, doğrulama FQE’sinin ortak terminal sağkalım/ölüm ödülü (terminal survival/death reward) ile çalışmasını, zamansal hizalamayı (temporal alignment), hasta çakışması bulunmamasını ve mortalite/taburculuk (mortality/discharge) gibi gelecek sonuç bilgisinin (future outcome) durum özelliklerine (state features) sızmasını kontrol eder.

Tablo III
PRESWEEP AUDIT SUMMARY.

Kanıt kalemi	Eğitim	Doğrulama	Test
Split manifest satırı	12063	2585	2585
SOFA replay satırı	140635	30539	30046
Seyrek replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage analizi		Başarılı	

Bu denetim kapısı, aynı hastanın farklı bölmelere (splits) düşmesi veya terminal bilginin özelliklere sızması gibi klinik yapay zeka çalışmalarında sık görülen geçerlilik ihlallerini deney başlamadan önce sınırlar.

VIII. BASELINE POLİTİKALAR (BASELINE POLICIES)

Final test karşılaştırması üç referans politika içerir. Clinician replay, replay dataset’indeki gözlenen klinisyen aksiyonlarını değerlendirir ve davranış verisinin kendisini referans alır. No-treatment politikası (no-treatment policy), uygun yerlerde vazopresör yok/sıvı yok (no-vasopressor/no-fluid) bin’ini seçen basit kontrol politikasıdır. Behavior Cloning (BC) ise klinisyen aksiyonlarını gözetimli öğrenme (supervised learning) ile taklit eder. Bu baselineler, IQL çıktısının davranış politikası ve basit kontrol stratejilerine göre bağlandıırılmasını sağlar.

IX. IMPLICIT Q-LEARNING (IQL) ALGORİTMASI

Implicit Q-Learning (IQL), veri seti dışındaki (out-of-dataset) aksiyonları maksimize etmeden politika çıkarır [5]. Model üç parça öğrenir: eleştirmen (critic), değer işlevi (value function) ve aktör (actor). Eleştirmen $Q_\theta(s, a)$ durum-aksiyon değerini (state-action value) tahmin eder. Değer işlevi, klasik maksimum operatörü (max operator) yerine expectile regresyonu (expectile regression) ile uydurulur. Expectile düştükçe değer hedefi davranış verisine yaklaşır; expectile yükseldikçe veri içindeki daha yüksek değerli aksiyonlara ağırlık verir.

Değer amacı (value objective) asimetrik expectile kaybı (expectile loss) ile yazılır:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim D} [L_2^T(Q_\theta(s, a) - V_\psi(s))], \quad (5)$$

$$L_2^T(u) = |\tau - \mathbb{I}(u < 0)|u^2. \quad (6)$$

τ 1’e yaklaştıkça değer fonksiyonu davranış verisi içinde daha iyi görünen aksiyonların üst expectile değerine (upper expectile) yaklaşır. Q fonksiyonu ise veri dışı aksiyon maksimumu yerine öğrenilen durum-değer hedefiyle (state-value target) güncellenir:

$$L_Q(\theta) = \mathbb{E}_D [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (7)$$

Aktör, veri seti içindeki (in-dataset) aksiyonları avantaja (advantage) göre ağırlıklandırarak öğrenir:

$$A(s, a) = Q_\theta(s, a) - V_\psi(s), \quad (8)$$

$$L_\pi(\phi) = \mathbb{E}_D [\exp(\beta A(s, a)) \log \pi_\phi(a|s)]. \quad (9)$$

Algorithm 1 Final IQL Sweep ve Raporlama İş Akışı

- 1: Replay dataset, bölme ve ön işleme (replay, split, preprocessing) ve zamansal sözleşmeleri doğrula
 - 2: Ödül, öğrenme oranı ve IQL ayarlarını genişlet
 - 3: **for** her Aşama 1 adayı **do**
 - 4: Seed 42 ile politikayı eğit
 - 5: Doğrulama metriklerini ve destek teşhislerini hesapla
 - 6: **end for**
 - 7: Güvenlik veya destek kapılarını geçemeyen adayları işaretle
 - 8: Bileşik skor (composite), ödül dengesi, güvenlik ve çeşitlilik slotlarıyla finalist seç
 - 9: **for** her finalist ve her doğrulama seed'i **do**
 - 10: Seed 123 ve 456 ile politikayı eğit veya yeniden kullan
 - 11: Multi-seed değerlendirme kanıtını toplama
 - 12: **end for**
 - 13: Tekrarlanan seed kanıtıyla final konfigürasyonu seç
 - 14: Baseline karşılaştırmaları (baseline comparisons), grafikler ve yeniden üretilebilirlik çıktıları üret
-

Burada β ya da temperature politika çıkarımının agresifliğini kontrol eder. Düşük temperature davranış politikasına daha yakın ve konservatif politika çıkarır; yüksek temperature potansiyel getiriye artırabilir fakat low-support action'lara kayma riskini de büyütür. Bu nedenle güvenli (safe), referans (baseline) ve iyimser (optimistic) ayarları birlikte denenmiştir.

X. IQL FINAL SWEEP TASARIMI

Final sweep iki ödül varyantı, üç öğrenme oranı (learning-rate) rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Öğrenme oranı rejimleri (learning-rate regimes) aktör, eleştirmen ve değer (value) optimizasyonunu ayrı olarak kontrol eder. Konservatif öğrenme oranı rejimi finalde öne çıkarılmıştır; çünkü offline RL'de agresif eleştirmen güncellemeleri (critic updates) veri dışı Q tahminlerini büyütebilir ve politika çıkarımı bu hataları çoğaltabilir [3], [5]. Referans rejim (baseline regime) yalnızca referans çapa (baseline anchor) olarak tutulmuştur; hiç denenmeseydi konservatif seçimin gerçekten gerekli olup olmadığı gözlenemezdi. Aktör-konservatif rejim ise politika güncellemelerini yavaşlatmanın, eleştirmen/değer (critic/value) öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.

Sabit parametreler korunmuştur; böylece final sweep yalnızca ödül (reward), öğrenme oranı rejimi, expectile ve temperature etkisini ölçer. Sabit parametreler, 18 konfigürasyonun etkisini ödül, öğrenme oranı ve IQL ayarları üzerinde izole etmeyi sağlar.

XI. SEED STRATEJİSİ (SEED STRATEGY) VE KARAR KURALI

Tek seed'li (single-seed) değerlendirme, offline RL modellerinde kararlı politika seçimi için yetersiz kanıt üretir. Başlatma (initialization), mini-yığın (minibatch) sırası ve stokastik optimizasyon (stochastic optimization) aynı konfigürasyonun FQE/WIS değerini değiştirebilir. Aşama 1'de 18 konfigürasyon

seed 42 ile taranır; ardından altı finalist seed 123 ve 456 ile yeniden değerlendirilir. Böylece tüm $2 \times 3 \times 3 \times 3 = 54$ çalıştırma (run) yerine 30 çalıştırma çalıştırılır. Bu tasarım hesaplama maliyetini düşürür, fakat final adayları üç seed üzerinden raporladığı için seed varyansı (seed variance) görünür kalır.

Hiperparametre seçimi test set üzerinden yapılmaz. Seçim doğrulama bölmesi üzerindeki FQE, WIS, ESS, clinician agreement, aksiyon dağılımı (action distribution) makullüğü, low-support action uyarıları, ödül eğrisi (reward curve) ve eğitim kararlılığı (training stability) sinyallerine dayanır. Tek bir metrikle karar verilmez. Örneğin yüksek WIS ama çok düşük ESS varsa bu sonuç güvenilir kabul edilmez.

Bir konfigürasyon final aday olmadan önce doğrulama performansı rekabetçi olmalı, ESS çok düşük olmamalı, FQE sonucu WIS ile tamamen çelişmemeli, aksiyon dağılımı klinik olarak makul olmalı, low-support action oranı kabul edilebilir düzeyde olmalı, farklı seed'lerde (seeds) performans tamamen kararsız olmamalı ve test set seçim sürecinde kullanılmaması olmalıdır.

XII. AŞAMA 1 FINALIST SEÇİM SONUÇLARI

Aşama 1 seçici altı finalist üretmiştir. En yüksek iki aday SOFA-biçimli ödül ve konservatif öğrenme oranı kullanırken, diğer slotlar seyrek ödül temsilini, güvenlik-destek dengesini, referans çapa seçimini ve çeşitlilik tamamlama (diversity back-fill) kuralını korur. Tablo VI, seçilen adayları ve ana doğrulama teşhislerini gösterir.

Finalist havuzu (finalist pool) tek bir skora göre seçilmez. Klinik offline learning'de yüksek değer tahmini (value estimate), düşük behavior support ile birleştiğinde güvenilir değildir [8]. Yalnız en yüksek FQE veya WIS kullanılsaydı, düşük ESS ya da zayıf clinician exact-bin agreement taşıyan bir politika Aşama 2'ye geçebilirdi. Çeşitlilik slotları da bu yüzden korunur: Aşama 2 yalnız SOFA-konservatif adayları tekrar etmez; seyrek ödülün ve baseline settings'in sınırlarını da gösterir.

XIII. AŞAMA 2 VE BASELINE DEĞERLENDİRMESİ

Aşama 2, altı finalist ve üç seed'den oluşan on sekiz satırlık bir tekrarlı-seed özeti üretmiştir. Her finalist için seed 42, 123 ve 456 kontrol noktaları (checkpoints) test replay dataset (test replay) üzerinde yeniden değerlendirilmiştir. Tek seed'li seçim yapılmış olsaydı rastgele başlatma, mini-yığın sırası veya erken eğitim dalgalanması final politika kararını belirleyebilirdi. Üç seed, hesaplama maliyetini sınırlı tutarken bu varyansı görünür yapar; daha fazla seed istatistiksel güveni artırır, fakat final sweep maliyetini doğrusal olarak büyütürdü.


Final skor; FQE, WIS, ESS, behavior support mass, clinician exact-bin agreement, low-support cezası ve güvenlik bayraklarını üç seed ortalamasıyla birleştirir. FQE fonksiyon yaklaştırmaya dayalı değer tahmini verir; WIS davranış politikasına göre ağırlıklandırılmış gözlemsel kanıt sağlar. İkisini birlikte kullanmak, tek tahminleyicinin (estimator) yanlılık-varyans profilini final kararına dönüştürmemek içindir [2], [8], [15]. ESS ve behavior support mass olmasaydı, birkaç

Tablo IV
FINAL IQL HYPERPARAMETER GRID (HIPERPARAMETRE IZGARASI).


Boyut	Seenek	Deęerler
Ödöl	seyrek	terminal sağkalım/ölüm faydası (terminal survival/death utility)
Ödöl	SOFA-biimli	terminal fayda + SOFA deęişim şekillendirmesi (shaping)
LR rejimi	konservatif (conservative)	aktör 3×10^{-5} , eleştirmen 1×10^{-4} , deęer 1×10^{-4}
LR rejimi	referans	aktör 1×10^{-4} , eleştirmen 3×10^{-4} , deęer 3×10^{-4}
LR rejimi	aktör-konservatif (actor-conservative)	aktör 3×10^{-5} , eleştirmen 3×10^{-4} , deęer 3×10^{-4}
IQL ayarı	güvenli	expectile 0.7, temperature 1.0
IQL ayarı	referans	expectile 0.7, temperature 3.0
IQL ayarı	iyimser	expectile 0.8, temperature 3.0

Tablo V
SABİT EęİTİM PARAMETRELERİ.


Parametre	Deęer
Algoritma	IQL
Epoch	200
Yığın boyutu (batch size)	256
İskonto (discount)	0.99
Politika gizli katman boyutları (policy hidden sizes)	[256, 256]
Deęer gizli katman boyutları (value hidden sizes)	[256, 256]
Eleştirmen gizli katman boyutları (critic hidden sizes)	[256, 256]
Polyak tau	0.005
Hedef güncelleme sıklığı (target update freq)	10
Gradyan kırpması (grad clip)	10.0
Cihaz (device)	auto



Şekil 2. Final seçili IQL politikası ve baselines için WIS ve ESS teşhisleri. Behavior Cloning (BC) WIS değeri yüksek görünse de ESS=1.6 olduęu için güvenilir politika üstünlüęü kanıtı olarak yorumlanmaz.



Şekil 1. Doğrulama değeri tahmini ile behavior support teşhislerinin birlikte gösterimi. Yüksek değeri yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.



Şekil 3. Aşama 2 finalistleri için tekrarlı-seed FQE deęişkenlięi. Daha düşük değeri, aynı konfigürasyonun seed'ler arasında daha stabil olduęunu gösterir.

yüksek ağırlıklı yörünge yüksek WIS değeri güvenli gör-
terebilirdi. Clinician agreement (klinikyen uyumu) olmasaydı
politika davranış verisinden gereęinden fazla uzaklaşabilirdi.
Bu kurala göre final konfigürasyon SOFA-biimli (SOFA-
shaped), konservatif öğrenme oranı ve güvenli IQL (safe IQL)
ayarına sahip 'iql_sofa_shaped_conservative_safe' modelidir.

XIV. AKSİYON VE GÜVENLİK TEŞHİSLERİ (ACTION AND SAFETY DIAGNOSTICS)

Deęer metrięi (value metric) tek başına klinik politika
güvenlięi göstermez. Bir politika iyi FQE üretebilir, fakat göz-

lemsel veride nadir görülen sıvı-vazopresör kombinasyonlarına
kayabilir. Bu yüzden action heatmap, behavior support mass,
low-support rate, clinician agreement ve action entropy aynı
anda okunur.

Teşhis okuması (diagnostic reading) somut sorulara da-
yanır: politika sürekli yüksek sıvı veya yüksek vazopresör
mü öneriyor, 'no-treatment' bini'ne çöküyor mu, low-support
action'ları sık seçiyor mu, yüksek riskli alt gruplarda uyarılar
artıyor mu, ödöl varyantı (reward variant) deęişince aksiyon
dağılımı dramatik biçimde deęişiyor mu? Protokol bu sorular

Tablo VI
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.

Sıra	Yuva (slot)	Ödül	LR	IQL	FQE	WIS	support mass	agreement
1	en iyi bileşik (top composite)	SOFA	konservatif	güvenli	3.169	8.616	0.965	0.418
2	en iyi bileşik	SOFA	konservatif	referans	2.280	7.009	0.973	0.401
3	en iyi seyrek (best sparse)	sparse	konservatif	güvenli	1.954	8.740	0.971	0.411
4	güvenlik desteği (safety support)	sparse	referans	referans	1.421	6.768	0.973	0.410
5	referans çapa	sparse	referans	güvenli	2.345	8.125	0.963	0.416
6	çeşitlilik tamamlama	sparse	konservatif	referans	2.012	7.782	0.969	0.407

Tablo VII
AŞAMA 2 ÜÇ-SEED FINALIST DEĞERLENDİRMESİ. SKOR; FQE, WIS, ESS, SUPPORT MASS, EXACT-BIN AGREEMENT VE LOW-SUPPORT CEZASINI BİRLEŞTİREN SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	support mass	agreement
1	SOFA konservatif güvenli	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif referans	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif güvenli	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif referans	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline güvenli	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline referans	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo VIII
FINAL SEÇİLİ IQL POLİTİKASININ SEED-DÜZEYİ TEST SONUÇLARI. BU SATIRLAR TABLO X'DEKİ ÜÇ-SEED ORTALAMASININ KAYNAĞINI GÖSTERİR.

Seed	FQE	WIS	ESS	agreement
123	2.806	7.116	31.97	0.417
42	3.217	10.218	28.73	0.414
456	2.520	8.160	27.52	0.410
Ortalama	2.848	8.203	29.41	0.414

Tablo IX
BASELINE POLİTİKA WIS TEŞHİSLERİ. FQE YALNIZ ÖĞRENİLMİŞ IQL KONTROL NOKTASI İÇİN RAPORLANIR; BASELINES İÇİN WIS/ESS VE CLINICIAN AGREEMENT AYNI TEST REPLAY DATASET ÜZERİNDE HESAPLANMIŞTIR.

Politika	WIS	ESS	agreement
Clinician replay	8.774	2585.0	1.000
No-treatment	7.464	34.2	0.354
Behavior Cloning	9.194	1.6	0.405
Seçili IQL	8.203	29.4	0.414

için clinician action distribution, IQL policy action distribution, difference heatmap, low-support action oranı, subgroup'a göre clinician agreement, high-risk subgroup policy action frequency, eğitim kaybı eğrileri (training loss curves), doğrulama metrik eğrileri, ödül varyantı kutu grafiği, LR rejimi karşılaştırması ve expectile-temperature karşılaştırması grafiklerini çıktı olarak üretir.

Aşama 2 finalistlerinde behavior support mass 0.990–0.991, clinician exact-bin agreement 0.401–0.418 aralığındadır. Kazanan politikanın exact-bin agreement değeri 0.414'tür; yani kararların 0.586'lık kısmı klinisyen davranışıyla birebir aynı değildir. Buna rağmen low-support action deviation değeri 0.009'da kalır. Bu ayrım önemlidir: politika klinisyeni kopya-





Tablo X
KAZANAN KONFIGÜRASYONUN TEST DIAGNOSTICS (TEST TEŞHİSLERİ). WIS CONFIDENCE INTERVAL, 50 HASTA-DÜZEYİ PATIENT-LEVEL BOOTSTRAP RESAMPLING İLE HESAPLANMIŞTIR.

Metrik	Sonuç
FQE	2.848
WIS	8.203
WIS 95% CI	4.963–10.817
ESS	29.410
Behavior support mass	0.991
Clinician exact-bin agreement	0.414
Clinician exact-bin disagreement	0.586
Low-support action deviation	0.009

lamaz, fakat çoğu çoğu sapma veri desteği bulunan komşu tedavi yörüngelerinde kalır. ESS ise tüm finalistlerde 50 eşliğinin altındadır. Bu uyarı, az sayıda etkili yörüngenin taşıdığı WIS tahmininin kesin klinik sonuç gibi yorumlanmasını engeller. Bu nedenle final karar “klinik üstünlük” değil, destek kısıtı belirtilmiş retrospektif OPE sonucudur.

XV. YENİDEN ÜRETİLEBİLİRLİK (REPRODUCIBILITY) VE TEKNOLOJİ YİĞİNİ

İş akışı protokoldeki ana boşlukları kapatır: final IQL sweep runner, 18 konfigürasyonlu grid, workflow seviyesinde orkestrasyon, presweep audit, final-altı seçim mantığı, tekrarlı-seed Aşama 2 birleştirmesi, baseline karşılaştırması ve final grafik raporları. Çıktı seti (artifact set) presweep audit sonucunu, Aşama 1 seçim tablosunu, Aşama 2 seed özetini (seed summary), final metrik paketi (final metrics bundle)'ı, baseline politika gösterimini ve raporda kullanılan behavior support mass, seed varyansı, Pareto frontier, OPE sıralaması, aksiyon, bootstrap, clinician agreement, subgroup safety ve sapma şiddeti grafiklerini içerir. Aşama 2 değerlendirmesi 18 finalist-seed (finalist-seed) satırı olarak saklanır.




Teknoloji yığını (technology stack) Python ve ‘uv’ tabanlı ortam yönetimi, yüksek hızlı ‘Polars’ ve ‘PyArrow’ tabanlı Parquet veri dönüşümü, ‘PyTorch’ ve özelleştirilmiş ‘d3rlpy’ tabanlı RL eğitimi, ‘Hydra’ konfigürasyon yönetimi, ‘MLflow’ deney takibi ve IEEE LaTeX raporlamasından oluşur. Hardware-agnostic execution layer (donanımdan bağımsız yürütme katmanı) sayesinde eğitim kodu MPS, CUDA veya otomatik cihaz seçimiyle çalışabilir. Bu altyapı ayrıştırılmasaydı deney sonuçları belirli bir donanıma veya elle değiştirilmiş konfigürasyonlara bağımlı hale gelirdi.

Her çalıştırma için git commit özeti (git commit hash), konfigürasyon dosyası (config file), ödül varyantı, LR rejimi, expectile, temperature, seed, veri seti yolu (dataset path), metadata yolu (metadata path), bölme manifestosu seed'i (split manifest seed), action bin çıktısı (action bin artifact), eğitim günlükleri (training logs), kontrol noktası yolu (checkpoint path), değerlendirme çıktısı (evaluation output) ve figür yolları (figure paths) kaydedilmelidir. Çalıştırma isimlendirme (run naming) şablonu ödül, LR rejimi, IQL ayarı ve seed bilgisini birlikte taşıyan 'iql_reward_lr_setting_seed' biçimindedir. Örneğin SOFA-biçimli, actor-conservative, baseline ve seed 42 bilgileri aynı çalıştırma adında saklanır. Bu sözleşme tutulmasaydı sonradan hangi kontrol noktasının hangi veri ve konfigürasyonla üretildiği izlenemezdi.


XVI. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve gözlemseldir (observational); öğrenilen politika yatak başı tedavi önerisi değildir. Durum vektörü gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen karıştırıcılık etkilerini tam kapsamaz. Gerçek klinik süreç kısmi gözlemlenebilir Markov karar sürecine (partially observable Markov decision process, POMDP)'ye daha yakındır; model hekimin tüm yatak başı bilgisini görmez. Klinisyen aksiyonları (clinician actions) da karıştırıcılık taşıır: daha ağır hastalara daha agresif vazopresör verilmesi, tedaviyi zararlı gösterebilir veya yanlış fayda atfı üretebilir.

MIMIC-IV verisi PhysioNet credentialing, CITI training ve Data Use Agreement kapsamındaki yükümlülöklere tabidir; hasta verileri kimliksizleştirilmiř olsa da raporlama akademik ve etik sınırlar içinde kalmalıdır. FQE ve WIS prospektif klinik kanıt (prospective clinical evidence) deęildir; fonksiyon yaklařımı, davranıř politikası (behavior policy) tahmini, destek varsayımları ve varyans profiline (variance profile) baęlıdır. ESS deęerinin 50 eřięinin altında kalması ve patient-level



Şekil 8. Finalist politikalar için clinician exact-bin agreement. Bu metrik, politikanın davranış verisinden ne kadar uzaklaştığını gösterir; tek başına performans kanıtı değildir, destek ve OPE metrikleriyle birlikte yorumlanır.




Şekil 9. Yüksek riskli alt gruplarda clinician agreement ve low-support action oranı. Bu teşhis, final politikanın ortalama hasta dışındaki daha kırılgan alt gruplarda da destek sınırlarını koruyup korumadığını inceler.

bootstrap resampling sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.

XVII. SONUÇ

IQL final sweep iş akışı, sepsis dozaj politikalarını tek seferlik bir model çıktısı olarak değil, denetlenebilir bir çevrimdışı değerlendirme protokolü olarak ele alır. Kohort seçimi, zaman penceresi, state/action/reward mühendisliği, sızıntısız ön işleme (leakage-free preprocessing), IQL eğitimi, hyperparameter grid, Aşama 1 finalist seçimi ve Aşama 2 çoklu-seed değerlendirmesi aynı raporda izlenebilir hale gelir. Aşama 0 presweep audit geçilmiştir; Aşama 1 altı destek-duyarlı finalist üretmiştir. Aşama 2 sonucunda final konfigürasyon ‘iql_sofa_shaped_conservative_safe’ olarak seçilir. Model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 verir; ancak ESS=29.41 ile güvenilirlik eşliğinin altındadır. Bu nedenle sonuç klinik performans kanıtı değil, metodolojik ve retrospektif OPE kanıtıdır.



Şekil 10. Politika aksiyonlarının klinisyen aksiyonlarından sapma şiddeti. Sapma analizi, exact-bin disagreement’ın klinik grid üzerinde küçük komşu hareketlerden mi yoksa daha büyük dozaj değişimlerinden mi kaynaklandığını gösterir.

KAYNAKLAR

- [1] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” *arXiv preprint arXiv:2005.01643*, 2020.
- [2] C. Voloshin, H. M. Le, N. Jiang, and Y. Yue, “Empirical study of off-policy policy evaluation for reinforcement learning,” in *NeurIPS Datasets and Benchmarks*, 2021.
- [3] A. Kumar, A. Zhou, G. Tucker, and S. Levine, “Conservative q-learning for offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, 2020.
- [4] S. Fujimoto, D. Meger, and D. Precup, “Off-policy deep reinforcement learning without exploration,” in *Proceedings of the 36th International Conference on Machine Learning*, 2019, pp. 2052–2062.
- [5] I. Kostrikov, A. Nair, and S. Levine, “Offline reinforcement learning with implicit q-learning,” in *International Conference on Learning Representations*, 2022.
- [6] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, “The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care,” *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [7] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, “Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach,” in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [8] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, “Guidelines for reinforcement learning in healthcare,” *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [9] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, “Mimic-iv, a freely accessible electronic health record dataset,” *Scientific Data*, vol. 10, no. 1, p. 1, 2023.
- [10] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, “Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021,” *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.
- [11] J. Peng and R. J. Williams, “Incremental multi-step q-learning,” *Machine Learning*, vol. 22, no. 1–3, pp. 283–290, 1996.
- [12] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Annane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, “The third international consensus definitions for sepsis and septic shock (sepsis-3),” *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.
- [13] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018.
- [14] S. Liu, K. C. See, K. Y. Ngiam, L. A. Celi, X. Sun, and M. Feng, “Reinforcement learning for clinical decision support in critical care: Comprehensive review,” *Journal of Medical Internet Research*, vol. 22, no. 7, p. e18477, 2020.
- [15] D. Precup, R. S. Sutton, and S. P. Singh, “Eligibility traces for off-policy policy evaluation,” in *Proceedings of the Seventeenth International Conference on Machine Learning*, 2000, pp. 759–766.