

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Çevrimdışı Pekiştirmeli Öğrenme İş Akışı

Furkan Nezih Üzmez
230202073

Özet—Bu rapor, MIMIC-IV tabanlı sepsis kohortunda int-ravenöz sıvı ve vazopresör tedavi kararlarını değerlendirmek için geliştirilen uçtan uca, zero-leakage ve yeniden üretilebilir bir offline pekiştirmeli öğrenme iş akışını sunar. Çalışma canlı hastalar üzerinde çevrimiçi keşif yapmaz; yalnızca retrospektif yoğun bakım kayıtlarından model-free, off-policy ve offline politika öğrenimi yapar. Proje Sepsis-3 kohort seçimi, 72 saatlik klinik pencereleme, 62 boyutlu durum temsili, 5×5 ayrık aksiyon uzayı, sparse ve SOFA-shaped ödül varyantları, train-only preprocessing, hasta-düzeyi split, IQL hiperparametre taraması, çok kriterli finalist seçimi, çoklu tohum doğrulaması, off-policy evaluation ve raporlanabilir grafik artifactlerini kapsar. Final IQL taraması iki ödül varyantı, üç learning-rate rejimi ve üç expectile-temperature ayarından oluşan on sekiz konfigürasyonu Aşama 1’de değerlendirir; Aşama 2’de seçilen altı finalist üç tohumla doğrulanır. Güncel sonuçlar, final seçili politikanın SOFA-shaped ödül, konservatif learning-rate ve safe IQL ayarını kullanan ‘iql_sofa_shaped_conservative_safe’ konfigürasyonu olduğunu gösterir. Bu aday üç tohum ortalamasında FQE=2.848, WIS=8.203, bootstrap WIS 95% CI=4.963–10.817, ESS=29.410, destek kütle=0.991 ve klinisyen exact-bin uyumu=0.414 elde etmiştir. ESS 50 eşliğinin altında kaldığından sonuç klinik üstünlük kanıtı olarak değil, destek kısıtı açıkça raporlanan retrospektif off-policy değerlendirme kanıtı olarak yorumlanmalıdır.

Index Terms—offline pekiştirmeli öğrenme, implicit Q-learning, sepsis, MIMIC-IV, off-policy evaluation, yeniden üretilebilirlik, klinik karar desteği

I. GİRİŞ

Sepsis tedavisi, belirsizlik altında ardışık kararlar, gecikmeli sonuçlar ve klinik şiddete bağlı confounding içeren bir yoğun bakım problemidir. Offline pekiştirmeli öğrenme, hasta üzerinde yeni denemeler yapmadan tarihsel klinik trajektorilerden politika öğrenmeyi sağlar. Bu özellik tıbbi ortamda kritiktir; çünkü çevrimiçi keşif etik olarak kabul edilemez. Ancak offline öğrenme, desteklenmeyen aksiyonlara kayma, yüksek varyanslı off-policy estimatorler ve validasyon artifactlerine aşırı uyum gibi riskler taşır.

Bu projenin amacı, MIMIC-IV verisi üzerinde sepsis tedavisi için güvenilir bir klinik karar destek değerlendirme altyapısı kurmaktır. Sistem yatak başı canlı tedavi aracı değildir; geriye dönük offline policy evaluation ve model karşılaştırma laboratuvarıdır. Model sınıfı model-free, off-policy ve offline RL’dir; proje genelinde CQL, BCQ ve IQL aileleri değerlendirme bağlamında düşünülmüş, final rapor odağı IQL olarak belirlenmiştir. Kod tabanı cihaz-bağımsız çalışacak şekilde tasarlanmıştır; Apple Silicon MPS ve NVIDIA CUDA ortamlarında aynı eğitim mantığıyla çalışması hedeflenmiştir.

Bu proje, MIMIC-IV tabanlı sepsis kohortunda dört saatlik karar pencereleriyle retrospektif politika değerlendirmesi yapar. Aksiyon uzayı, vazopresör ve intravenöz sıvı şiddetinin 5×5 ayrık kombinasyonudur. Final deneyin amacı IQL konfigürasyonlarını iki ödül varyantı altında karşılaştırmak, güvenilir finalistleri yalnız validasyon kanıtıyla seçmek ve raporlanabilir bir artifact bundle üretmektir. Bu çalışmada protokol, açık denetim kapıları, deterministik konfigürasyon genişletmesi, çoklu tohum birleştirmesi ve grafik raporlama ile çalışır hale getirilmiştir.

II. İLGİLİ ÇALIŞMALAR

Offline pekiştirmeli öğrenme sabit veri kümelerinden politika öğrenme problemine odaklanır. IQL, veri dışı aksiyonları doğrudan maksimize etmek yerine expectile value learning ve advantage-weighted behavioral cloning kullanarak konservatif offline ortamlara uygun bir yaklaşım sunar [1]. Bu tercih CQL gibi açık Q-cezası kullanan yöntemlere göre daha sade bir seçimdir: CQL extrapolation error riskini doğrudan cezalandırır, fakat ceza ağırlığı yanlış seçildiğinde klinik olarak makul ama nadir aksiyonları aşırı bastırabilir [2]. IQL ise veri içi Q yedekleriyle ve davranış klonlamasına yakın politika çıkarımıyla destek dışına taşmayı azaltır; bunun bedeli, veri dağılımında hiç temsil edilmeyen tedavi stratejilerini keşfedememesidir.

Sepsis alanında RL çalışmalarının temel örnekleri, sıvı ve vazopresör dozlarını ayrık tedavi aksiyonları olarak modelleyen AI Clinician çalışması ve sürekli durum temsiliyle optimal sepsis tedavisi öğrenmeye çalışan derin RL yaklaşımıdır [3], [4]. Bu çizgideki sonuçlar klinik karar desteği için umut verici olsa da, sağlıkta RL rehberleri gözlemsel veriden öğrenilen politikaların confounding, destek eksikliği, estimator varyansı ve prospektif doğrulama eksikliği nedeniyle doğrudan tedavi önerisi sayılamayacağını vurgular [5]. Bu nedenle bu raporun amacı da klinik üstünlük iddiası üretmek değil, raporlanabilir ve yeniden üretilebilir bir offline değerlendirme kanıtı oluşturmaktır. Veri temeli, de-identified kritik bakım kayıtları sağlayan MIMIC-IV veri tabanıdır [6]; tedavi aksiyonlarının sıvı ve vazopresör eksenlerinde kurulması ise sepsis ve septik şok yönetiminde bu iki müdahalenin merkezi rol oynadığı güncel kılavuzlarla uyumludur [7].

III. KURAMSAL ARKA PLAN VE ALGORİTMİK KONUMLANDIRMA

Offline RL’de temel gerilim, politika iyileştirmesi ile veri desteği dışına taşmama zorunluluğu arasındadır. Klasik off-policy değer öğrenimi, bir sonraki durumda $\max_{a'} Q(s', a')$ gibi veri setinde gözlenmemiş aksiyonları sorguladığında, fonksiyon yaklaşıtımcıların eğitim sinyali almadığı bölgelerde extrapolation error oluşur. Bu hata Bellman yedeklemeleriyle tekrar tekrar taşınır ve özellikle klinik veri gibi seyrek, heterojen ve confounded alanlarda politikayı güvenilmez doz önerilerine yöneltebilir.

Bu riske karşı literatürde üç ana yaklaşım öne çıkar. Birincisi, CQL gibi explicit action-space regularization yöntemleridir; bu yöntemler veri dışı aksiyonların Q değerlerini cezalandırarak kötümser bir alt sınır kurar [2]. İkincisi, IQL gibi implicit ve in-sample regularization yöntemleridir; bu yöntemler gözlenmemiş aksiyonları doğrudan sorgulamak yerine veri içi aksiyonların üst expectile değerlerini öğrenir [1]. Üçüncüsü, daha yeni state-space manifold regularization fikirleridir; bunlar aksiyon uzayı yerine durum manifoldunun dışındaki bölgelerde value fonksiyonunu cezalandırmayı önerir. Bu proje klinik güvenlik ve uygulama sadeliği nedeniyle IQL hattını kullanır, fakat CQL ve state-space regularization fikirlerini sonuçların yorumlanmasında karşılaştırmalı arka plan olarak dikkate alır.

Referans araştırma taslaklarında vurgulanan multi-step value propagation fikri de bu çalışma için önemli bir gelecek yönüdür. Tek adımlı yedeklemeler sparse terminal mortalite sinyalini uzun trajectory boyunca yavaş taşır; Peng’in $Q(\lambda)$ gibi eligibility trace tabanlı yaklaşımlar bu sinyali daha hızlı yayabilir. Ancak mevcut klinik final raporda, önce destek güvenliği ve leakage-free değerlendirme sabitlenmiş; multi-step operatörler daha sonra eklenecek araştırma eksenini olarak bırakılmıştır. Bu tercih yapılmasaydı final IQL sonucunun etkisi, aynı anda değişen yedekleme operatörü ve güvenlik protokolü nedeniyle ayrıştırılamazdı.

IV. UÇTAN UCA PROJE MIMARISI

Proje, katı bağımlılık zinciriyle ilerleyen on ana adımdan oluşur. Bu yapı, veri hazırlama hatalarının final politika değerlendirmesine taşınmasını engellemek için bilinçli olarak aşamalı tasarlanmıştır.

Bu mimari tek bir eğitim scriptinden daha fazlasıdır: kohort tanımı, veri sözleşmesi, model eğitimi, off-policy değerlendirme, güvenlik analizi ve raporlama artifactleri aynı deney protokolünün parçalarıdır. Böyle seçilmeseydi final IQL sonucu üretilebilir görünse bile, veri hazırlama, split sızıntısı veya preprocessing farkı gibi alt seviye hatalar model başarısı sanılabildi.

V. KOHORT, ZAMAN VE SPLIT TASARIMI

A. Kohort Seçimi

Kohort MIMIC-IV üzerinde Sepsis-3 kriterlerine göre oluşturulur [6], [8]. Dahil edilen popülasyon 18 yaş ve üzeri yetişkin, doğrudan ICU izlemine sahip ve sepsis tanımıyla uyumlu hastalardır. Çocuk hastalar farklı doz ve fizyoloji

rejimlerine sahip oldukları için dışarıda bırakılır; bu karar verilmeseydi model tek bir aksiyon-doz anlamını heterojen yaş grupları için öğrenmeye zorlanırdı. ICU dışı veya yoğun gözlem verisi olmayan hastalar da dışlanır; çünkü 4 saatlik karar pencereleri için yeterli fizyolojik zaman serisi kurulamaz.

Dışlama kuralları metodolojik güvenlik için açık tutulmuştur. Sepsis onset zamanı bulunamayan hastalar, 4 saatten kısa ICU kalışı olanlar ve yaş/cinsiyet gibi temel demografisi eksik olanlar çıkarılır. Tekrar yatan hastalarda yalnız ilk yatış kullanılır. Bu en kritik zero-leakage kararlarından biridir: aynı hastanın bir yatışı train setine, sonraki yatışı test setine düşerse model hasta anatomisini veya kronik profilini dolaylı olarak ezberleyebilir. Filtreleme sonucu ve dışlanan hasta sayısı audit artifactleriyle belgelenir.

B. Zaman Çizelgesi

Her ICU kalışı için ‘sepsis_onset_time’ hesaplanır. Analiz penceresi onset’ten 24 saat önce başlayıp 48 saat sonrasına kadar devam eder. Bu 72 saatlik pencere 4 saatlik karar adımlarına ayrıldığında tipik episode yaklaşık 18 timestep içerir. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger [3], [4]. Daha kısa pencere seçilseydi ölçüm eksikliği ve gürültülü aksiyon tekrarları artacak, davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde tahmin edilecekti. Daha uzun pencere seçilseydi de sıvı ve vazopresör değişimlerinin akut fizyolojik etkileri ortalamaya karışacak, ardışık karar yapısı zayıflayacaktı.

C. Split Stratejisi

Varsayılan split hasta düzeyinde train %70, validation %15 ve test %15 olarak yapılır. Split seed’i 42 olarak sabitlenir. Train, validation ve test subject kümelerinin kesişimi boş olmalıdır. Test seti yalnız final raporlama için kullanılır; hyperparameter, checkpoint veya metrik tasarımı test sonucuna göre değiştirilmez. Bu kural ihlal edilseydi final test metrikleri gerçek held-out kanıt olmaktan çıkar, validasyonun uzantısı haline gelirdi.

VI. MDP FORMÜLASYONU

Problem sonlu ufuklu bir Markov karar süreci olarak modellenir:

$$M = (S, A, P, R, \gamma). \quad (1)$$

Burada S hasta durum uzayını, A ayrık tedavi aksiyonlarını, P geçiş dinamiklerini, R ödül fonksiyonunu ve γ discount factor’ü temsil eder. Her geçiş şu biçimdedir:

$$(s_t, a_t, r_t, s_{t+1}, done_t). \quad (2)$$

A. State Temsili

State vektörü hastanın o andaki klinik durumunu özetleyen 62 sürekli/ikili özellikten oluşur. Başlıca gruplar kalp hızı, MAP, sistolik/diyastolik tansiyon, solunum ve SpO2 gibi vital bulgular; kan gazı, elektrolit, renal, hepatik, koagülasyon ve hemogram laboratuvarları; kümülatif sıvı, vazopresör maruziyeti ve idrar çıkışı gibi tedavi sinyalleri; yaş ve cinsiyet

Tablo I
PROJENİN ON AŞAMALI UÇTAN UCA MIMARISI.

Adım	Bileşen	İçerik
1	Kohort seçimi	MIMIC-IV içinden Sepsis-3 kriterlerine uyan yetişkin ICU hastalarının seçilmesi; geçersiz onset, kısa ICU kalışı, eksik temel demografi ve tekrar yatışların yönetilmesi.
2	Zaman çizelgesi	Sepsis onset'inden 24 saat önce başlayıp 48 saat sonrasına uzanan 72 saatlik pencerenin 4 saatlik karar adımlarına bölünmesi.
3	Zero-leakage split	Hastaların train/validation/test olarak hasta-düzeyinde ayrılması ve preprocessing fit işlemlerinin yalnız train üzerinde yapılması.
4	State çıkarımı	Vital, laboratuvar, tedavi geçmişi, demografi, missingness ve türetilmiş değişkenlerden 62 boyutlu durum vektörü üretilmesi.
5	Action/reward	Vazopresör ve IV sıvı dozlarının 25 ayrıklı aksiyona dönüştürülmesi; sparse ve SOFA-shaped ödüllerin üretilmesi.
6	Transition/baseline	Replay verisinin $(s_t, a_t, r_t, s_{t+1}, done_t)$ formatında yazılması; clinician, no-treatment ve behavior cloning baselinelerinin kurulması.
7-8	IQL eğitimi	Offline veride destek dışına çıkmadan expectile value learning ve advantage-weighted actor update ile IQL politikalarının eğitilmesi.
9	OPE ve güvenlik	FQE, WIS, ESS, bootstrap CI, destek kütesi, clinician agreement, heatmap ve güvenlik diagnostiklerinin hesaplanması.
10	Final sweep	18 konfigürasyonlu IQL taraması, finalist seçimi, çoklu tohum doğrulaması ve IEEE rapor artifactlerinin üretilmesi.

gibi demografik değişkenler; PaO2/FiO2, shock index ve onset sonrası saat gibi türetilmiş değişkenlerdir.

Her 4 saatlik pencerede birden fazla ölçüm varsa özelliğe göre 'last', 'mean', 'min', 'max', 'sum' veya 'cumulative' agregasyon kuralı uygulanır. Örneğin bazı vital bulgularda son ölçüm klinik karar anına daha yakın bilgi taşıırken, toplam sıvı veya kümülatif vazopresör maruziyeti pencere içi tedavi yükünü temsil eder. Tek bir agregasyon kuralı tüm değişkenlere dayatılsaydı klinik anlamı farklı sinyaller aynı istatistiksel kalıba sıkıştırılmış olurdu.

Eksik veriler için sıralı strateji uygulanır: episode içinde forward-fill, train split üzerinden hesaplanan medyan, klinik normal değer fallback ve gerekli durumda missingness flag. Missingness göstergeleri eklenmeseydi model, ölçülmeyen laboratuvarı normal değerle karıştırabilir ve hekimin ölçüm kararıyla taşınan risk bilgisini kaybedebilirdi. Train-only medyan kullanılsaydı validation/test dağılım bilgisi preprocessing üzerinden eğitime sızardı.

B. Action Uzayı

Aksiyon uzayı 25 ayrıklı tedavi kararından oluşur. Her aksiyon, vazopresör dozu ve IV sıvı miktarının 5×5 kombinasyonudur:

$$action_id = vaso_bin \times 5 + fluid_bin. \quad (3)$$

Bin 0 tedavi yok anlamına gelir; non-zero dozlar train split üzerindeki çeyrekliklere göre Q1-Q4 olarak ayrılır. Zero dose ayrı tutulur, çünkü hiç tedavi vermemek küçük ama non-zero tedaviyle aynı klinik anlamı taşımaz. Bin eşikleri yalnız train split üzerinde öğrenilir ve validation/test üzerinde dondurulmuş şekilde uygulanır. Eşikler tüm veri üzerinde hesaplınsaydı test doz dağılımı aksiyon kodlamasına sızardı.

C. Reward Tasarımı

İki ödül varyantı kullanılır. Sparse ödül yalnız terminal mortalite/sağkalım utility'sini kullanır: 90 gün yaşayan hasta

Tablo II
VAZOPRESÖR VE IV SIVI AKSIYON GRID'İ.

Vazo bini	Sıvı bini				
	0	1	2	3	4
0	0	1	2	3	4
1	5	6	7	8	9
2	10	11	12	13	14
3	15	16	17	18	19
4	20	21	22	23	24

için +15, 90 gün içinde ölüm için -15. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir.

SOFA-shaped ödül terminal utility'yi korur ve ara adımlarda SOFA değişimine küçük bir shaping sinyali ekler:

$$sofa_shaping = -0.025 \times (SOFA_{current} - SOFA_{previous}). \quad (4)$$

SOFA artışı kötüleşme olarak negatif, SOFA azalması iyileşme olarak pozitif sinyal üretir. SOFA'nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara sinyali klinik olarak gerekçelendirir [8]. SOFA shaping kullanılsaydı eğitim yalnız terminal sonuca dayanacak ve ara fizyolojik iyileşmeleri ayırt etmek zorlaşacaktı. Tersine, shaping ağırlığı çok güçlü seçilseydi ajan mortalite yerine kısa vadeli skor oynamalarını optimize edebilirdi; bu nedenle terminal utility korunmuş ve seçim ortak terminal değerlendirmeye bağlanmıştır.

D. Discount Factor

Discount factor $\gamma = 0.99$ olarak sabitlenir. Bu seçim, sepsis tedavisinde kısa vadeli hemodinamik kararların uzun vadeli mortalite sonucuya ilişkili olması nedeniyle uygundur. Daha küçük bir γ kısa vadeli SOFA değişimlerini fazla önerebilir, $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE

Tablo III
PRESWEEP DENETİM ÖZETİ.

Kanıt kalemi	Train	Validation	Test
Split manifest satırı	12063	2585	2585
SOFA-shaped replay satırı	140635	30539	30046
Sparse replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage taraması		Başarılı	

ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilirdi.

VII. PREPROCESSING VE LEAKAGE-FREE SÖZLEŞMELER

Temel kural ‘fit on train, transform everywhere’ şeklindedir. Scaler parametreleri, imputer medyanları, clip bound veya percentile eşikleri, action bin quartile eşikleri, behavior policy estimator, FQE estimator ve normalization sabitleri train üzerinde fit edilir. Validation ve test üzerinde yalnız train’de fit edilmiş transformlar uygulanır.

Fizyolojik olarak makul olmayan değerler valid range dışında filtrelenebilir veya clip edilir. Clipping ve normalization parametreleri train split üzerinde fit edilir. Bu tercih yapılmasaydı validation/test dağılımının uç değer bilgisi eğitim öncesi veri dönüşümlerine yansiyabilir ve raporlanan performans fazla iyimser olurdu.

A. Aşama 0 Ön Tarama Denetimi

Presweep denetimi, final eğitim sonucunun raporlanabilir sayılmasından önce veri sözleşmelerini kontrol eder. Bu kapı özellikle sağlıkta RL için gereklidir; çünkü küçük bir split sızıntısı veya outcome leakage, gözlemsel klinik veride gerçek politika kalitesinden çok daha büyük görünen kazançlar üretebilir [5]. Denetim şu maddeleri kapsar: sparse replay üretimi, sparse ve SOFA-shaped replay artifactlerinde aynı patient split/preprocessing/action bin/transition indexing/terminal outcome tanımlarının kullanılması, action binlerinin train-only fit edilmesi, imputation/scaling/clipping/normalization istatistiklerinin train-only olması, validation FQE’nin ortak terminal survival/death reward ile çalışması, temporal alignment kontrolü, splitler arası hasta çıkışması bulunmaması ve mortality/discharge/gelecek outcome bilgisinin state feature’larına sızması.

Bu adım atlanmış olsaydı Aşama 2 sonucu sayısal olarak üretilebilir görünse bile, aynı hastanın farklı splitlere düşmesi veya terminal bilginin özelliklere sızması nedeniyle metodolojik olarak geçersiz hale gelebilirdi.

VIII. BASELINE POLİTİKALARI

Final test karşılaştırması üç referans politika içerir. Clinician replay, replay datasetindeki gözlenen klinisyen aksiyonlarını değerlendirir ve davranış verisinin kendisini referans alır. No-treatment policy, uygun yerlerde no-vasopressor/no-fluid bin’ini seçen basit kontrol politikasıdır. Behavior cloning ise klinisyen aksiyonlarını supervised learning ile taklit eder. Bu

baselineler eklenmeseydi IQL çıktısı yalnız kendi OPE skoru ile raporlanır, davranış politikasına ve basit kontrol stratejilerine göre bağlamı kaybolurdu.

IX. IQL ALGORİTMASI

Implicit Q-Learning, offline RL için geliştirilmiş ve dataset dışındaki aksiyonları doğrudan maksimize ederek extrapolation error üretmekten kaçınan bir algoritmadır [1]. IQL üç bileşen kullanır: critic, value function ve actor. Critic $Q_\theta(s, a)$ state-action değerini tahmin eder. Value function klasik max operator yerine expectile regression ile öğrenilir. Expectile parametresi value hedefinin Q dağılımının hangi bölgesine yaklaşacağını belirler; daha düşük expectile daha konservatif, daha yüksek expectile daha optimistic value tahmini üretir.

Value objective asimetrik expectile kaybı ile yazılır:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim D} [L_2^\tau(Q_\theta(s, a) - V_\psi(s))], \quad (5)$$

$$L_2^\tau(u) = |\tau - \mathbb{I}(u < 0)|u^2. \quad (6)$$

τ 1’e yaklaştıkça value fonksiyonu davranış verisi içinde daha iyi görünen aksiyonların üst expectile’ına yaklaşır. Q fonksiyonu ise veri dışı aksiyon maksimumu yerine öğrenilen state value hedefiyle güncellenir:

$$L_Q(\theta) = \mathbb{E}_D [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (7)$$

Actor, dataset içindeki aksiyonları advantage’a göre ağırlıklandırarak öğrenir:

$$A(s, a) = Q_\theta(s, a) - V_\psi(s), \quad (8)$$

$$L_\pi(\phi) = \mathbb{E}_D [\exp(\beta A(s, a)) \log \pi_\phi(a|s)]. \quad (9)$$

Burada β ya da temperature politika çıkarımının agresifliğini kontrol eder. Düşük temperature davranış politikasına daha yakın ve konservatif politika çıkarır; yüksek temperature potansiyel getiriyi artırabilir fakat düşük destekli aksiyonlara kayma riskini de büyütür. Bu nedenle safe, baseline ve optimistic ayarları birlikte denenmiştir.

X. IQL FINAL TARAMA TASARIMI

Final tarama iki ödül varyantı, üç learning-rate rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Learning-rate rejimleri actor, critic ve value optimizasyonunu ayrı olarak kontrol eder. Konservatif learning-rate rejimi finalde öne çıkarılmıştır; çünkü offline RL’de agresif critic güncellemeleri veri dışı Q tahminlerini büyütebilir ve politika çıkarımı bu hataları çoğaltabilir [1], [2]. Baseline rejim yalnızca referans anchor olarak tutulmuştur; hiç denenmeseydi konservatif seçimin gerçekten gerekli olup olmadığı gözlenemezdi. Actor-konservatif rejim ise politika güncellemelerini yavaşlatmanın, critic/value öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.

Sabit parametreler korunmuştur; böylece final sweep yalnız reward, learning-rate rejimi, expectile ve temperature etkisini ölçer. Bu parametreler de serbest bırakılsaydı 18 konfigürasyonun etkisi yorumlanamaz, model başarısının mimari mi yoksa reward/LR/IQL ayarı kaynaklı mı olduğu belirsizleşirdi.

Tablo IV
FINAL IQL HIPERPARAMETRE GRID'İ.

Boyut	Seenek	Deęerler
Reward	sparse	terminal survival/death utility
Reward	SOFA-shaped	terminal utility + SOFA deęişim shaping
LR rejimi	conservative	actor 3×10^{-5} , critic 1×10^{-4} , value 1×10^{-4}
LR rejimi	baseline	actor 1×10^{-4} , critic 3×10^{-4} , value 3×10^{-4}
LR rejimi	actor-conservative	actor 3×10^{-5} , critic 3×10^{-4} , value 3×10^{-4}
IQL ayarı	safe	expectile 0.7, temperature 1.0
IQL ayarı	baseline	expectile 0.7, temperature 3.0
IQL ayarı	optimistic	expectile 0.8, temperature 3.0

Tablo V
SABİT EęİTİM PARAMETRELERİ.

Parametre	Deęer
Algoritma	IQL
Epoch	200
Batch size	256
Discount	0.99
Policy hidden sizes	[256, 256]
Value hidden sizes	[256, 256]
Critic hidden sizes	[256, 256]
Polyak tau	0.005
Target update freq	10
Grad clip	10.0
Device	auto

Algorithm 1 Final IQL Tarama ve Raporlama İş Akışı

- 1: Replay, split, preprocessing ve zamansal sözleşmeleri doğ-
rula
- 2: Ödöl, learning-rate ve IQL ayarlarını genişlet
- 3: **for** her Aşama 1 adayı **do**
- 4: Seed 42 ile politikayı eęit
- 5: Validasyon metriklerini ve destek diagnostiklerini he-
sapla
- 6: **end for**
- 7: Güvenlik veya destek kapılarını geçemeyen adayları işa-
retle
- 8: Composite, ödöl dengesi, güvenlik ve çeşitlilik slotlarıyla
finalist seç
- 9: **for** her finalist ve her doğrulama tohumu **do**
- 10: Seed 123 ve 456 ile politikayı eęit veya yeniden kullan
- 11: Çoklu tohum deęerlendirme kanıtını topla
- 12: **end for**
- 13: Tekrarlanan tohum kanıtıyla final konfigürasyonu seç
- 14: Baseline karşılaştırmaları, grafikler ve yeniden üretilebi-
lirlik artifactleri üret

XI. SEED STRATEJİSİ VE KARAR KURALI

Final rapor için tek seed yeterli deęildir. Offline RL eęiti-
minde initialization, minibatch sırası ve stochastic optimizasyon sonucu etkileyebilir. Aşama 1'de 18 konfigürasyon seed 42 ile taranır. Hesaplama verimli olsun diye tüm $2 \times 3 \times 3 \times 3 = 54$ run doğrudan çalıştırılmamış, önce tek seed tarama yapılmış, ardından umut vadeden finalistler ek seedlerle doğrulanmıştır. Compute kısıtlı durumda önerilen tasarım $18 + (6 \times 2)$

= 30 run'dır. Bu tasarım 54 run'lık tam grid'e göre daha ekonomiktir; yine de finalist konfigürasyonlar üç seed ile doğrulandığı için final raporda seed varyansı ve stabilite analizi raporlanabilir.

Hyperparameter seçimi test set üzerinden yapılmaz. Seçim validation split üzerindeki FQE, WIS, ESS, clinician agreement, action distribution makullüğü, low-support action uyarıları, reward curve ve training stability sinyallerine dayanır. Tek bir metrikle karar verilmez. Örneğin yüksek WIS ama çok düşük ESS varsa bu sonuç güvenilir kabul edilmez.

Bir konfigürasyon final aday olmadan önce validation performansı rekabetçi olmalı, ESS çok düşük olmamalı, FQE sonucu WIS ile tamamen çelişmemeli, action distribution klinik olarak makul olmalı, low-support action oranı kabul edilebilir düzeyde olmalı, farklı seedlerde performans tamamen kararsız olmamalı ve test set seçim sürecinde kullanılmamış olmalıdır.

XII. AŞAMA 1 FINALIST SEÇİM SONUÇLARI

Aşama 1 seçici altı finalist üretmiştir. En yüksek iki aday SOFA-shaped ödöl ve konservatif learning-rate kullanırken, diğer slotlar sparse ödöl temsili, güvenlik-destek dengesini, baseline anchor seçimini ve çeşitlilik backfill kuralını korur. Tablo VI, seçilen adayları ve ana validasyon diagnostiklerini gösterir.


Seçilen küme, protokolün tek skorlu sıralama yerine çok kriterli ve çeşitlilik koruyan seçim hedefiyle uyumludur. Klinik offline öğrenmede bu önemlidir; çünkü yüksek value tahmini, zayıf davranış desteęi veya aşırı dağılım kayması durumunda güvenilir olmayabilir [5]. Eęer yalnız en yüksek FQE veya WIS deęerine göre seçim yapılsaydı, düşük ESS ya da düşük clinician agreement taşıyan bir politika final rapora girebilirdi. Çeşitlilik slotları korunmasaydı ise Aşama 2 yalnız birbirine çok benzeyen SOFA-konservatif adayları tekrarlar, sparse ödölün ve baseline ayarların başarısızlık/başarı sınırları raporlanamazdı.

XIII. AŞAMA 2 VE BASELINE DEęERLENDİRMESİ


Aşama 2, altı finalist ve üç tohumdan oluşan on sekiz satırlık bir tekrarlı-tohum özeti üretmiştir. Her finalist için seed 42, 123 ve 456 checkpointleri test replay üzerinde yeniden deęerlendirilmiştir. Tek tohumlu seçim yapılmış olsaydı rastgele başlatma, minibatch sırası veya erken eęitim dalgalanması final politika kararını belirleyebilirdi. Üç tohum, hesaplama maliyetini sınırlı tutarken bu varyansı görünür yapar; daha

Tablo VI
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.

Sıra	Slot	Ödül	LR	IQL	FQE	WIS	Destek	Uyum
1	top composite	SOFA	konservatif	safe	3.169	8.616	0.965	0.418
2	top composite	SOFA	konservatif	baseline	2.280	7.009	0.973	0.401
3	best sparse	sparse	konservatif	safe	1.954	8.740	0.971	0.411
4	safety support	sparse	baseline	baseline	1.421	6.768	0.973	0.410
5	baseline anchor	sparse	baseline	safe	2.345	8.125	0.963	0.416
6	diversity backfill	sparse	konservatif	baseline	2.012	7.782	0.969	0.407



Şekil 1. Validasyon value tahmini ile davranış desteği diagnostiklerinin birlikte gösterimi. Yüksek value yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.



Şekil 2. Final seçili IQL politikası ve referans baseline gösterimi. Seçili IQL değeri gerçek Aşama 2 değerlendirmesinden, referans baseline çubukları ise rapor artifactinde kullanılan karşılaştırma gösteriminden gelir.


fazla tohum istatistiksel güveni artırır, fakat final tarama maliyetini doğrusal olarak büyütürdü.

Final skor; FQE, WIS, ESS, destek kütlesi, klinisyen uyumu, low-support cezası ve güvenlik bayraklarını birleştiren tekrarlı-tohum ortalamasına dayanır. FQE model tabanlı değer tahmini sağlarken WIS davranış politikasına göre ağırlıklandırılmış gözlemsel kanıt verir; ikisinin birlikte kullanılması tek estimatorün yanlışlık-varyans profilini tek başına final kararına dönüştürmek içindir [5]. ESS ve destek kütlesi eklenmeseydi yüksek WIS değeri, birkaç yüksek ağırlıklı trajectory tarafından taşınsa bile güvenilir görünürdü. Klinisyen uyumu eklenmeseydi politika davranış verisinden çok uzaklaşabilir, bu da offline değerlendirme desteğini azaltabilirdi. Bu kurala göre final seçili konfigürasyon SOFA-shaped, konservatif learning-rate ve safe IQL ayarına sahip 'iql_sofa_shaped_conservative_safe' modelidir.

XIV. AKSIYON VE GÜVENLİK DIAGNOSTİKLERİ

Aksiyon dağılımı diagnostikleri zorunludur; çünkü öğrenilen klinik politika iyi value tahminleri üretirken observational veride nadir veya desteklenmeyen aksiyonlara kayabilir. Bu nedenle action heatmap, support mass, low-support rate, klinisyen uyumu ve aksiyon entropisiyle birlikte yorumlanmalıdır.

Klinik yorum için politika sürekli aşırı sıvı veya aşırı vazopresör öneriyor mu, 'no treatment' aksiyonuna anormal



Şekil 3. Aşama 2 finalistleri için tekrarlı-tohum FQE değişkenliği. Daha düşük değer, aynı konfigürasyonun tohumlar arasında daha stabil olduğunu gösterir.


şekilde collapse ediyor mu, düşük davranış desteği olan aksiyonları sık seçiyor mu, yüksek riskli alt gruplarda güvenlik uyarıları artıyor mu ve reward variant değişince politika dramatik şekilde değişiyor mu soruları kontrol edilmelidir. Protokolde ayrıca clinician action distribution, IQL policy action distribution, difference heatmap, low-support action rate, clinician agreement by subgroup, high-risk subgroup policy action frequency, training loss curves, validation metric curves, reward variant boxplot, LR regime comparison ve expectile/temperature comparison grafikleri raporlanabilir

Tablo VII
AŞAMA 2 ÜÇ-TOHUM FINALIST DEĞERLENDİRMESİ. SKOR, FQE/WIS/ESS/DESTEK/UYUM VE LOW-SUPPORT BİLEŞİK SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	Destek	Uyum
1	SOFA konservatif safe	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif baseline	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif safe	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif baseline	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline safe	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline baseline	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo VIII
KAZANAN KONFIGÜRASYONUN TEST DIAGNOSTİKLERİ. WIS GÜVEN ARALIĞI 50 HASTA-DÜZEYİ BOOTSTRAP RESAMPLE İLE HESAPLANMIŞTIR.


Metrik	Sonuç
FQE	2.848
WIS	8.203
WIS 95% CI	4.963–10.817
ESS	29.410
Davranışsal destek kütlesi	0.991
Klinisyen tam-kutu uyumu	0.414
Klinisyen uyumsuzluğu	0.586
Desteklenmeyen aksiyon sapması	0.009



Şekil 4. Final politika analizi için üretilmiş aksiyon dağılımı heatmap'i. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.

artifactler olarak tanımlanmıştır.

Aşama 2 finalistlerinde destek kütlesi yaklaşık 0.990–0.991, klinisyen exact-bin uyumu ise yaklaşık 0.401–0.418 aralığındadır. Kazanan politikanın tam-kutu uyumu 0.414 olduğu için kararların 0.586'lık kısmı klinisyen davranışıyla birebir aynı değildir; ancak desteklenmeyen aksiyon sapmasının 0.009 düzeyinde kalması, bu sapmaların büyük bölümünün veri desteği bulunan komşu tedavi yörüngeleri içinde gerçekleştiğini gösterir. Bu ayrım klinik olarak önemlidir: politika klinisyeni kopyalayamaz, fakat davranış verisinin tamamen dışına da sığmaz. Buna karşın ESS değerleri tüm finalistlerde 50 eşliğinin



Şekil 5. Final seçili IQL politikasının üç tohum için hasta-düzeği bootstrap WIS güven aralıkları. Güven aralıkları 50 bootstrap resample ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.

altındadır; bu nedenle WIS tabanlı sıralama yüksek varyans riskiyle birlikte raporlanmalıdır. ESS uyarısı saklansaydı rapor, gözlemsel veride yalnız az sayıda etkili trajectory ile desteklenen bir tahmini kesin sonuç gibi sunma riski taşırdı. Bu yüzden final karar “klinik üstünlük” değil, destek kısıtı belirtilmiş retrospektif OPE sonucu olarak ifade edilmiştir.

XV. YENİDEN ÜRETİLEBİLİRLİK VE TEKNOLOJİ YİĞİNİ

Tamamlanan iş akışı, protokol incelemesinde belirlenen ana eksikleri karşılar: final IQL sweep runner, on sekiz konfigürasyonlu grid, workflow seviyesinde orkestrasyon, presweep audit, final-altı seçim mantığı, tekrarlı-tohum Aşama 2 birleştirilmesi, baseline karşılaştırma artifactleri ve final grafik raporları. Üretilen artifact seti presweep audit sonucunu, Aşama 1 seçim tablosunu, Aşama 2 seed özetini, final metrics bundle'ı, baseline karşılaştırmasını ve beş grafik çıktısını içerir. Güncel Aşama 2 değerlendirme sonuçlarında on sekiz finalist-tohum satırı olarak saklanmıştır.

Teknoloji yığını Python ve ‘uv’ tabanlı ortam yönetimi, yüksek hızlı ‘Polars’ ve ‘PyArrow’ tabanlı Parquet veri dönüşümü, ‘PyTorch’ ve özelleştirilmiş ‘d3rlpy’ tabanlı RL eğitimi, ‘Hydra’ konfigürasyon yönetimi, ‘MLflow’ deney takibi ve IEEE LaTeX raporlamasından oluşur. Device-agnostic tasarım sayesinde eğitim kodu MPS, CUDA veya otomatik cihaz seçimiyle çalışabilir. Bu altyapı ayrıştırılmasaydı deney sonuçları belirli bir donanıma veya elle değiştirilmiş konfigürasyonlara bağımlı hale gelirdi.

Her run için git commit hash, config dosyası, reward variant, LR regime, expectile, temperature, seed, dataset path, metadata

path, split manifest seed, action bin artifact, training logs, checkpoint path, evaluation output ve figure paths kaydedilmedir. Run isimlendirme şablonu reward, LR rejimi, IQL ayarı ve seed bilgisini birlikte taşıyan ‘iql_reward_lr_setting_seed’ biçimindedir. Örneğin SOFA-shaped, actor-conservative, baseline ve seed 42 bilgileri aynı run adında saklanır. Bu sözleşme tutulmasaydı sonradan hangi checkpointın hangi veri ve konfigürasyonla üretildiği izlenemezdi.

XVI. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve observational niteliktedir. Öğrenilen politika yatak başı tedavi önerisi olarak yorumlanmamalıdır. Durum temsili gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen confounding etkilerini tam olarak kapsayamaz. Gerçek klinik süreç POMDP niteliği taşır; eldeki state vektörü hekimin tüm yatak başı bilgisini içermez. Clinician action’ları observational olduğu için confounding içerir; örneğin daha hasta kişilere daha agresif vazopresör verilmesi, tedavinin zararlı görünmesine veya yanlış fayda atfedilmesine neden olabilir.

MIMIC-IV verisi PhysioNet credentialing, CITI training ve Data Use Agreement kapsamındaki yükümlülüklerle tabidir; hasta verileri de-identified olsa da raporlama akademik ve etik sınırlar içinde kalmalıdır. FQE ve WIS prospektif klinik kanıt değildir; fonksiyon yaklaşımı, behavior policy tahmini, destek varsayımları ve variance profiline bağlıdır. ESS değerinin 50 eşliğinin altında kalması ve bootstrap resample sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.

XVII. GELECEK ARAŞTIRMA YÖNLERİ

Referans araştırma taslakları, bu çalışmanın güvenli IQL hattını daha ileri offline RL fikirleriyle genişletmek için üç somut yön göstermektedir. İlk yön, statik expectile yerine epistemic uncertainty ve yerel veri yoğunluğuna göre değişen dinamik expectile kalibrasyonudur. Yoğun destekli bölgelerde τ yükseltilerek daha agresif politika iyileştirme yapılabilir; seyrek ve belirsiz bölgelerde τ 0.5’e yaklaştırılarak davranış klonlamasına benzer güvenli güncelleme tercih edilebilir.

İkinci yön, sparse terminal mortalite sinyali daha hızlı yaymak için adaptive multi-step trace blending kullanmaktır. Peng’in $Q(\lambda)$ fikri, yüksek güvenli trajectory bölümlerinde daha büyük λ , belirsiz veya düşük destekli geçişlerde daha küçük λ kullanacak şekilde klinik veriye uyarlanabilir. Üçüncü yön, state-space manifold regularization için generative world-model veya diffusion tabanlı trajectory simülatörleridir. Böyle bir model, klinik olarak gerçekçi ama veri setinde seyrek görülen sınır durumları sentezleyerek value fonksiyonuna daha güvenli marjlar öğretebilir. Bu üç genişleme, mevcut raporun temel ilkesini korumalıdır: önce veri desteği ve leakage-free değerlendirme, sonra politika iyileştirmesi.

XVIII. SONUÇ

Geliştirilen IQL final tarama iş akışı, protokol düzeyindeki deney tasarımı sepsis tedavi politikası değerlendirme için yeniden üretilebilir bir offline pekiştirmeli öğ-

renme pipeline’ına dönüştürür. Rapor artık kohort seçimin-den zaman penceresine, state/action/reward mühendisliğinden leakage-free preprocessing sözleşmelerine, IQL algoritma ayarlarından hiperparametre grid’ine, Aşama 1 finalist seçimi ve Aşama 2 çoklu-tohum değerlendirmesine kadar projenin bütün ana adımlarını içerir. Aşama 0 denetimi başarılıdır ve Aşama 1 altı çeşitli, destek-duyarlı finalist belirlemiştir. Güncel Aşama 2 sonucuna göre final konfigürasyon ‘iql_sofa_shaped_conservative_safe’ olarak seçilmiştir. Bu model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 ile final konfigürasyon olarak raporlanmıştır; ancak ESS=29.41 ile destek eşliğinin altındadır. Bu nedenle sonuç klinik değil metodolojik ve retrospektif OPE kanıtı olarak raporlanmalıdır.

KAYNAKLAR

- [1] I. Kostrikov, A. Nair, and S. Levine, “Offline reinforcement learning with implicit q-learning,” in *International Conference on Learning Representations*, 2022.
- [2] A. Kumar, A. Zhou, G. Tucker, and S. Levine, “Conservative q-learning for offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, 2020.
- [3] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, “The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care,” *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [4] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, “Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach,” in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [5] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, “Guidelines for reinforcement learning in healthcare,” *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [6] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, “Mimic-iv, a freely accessible electronic health record dataset,” *Scientific Data*, vol. 10, no. 1, p. 1, 2023.
- [7] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, “Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021,” *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.
- [8] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Annane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, “The third international consensus definitions for sepsis and septic shock (sepsis-3),” *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.