

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Offline Reinforcement Learning İş Akışı

Furkan Nezir Üzmez
230202073

Özet—Bu çalışma, MIMIC-IV veri seti üzerinde sepsis dozaj politikalarının yeniden üretilebilir biçimde değerlendirilmesi için orkestre edilmiş bir Offline Reinforcement Learning (çevrimdışı pekiştirmeli öğrenme) iş akışı sunmaktadır. Temel risk, modelin tarihsel veride zayıf temsil edilen sıvı-vazopresör kombinasyonlarını güvenilir sanmasıdır. Bu nedenle iş akışı; Sepsis-3 kohort seçimini, 72 saatlik klinik pencereyi, 62 boyutlu durum vektörünü, 5×5 ayrık aksiyon uzayını, seyrek ödül ve SOFA-biçimli ödül tasarımlarını, yalnız eğitim verisine dayalı ön işleme, hasta düzeyi bölme, Implicit Q-Learning (IQL) hiperparametre taramasını, çok kriterli finalist seçimini ve multi-seed doğrulamasını aynı protokol içinde tutar. Aşama 1’de iki ödül, üç öğrenme oranı (learning rate) rejimi ve üç expectile-temperature ayarından oluşan 18 konfigürasyon değerlendirilir; Aşama 2’de altı finalist üç seed ile yeniden ölçülür. Final aday, SOFA-biçimli ödül, konservatif öğrenme oranı ve güvenli IQL ayarına sahip final modeldir. Üç seed ortalamasında FQE = 2.848, WIS = 8.203, bootstrap WIS 95% CI = 4.963–10.817, ESS = 29.410, behavior support mass = 0.991 ve clinician exact-bin agreement = 0.414 elde edilmiştir. ESS değeri 50 eşişinin altında kaldığı için bu sonuç klinik üstünlük iddiası değil, destek sınırı açıkça belirtilmiş retrospektif OPE kanıtıdır.

Index Terms—Offline Reinforcement Learning, Implicit Q-Learning (IQL), sepsis, MIMIC-IV, OPE, yeniden üretilebilirlik, klinik karar desteği

I. GİRİŞ

Sepsis, enfeksiyona karşı gelişen bağışıklık ve fizyolojik yanıtın kontrolsüzleşerek yaşamı tehdit eden organ disfonksiyonuna yol açtığı ciddi bir klinik sendromdur [1]. Basit bir enfeksiyon tablosundan farklı olarak, konak yanıtının kontrolsüzleşmesi hastanın kendi doku ve organlarına zarar verebilir; klinik süreç septik şoka, çoklu organ yetmezliğine ve ölümle sonuçlanabilecek hızlı fizyolojik bozulmaya ilerleyebilir. Küresel Hastalık Yüğü analizine göre 2017 yılında dünya genelinde yaklaşık 48.9 milyon sepsis olgusu ve 11 milyon sepsis ilişkili ölüm bildirilmiştir; bu ölümler tüm küresel ölümlerin yaklaşık beşte birine karşılık gelmektedir [2]. Bu nedenle sepsis, özellikle yoğun bakım ünitesinde sürekli izlem, zamanında müdahale ve ardışık tedavi kararları gerektiren yüksek riskli bir klinik karar problemi olarak ele alınmaktadır.

Yoğun bakımda sepsis resüsitasyonu, hastanın fizyolojik durumuna bağlı olarak kısa zaman aralıklarında değişen sıvı ve vazopresör kararlarını içerir. Aynı hasta birkaç saat içinde farklı doz gereksinimleri gösterebilir; bu kararların etkisi ise çoğu zaman yalnızca anlık ölçümlerde değil, gecikmeli mortalite ve organ disfonksiyonu sonuçlarında gözlenir. Ayrıca daha ağır hastaların daha agresif tedavi alması, gözlemsel

yoğun bakım verilerinde belirgin karıştırıcılık üretir. Bu yapı, problemi yalnızca gözetimli öğrenme ile “doğru doz tahmini” olarak değil, ardışık karar verme ve politika değerlendirme problemi olarak formüle etmeyi gerektirir.

Offline Reinforcement Learning bu bağlamda uygun bir çerçeve sunar; çünkü politika öğrenimi yalnızca geçmiş yoğun bakım yörüngeleri üzerinden yapılır ve hastalar üzerinde çevrimiçi keşif gerektirmez [3]. Ancak bu avantaj aynı zamanda temel güvenilirlik sorununu doğurur: öğrenilen politika, tarihsel veride yeterince temsil edilmeyen sıvı-vazopresör kombinasyonlarına kayarsa, modelin değer tahminleri klinik olarak güvenilir olmayabilir. Bu nedenle FQE, WIS, ESS ve davranış desteği analizleri, bu çalışmada yalnızca yardımcı metrikler değil, politika yorumlanabilirliğinin temel güvenlik koşulları olarak ele alınmaktadır [4].

II. İLGİLİ ÇALIŞMALAR

Sepsis için pekiştirmeli öğrenme literatürü, AI Clinician ve Raghu ve arkadaşlarının çalışmalarıyla önemli ölçüde şekillenmiştir. Bu çalışmalar, yoğun bakım verilerinden tedavi politikası öğrenmenin potansiyelini gösterirken çevrim dışı değerlendirme, davranış politikasından sapma ve klinik güvenlik gereksinimlerini de bu alanın temel tasarım ölçütleri hâline getirmiştir. AI Clinician, yoğun bakım sepsis hastalarında IV sıvı ve vazopresör dozlarını ayrık tedavi binleri olarak modellemiş ve bu iki tedavi ekseninden oluşan ayrık aksiyon uzayı üzerinden politika öğrenimi gerçekleştirmiştir [5]. Bu yaklaşım, sepsis resüsitasyonunun ardışık karar verme problemi olarak modellenebileceğini göstermesi bakımından yol açııcıdır. Raghu ve arkadaşları ise aynı problemi daha sürekli durum temsilleri ve deep reinforcement learning çizgisinde ele alarak, hasta fizyolojisinin kaba ayrık kümelerle zorlanmasının oluşturabileceği bilgi kaybına dikkat çekmiştir [6]. Bu iki çalışma, bu rapordaki 4 saatlik karar adımı, sürekli klinik durum vektörü ve sıvı-vazopresör temelli 5×5 aksiyon grid’i için temel literatür zeminini oluşturur.

Bununla birlikte, sağlıkta RL çalışmaları gözlemsel veri üzerinden öğrenildiği için doğrudan klinik tedavi önerisi olarak yorumlanamaz. Daha ağır hastaların daha agresif tedavi alması confounding by indication riskini doğurur; destek eksikliği modelin az gözlenen aksiyonlarda güvenilmez değer tahmini üretmesine neden olabilir; WIS gibi OPE estimator’ları az sayıda yüksek ağırlıklı yörüngeden etkilenebilir; ayrıca retrospektif doğrulama prospektif klinik etkinlik kanıtı yerine

geçmez [7]. Bu nedenle bu raporun amacı, IQL politikasının klinik olarak üstün olduğunu iddia etmek değil, MIMIC-IV üzerinde sızıntısız veri bölme, davranış desteği analizi, FQE, WIS, ESS ve bootstrap güven aralıkları ile yeniden üretilebilir bir offline evaluation protokolü sunmaktır [4]. Aksiyon eksenlerinin IV sıvı ve vazopresör olarak seçilmesi ise güncel sepsis yönetiminde bu iki müdahalenin hemodinamik resüsitasyonun merkezinde yer almasıyla uyumludur [8].

III. KURAMSAL ARKA PLAN VE ALGORİTMİK KONUMLANDIRMA

Çok adımlı değer yayılımı bu çalışmanın doğrudan deney değişkeni değil, sonraki araştırma eksenidir. Tek adımlı yedeklemeler seyrek terminal mortalite sinyali 18 adımlık yörünge boyunca yavaş taşır; Peng'in $Q(\lambda)$ gibi uygunluk izi yaklaşımları bu gecikmeyi azaltabilir [9]. Bu raporda önce destek güvenliği ve sızıntısız değerlendirme sabitlenmiştir. Multi-step operatör aynı anda değiştirilseydi, final IQL sonucunun reward/LR/expectile seçimi mi yoksa yedekleme operatörü mü nedeniyle değiştiği ayrıştırılamazdı.

IV. UÇTAN UCA PROJE MIMARISI

Proje, katı bağımlılık zinciriyle ilerleyen on ana adımdan oluşur. Bu yapı, veri hazırlama hatalarının final politika değerlendirmesine taşınmasını engellemek için bilinçli olarak aşamalı tasarlanmıştır.

Bu mimari tek bir eğitim betiği olarak değil, veri hazırlama, model eğitimi, değerlendirme ve raporlama katmanlarını birbirine bağlayan deney protokolü olarak ele alınır. Kohort tanımı, veri sözleşmesi, model eğitimi, OPE, güvenlik analizi ve raporlama çıktıları aynı deney protokolüne bağlanır. Bu bağlantı, bölme sızıntısı, farklı ön işleme veya hatalı transition indexing kaynaklı yapay performans artışlarının model başarısı olarak yorumlanmasını engeller.

V. KOHORT, ZAMAN VE SPLIT TASARIMI

A. Kohort Seçimi

Kohort MIMIC-IV üzerinde Sepsis-3 kriterlerine göre oluşturulur [1], [10]. Dahil edilen popülasyon 18 yaş ve üzeri yetişkin, doğrudan yoğun bakım ünitesi izlemine sahip ve sepsis tanımıyla uyumlu hastalardır. Çocuk hastalar farklı doz ve fizyoloji rejimlerine sahip oldukları için dışarıda bırakılır; bu karar verilmeseydi model tek bir aksiyon-doz anlamını heterojen yaş grupları için öğrenmeye zorlanırdı. Yoğun bakım ünitesi dışı veya yoğun gözlem verisi olmayan hastalar da dışlanır; çünkü 4 saatlik karar pencereleri için yeterli fizyolojik zaman serisi kurulamaz.

Dışlama kuralları, karar penceresinin klinik ve zamansal tutarlılığını korumak amacıyla uygulanır. Sepsis başlangıç zamanı bulunamayan hastalar, 4 saatten kısa yoğun bakım ünitesi kalışı olanlar ve yaş/cinsiyet gibi temel demografisi eksik olanlar çıkarılır. Tekrar yatan hastalarda yalnız ilk yatış kullanılır. Aynı hastanın bir yatışı eğitim setine, sonraki yatışı test setine düşerse model kronik profili dolaylı olarak ezberleyebilir; bu nedenle filtreleme sonucu ve dışlanan hasta sayısı denetim çıktılarında saklanır.

B. Zaman Çizelgesi

Her yoğun bakım ünitesi kalışı için sepsis başlangıç zamanı hesaplanır. Analiz penceresi sepsis başlangıç zamanından 24 saat önce başlayıp 48 saat sonrasına kadar devam eder. Bu 72 saatlik pencere 4 saatlik karar adımlarına ayrıldığında tipik epizot yaklaşık 18 zaman adımı içerir. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger [5], [6]. Daha kısa pencere seçilseydi ölçüm eksikliği ve gürültülü aksiyon tekrarları artacak, davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde tahmin edilecekti. Daha uzun pencere seçilseydi de sıvı ve vazopresör değişimlerinin akut fizyolojik etkileri ortalamaya karışacak, ardışık karar yapısı zayıflayacaktı.

C. Split Stratejisi

Varsayılan split hasta düzeyinde eğitim %70, doğrulama %15 ve test %15 olarak yapılır. Bölme seed'i 42 olarak sabitlenir. Eğitim, doğrulama ve test özne kümelerinin kesişimi boş olmalıdır. Test seti yalnız final raporlama için kullanılır; hiperparametre, kontrol noktası veya metrik tasarımı test sonucuna göre değiştirilmez. Bu kural ihlal edilseydi final test metrikleri gerçek ayrılmış kanıt olmaktan çıkar, doğrulamanın uzantısı haline gelirdi.

VI. MDP FORMÜLASYONU

Sepsis resüsitasyonu ardışık karar yapısına sahip olduğu için her 4 saatlik pencere bir karar adımı olarak ele alınır. Bu kurulumda mevcut klinik durum $state$, sıvı-vazopresör kombinasyonu $action$, sonraki fizyolojik değişim ve terminal sonuç ise $reward$ sinyaliyle ilişkilendirilir. Bu nedenle problem sonlu ufuklu bir Markov karar süreci olarak modellenir [11]:

$$M = (S, A, P, R, \gamma). \quad (1)$$

Burada S hasta durum uzayını, A ayrık tedavi aksiyonlarını, P geçiş dinamiklerini, R ödül fonksiyonunu ve γ iskonto faktörünü temsil eder. Her geçiş şu biçimdedir:

$$(s_t, a_t, r_t, s_{t+1}, done_t). \quad (2)$$

A. Durum Temsili

Durum vektörü hastanın o andaki klinik durumunu özetleyen 62 sürekli/ikili özellikten oluşur. Başlıca gruplar kalp hızı, MAP, sistolik/diyastolik tansiyon, solunum ve SpO2 gibi yaşamsal bulgular; kan gazı, elektrolit, renal, hepatik, koagülasyon ve hemogram laboratuvarları; kümülatif sıvı, vazopresör maruziyeti ve idrar çıkışı gibi tedavi sinyalleri; yaş ve cinsiyet gibi demografik değişkenler; PaO2/FiO2, shock index ve sepsis başlangıcı sonrası saat gibi türetilmiş değişkenlerdir.

Her 4 saatlik pencerede birden fazla ölçüm varsa özelliğe göre 'last', 'mean', 'min', 'max', 'sum' veya 'cumulative' agregasyon kuralı uygulanır. Örneğin bazı yaşamsal bulgularda son ölçüm klinik karar anına daha yakın bilgi taşıırken, toplam sıvı veya kümülatif vazopresör maruziyeti pencere içi tedavi yükünü temsil eder. Tek bir agregasyon kuralı tüm değişkenlere dayatılsaydı klinik anlamı farklı sinyaller aynı istatistiksel kalıba sıkıştırılmış olurdu.

Tablo I
PROJENİN ON AŞAMALI UÇTAN UCA MIMARISI.

Adım	Bileşen	İçerik
1	Kohort seçimi	MIMIC-IV içinden Sepsis-3 kriterlerine uyan yetişkin yoğun bakım ünitesi hastalarının seçilmesi; geçersiz sepsis başlangıç zamanı, kısa yoğun bakım ünitesi kalışı, eksik temel demografi ve tekrar yatışların yönetilmesi.
2	Zaman çizelgesi	Sepsis başlangıç zamanından 24 saat önce başlayıp 48 saat sonrasına uzanan 72 saatlik pencerenin 4 saatlik karar adımlarına bölünmesi.
3	Sıfır sızıntı bölme	Hastaların eğitim/doğrulama/test olarak hasta-düzeyinde ayrılması ve ön işleme uyarlama işlemlerinin yalnız eğitim verisi üzerinde yapılması.
4	Durum çıkarımı	Yaşamsal bulgu, laboratuvar, tedavi geçmişi, demografi, eksiklik ve türetilmiş değişkenlerden 62 boyutlu durum vektörü üretilmesi.
5	Aksiyon/ödül	Vazopresör ve IV sıvı dozlarının 25 ayrık aksiyona dönüştürülmesi; seyrek ve SOFA-biçimli ödüllerin üretilmesi.
6	Geçiş/baseline	replay dataset'in $(s_t, a_t, r_t, s_{t+1}, done_t)$ formatında oluşturulması; clinician replay, no-treatment ve Behavior Cloning (BC) baselines kurulması.
7-8	IQL eğitimi	Offline data üzerinde destek dışına çıkmadan expectile değer öğrenimi ve avantaj ağırlıklı aktör güncellemesi ile IQL politikalarının eğitilmesi.
9	OPE ve güvenlik	FQE, WIS, ESS, bootstrap CI, behavior support mass, clinician agreement, heatmap ve safety diagnostics hesaplanması.
10	Nihai deney taraması	18 konfigürasyonlu IQL hiperparametre taraması, finalist seçimi ve multi-seed doğrulaması.

Tablo II
VAZOPRESÖR VE IV SIVI AKSIYON GRID'İ.

Vasopressor bin	Fluid bin				
	0	1	2	3	4
0	0	1	2	3	4
1	5	6	7	8	9
2	10	11	12	13	14
3	15	16	17	18	19
4	20	21	22	23	24

Eksik veriler için sıralı strateji uygulanır: epizot içinde forward-fill, eğitim bölmesi üzerinden hesaplanan medyan, klinik normal değer fallback ve gerekli durumda eksiklik göstergesi. Missingness göstergeleri eklenmeseydi model, ölçülme laboratuvarı normal değerle karıştırılabilir ve hekimin ölçüm kararıyla taşınan risk bilgisini kaybedebilirdi. Yalnız eğitim medyanı kullanılsaydı doğrulama/test dağılım bilgisi ön işleme üzerinden eğitime sızardı.

B. Aksiyon Uzayı

Aksiyon uzayı 25 ayrık tedavi kararından oluşur. Her aksiyon, vazopresör dozu ve IV sıvı miktarının 5×5 kombinasyonudur:

$$action_id = vaso_bin \times 5 + fluid_bin. \quad (3)$$

Bin 0 tedavi yok anlamına gelir; sıfır dışı dozlar eğitim bölmesi üzerindeki çeyrekliklere göre Q1–Q4 olarak ayrılır. Sıfır doz ayrı tutulur, çünkü hiç tedavi vermemek küçük ama sıfır dışı tedaviyle aynı klinik anlamı taşımaz. Bin eşikleri yalnız eğitim bölmesi üzerinde öğrenilir ve doğrulama/test üzerinde dondurulmuş şekilde uygulanır. Eşikler tüm veri üzerinde hesaplınsaydı test doz dağılımı aksiyon kodlamasına sızardı.

C. Ödül Tasarımı

İki ödül varyantı kullanılır. Seyrek ödül yalnız terminal mortalite/sağkalım fayda değerini kullanır: 90 gün yaşayan hasta

için +15, 90 gün içinde ölüm için −15. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir.

SOFA-biçimli ödül terminal faydayı korur ve ara adımlarda SOFA değişimine küçük bir şekillendirme sinyali ekler:

$$sofa_shaping = -0.025 \times (SOFA_{current} - SOFA_{previous}). \quad (4)$$

SOFA artışı kötüleşme olarak negatif, SOFA azalması iyileşme olarak pozitif sinyal üretir. SOFA'nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara sinyali klinik olarak gerekçelendirir [1]. SOFA şekillendirmesi kullanılsaydı eğitim yalnız terminal sonuca dayanacak ve ara fizyolojik iyileşmeleri ayırt etmek zorlaşacaktı. Tersine, shaping ağırlığı çok güçlü seçilseydi ajan mortalite yerine kısa vadeli skor oynamalarını optimize edebilirdi; bu nedenle terminal fayda korunmuş ve seçim ortak terminal değerlendirmeye bağlanmıştır.

D. İskonto Faktörü

İskonto faktörü $\gamma = 0.99$ olarak sabitlenir. Bu seçim, sepsis tedavisinde kısa vadeli hemodinamik kararların uzun vadeli mortalite sonucuyla ilişkili olması nedeniyle uygundur. Daha küçük bir γ kısa vadeli SOFA değişimlerini fazla öne çıkarabilir, $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilirdi.

VII. ÖN İŞLEME VE SIZINTISIZ SÖZLEŞMELER

Temel kural 'fit on train, transform everywhere' şeklindedir. Ölçekleyici parametreleri, atayıcı medyanları, kırpma sınırı veya yüzdelik eşikleri, action bin çeyreklik eşikleri, behavior policy estimator, FQE estimator ve normalleştirme sabitleri eğitim verisi üzerinde uydurulur. Doğrulama ve test üzerinde yalnız eğitim verisinde uydurulmuş dönüşümler uygulanır. Bu seçim, sağlık verisindeki sonuç sızıntısı ve tasarım sonrası

Tablo III
ÖN DENETİM ÖZETİ.

Kanıt kalemi	Eğitim	Doğrulama	Test
Split manifest satırı	12063	2585	2585
SOFA replay satırı	140635	30539	30046
Seyrek replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage analizi		Başarılı	

model seçimi risklerine karşı önerilen raporlama ilkeleriyle uyumludur [7], [12].

Fizyolojik olarak makul olmayan değerler geçerli aralık dışında filtrelenebilir veya kırılabilir. Kırılma ve normalleştirme parametreleri eğitim bölmesi üzerinde uydurulur. Bu tercih yapılmıyorsa doğrulama/test dağılımının uç değer bilgisi eğitim öncesi veri dönüşümlerine yansiyabilir ve raporlanan performans fazla iyimser olurdu.

A. Aşama 0 Ön Denetim

Ön denetim, eğitim başlamadan önce veri sözleşmelerini test eder. Sağlıkta RL için bu kapı zorunludur; küçük bir bölme sızıntısı veya sonuç sızıntısı, gözlemsel veride gerçek politika kalitesinden çok daha büyük görünen kazançlar üretebilir [7]. Denetim seyrek replay dataset üretimini, seyrek ve SOFA-biçimli replay dataset dosyalarının aynı split/preprocessing/action bin/transition indexing/terminal outcome tanımlarını kullanmasını, aksiyon binlerinin yalnız eğitim verisi fit edilmesini, atama/ölçekleme/kırılma/normalleştirme istatistiklerinin yalnız eğitim verisi kalmasını, doğrulama FQE'sinin ortak terminal sağkalım/ölüm ödülü ile çalışmasını, zamansal hizalamayı, hasta çakışması bulunmamasını ve mortalite/taburculuk gibi gelecek sonuç bilgisinin durum özelliklerine sızmasını kontrol eder.

Bu denetim kapısı, aynı hastanın farklı bölmelere düşmesi veya terminal bilginin özelliklere sızması gibi klinik yapay zeka çalışmalarında sık görülen geçerlilik ihlallerini deney başlamadan önce sınırlar.

VIII. BASELINE POLİTİKALAR

Final test karşılaştırması üç referans politika içerir. Clinician replay, replay dataset'teki gözlenen klinisyen aksiyonlarını değerlendirir ve davranış verisinin kendisini referans alır. No-treatment politikası, uygun yerlerde vazopresör yok/sıvı yok bin'ini seçen basit kontrol politikasıdır. Behavior Cloning (BC) ise klinisyen aksiyonlarını gözetimli öğrenme ile taklit eder. Bu baselineler, IQL çıktısının davranış politikası ve basit kontrol stratejilerine göre bağlamlandırılmasını sağlar.

IX. IMPLICIT Q-LEARNING (IQL) ALGORİTMASI

Offline Reinforcement Learning, öğrenilen politikanın sabit veri kümesinde gözlenmiş davranış desteği içinde kalmasını amaçlar. Davranış desteği, belirli hasta durumlarında hangi tedavi aksiyonlarının tarihsel klinik veride yeterli sıklıkta

görüldüğünü ifade eder. Destek dışına çıkan politikalar, az gözlenen veya hiç gözlenmeyen sıvı-vazopresör kombinasyonlarına yüksek değer atayabilir; bu da özellikle fonksiyon yaklaşımcı kullanan Q-öğrenme yöntemlerinde ekstrapolasyon hatasına yol açar.

IQL bu riski açık bir aksiyon cezası eklemeyen, in-sample bir öğrenme stratejisiyle azaltmaya çalışır. Klasik Q-learning'in aksine, bir sonraki durumda veri setinde gözlenmemiş aksiyonlar üzerinde doğrudan maksimum almaz. Bunun yerine expectile değer öğrenimiyle veri içindeki yüksek değerli aksiyonları tahmin eder ve avantaj ağırlıklı Behavior Cloning ile aktörü bu aksiyonlara yaklaştırır [13]. Bu nedenle IQL, davranış verisinden tamamen kopmadan politika iyileştirmeyi hedefler; ancak veri dağılımında hiç temsil edilmeyen yeni tedavi stratejilerini keşfedemez.

CQL ise aynı problemi daha kötümser bir düzensileştirme ile ele alır ve low-support action'ların Q değerini cezalandırır [14]. Bu yaklaşım ekstrapolasyon hatasına karşı güçlüdür; fakat yanlış ayarlandığında klinikte nadir ama gerekli müdahaleleri de bastırabilir. Bu nedenle IQL'nin seçimi, agresif kötümserlik ile destek içinde kontrollü politika iyileştirme arasında bilinçli bir metodolojik takas olarak değerlendirilmiştir.

IQL modeli üç parça öğrenir: eleştirmen, değer işlevi ve aktör. Eleştirmen $Q_\theta(s, a)$ durum-aksiyon değerini tahmin eder. Değer işlevi, klasik maksimum operatörü yerine expectile regresyonu ile uydurulur. Expectile düştükçe değer hedefi davranış verisine yaklaşır; expectile yükseldikçe veri içindeki daha yüksek değerli aksiyonlara ağırlık verir.

Değer amacı asimetrik expectile kaybı ile yazılır:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim D} [L_2^T(Q_\theta(s, a) - V_\psi(s))], \quad (5)$$

$$L_2^T(u) = |\tau - \mathbb{I}(u < 0)|u^2. \quad (6)$$

τ 1'e yaklaştıkça değer fonksiyonu davranış verisi içinde daha iyi görünen aksiyonların üst expectile değerine yaklaşır. Q fonksiyonu ise veri dışı aksiyon maksimumu yerine öğrenilen durum-değer hedefiyle güncellenir:

$$L_Q(\theta) = \mathbb{E}_D [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (7)$$

Aktör, veri seti içindeki aksiyonları avantaja göre ağırlıklandırarak öğrenir:

$$A(s, a) = Q_\theta(s, a) - V_\psi(s), \quad (8)$$

$$L_\pi(\phi) = \mathbb{E}_D [\exp(\beta A(s, a)) \log \pi_\phi(a|s)]. \quad (9)$$

Burada β ya da temperature politika çıkarımının agresifliğini kontrol eder. Düşük temperature davranış politikasına daha yakın ve konservatif politika çıkarır; yüksek temperature potansiyel getiriyi artırabilir fakat low-support action'lara kayma riskini de büyütür. Bu nedenle güvenli, referans ve iyimser ayarları birlikte denenmiştir.

X. NİHAİ DENEY TARAMASI

Nihai deney taraması iki ödül varyantı, üç öğrenme oranı rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Öğrenme oranı rejimleri aktör, eleştirmen ve değer optimizasyonunu ayrı olarak kontrol eder. Konservatif öğrenme oranı

Algorithm 1 Nihai deney taraması ve raporlama iş akışı

- 1: Replay dataset, bölme ve ön işleme ve zamansal sözleşmeleri doğrula
- 2: Ödül, öğrenme oranı ve IQL ayarlarını genişlet
- 3: **for** her Aşama 1 adayı **do**
- 4: Seed 42 ile politikayı eğit
- 5: Doğrulama metriklerini ve destek teşhislerini hesapla
- 6: **end for**
- 7: Güvenlik veya destek kapılarını geçemeyen adayları işaretle
- 8: Bileşik skor, ödül dengesi, güvenlik ve çeşitlilik slotlarıyla finalist seç
- 9: **for** her finalist ve her doğrulama seed'i **do**
- 10: Seed 123 ve 456 ile politikayı eğit veya yeniden kullan
- 11: Multi-seed değerlendirme kanıtını topla
- 12: **end for**
- 13: Tekrarlanan seed kanıtıyla final konfigürasyonu seç
- 14: Baseline karşılaştırmaları, grafikler ve yeniden üretilebilirlik çıktıları üret

rejimi finalde öne çıkarılmıştır; çünkü offline RL'de agresif eleştirmen güncellemeleri veri dışı Q tahminlerini büyütebilir ve politika çıkarımı bu hataları çoğaltabilir [13], [14]. Referans rejim yalnızca referans çapa olarak tutulmuştur; hiç denenmeseydi konservatif seçimin gerçekten gerekli olup olmadığı gözlenemezdi. Aktör-konservatif rejim ise politika güncellemelerini yavaşlatmanın, eleştirmen/değer öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.


Sabit parametreler korunmuştur; böylece nihai deney taraması yalnız ödül, öğrenme oranı rejimi, expectile ve temperature etkisini ölçer. Sabit parametreler, 18 konfigürasyonun etkisini ödül, öğrenme oranı ve IQL ayarları üzerinde izole etmeyi sağlar.

XI. SEED STRATEJİSİ VE KARAR KURALI

Tek seed'li değerlendirme, offline RL modellerinde kararlı politika seçimi için yetersiz kanıt üretir. Başlatma, mini-yığın sırası ve stokastik optimizasyon aynı konfigürasyonun FQE/WIS değerini değiştirebilir. Aşama 1'de 18 konfigürasyon seed 42 ile taranır; ardından altı finalist seed 123 ve 456 ile yeniden değerlendirilir. Böylece tüm $2 \times 3 \times 3 \times 3 = 54$ çalıştırma yerine 30 çalıştırma çalıştırılır. Bu tasarım hesaplama maliyetini düşürür, fakat final adayları üç seed üzerinden raporladığı için seed varyansı görünür kalır.

Hiperparametre seçimi test set üzerinden yapılmaz. Seçim doğrulama bölmesi üzerindeki FQE, WIS, ESS, clinician agreement, aksiyon dağılımı makullüğü, low-support action uyarıları, ödül eğrisi ve eğitim kararlılığı sinyallerine dayanır. Tek bir metrikle karar verilmez. Örneğin yüksek WIS ama çok düşük ESS varsa bu sonuç güvenilir kabul edilmez.

Bir konfigürasyon final aday olmadan önce doğrulama performansı rekabetçi olmalı, ESS çok düşük olmamalı, FQE sonucu WIS ile tamamen çelişmemeli, aksiyon dağılımı klinik olarak makul olmalı, low-support action oranı kabul edilebilir



Şekil 1. Doğrulama değer tahmini ile behavior support teşhislerinin birlikte gösterimi. Yüksek değer yalnız yeterli destekle birlikte anlamlı kabul edilebilir.

düzeyde olmalı, farklı seed'lerde performans tamamen kararsız olmamalı ve test set seçim sürecinde kullanılmamış olmalıdır.

XII. AŞAMA 1 FINALIST SEÇİM SONUÇLARI

Aşama 1 seçici altı finalist üretmiştir. En yüksek iki aday SOFA-biçimli ödül ve konservatif öğrenme oranı kullanırken, diğer slotlar seyrek ödül temsili, güvenlik-destek dengesini, referans çapa seçimini ve çeşitlilik tamamlama kuralını korur. Tablo VI, seçilen adayları ve ana doğrulama teşhislerini gösterir.

Finalist havuzu tek bir skora göre seçilmez. Klinik offline learning'de yüksek değer tahmini, düşük behavior support ile birleştiğinde güvenilir değildir [7]. Yalnız en yüksek FQE veya WIS kullanılsaydı, düşük ESS ya da zayıf clinician exact-bin agreement taşıyan bir politika Aşama 2'ye geçebilirdi. Çeşitlilik slotları da bu yüzden korunur: Aşama 2 yalnız SOFA-konservatif adayları tekrar etmez; seyrek ödülün ve baseline settings'in sınırlarını da gösterir.

XIII. AŞAMA 2 VE BASELINE DEĞERLENDİRMESİ

Aşama 2, altı finalist ve üç seed'den oluşan on sekiz satırlık bir tekrarlı-seed özeti üretmiştir. Her finalist için seed 42, 123 ve 456 kontrol noktaları test replay dataset üzerinde yeniden değerlendirilmiştir. Tek seed'li seçim yapılmış olsaydı rastgele başlatma, mini-yığın sırası veya erken eğitim dalgalanması final politika kararını belirleyebilirdi. Üç seed, hesaplama maliyetini sınırlı tutarken bu varyansı görünür yapar; daha fazla seed istatistiksel güveni artırır, fakat nihai deney taramasının maliyetini doğrusal olarak büyüttü.


Final skor; FQE, WIS, ESS, behavior support mass, clinician exact-bin agreement, low-support cezası ve güvenlik bayraklarını üç seed ortalamasıyla birleştirir. FQE fonksiyon yaklaştırmaya dayalı değer tahmini verir; WIS davranış politikasına göre ağırlıklandırılmış gözlemsel kanıt sağlar. İkisini birlikte kullanmak, tek tahminleyicinin yanlılık-varyans profilini final kararına dönüştürmemek içindir [4], [7], [15]. ESS ve behavior support mass olmasaydı, birkaç yüksek

Tablo IV
NİHAİ DENEY TARAMASI HİPERPARAMETRE IZGARASI.

Boyut	Seçenek	Değerler
Ödül	seyrek	terminal sağkalım/ölüm faydası
Ödül	SOFA-biçimli	terminal fayda + SOFA değişim şekillendirmesi
LR rejimi	konservatif	aktör 3×10^{-5} , eleştirmen 1×10^{-4} , değer 1×10^{-4}
LR rejimi	referans	aktör 1×10^{-4} , eleştirmen 3×10^{-4} , değer 3×10^{-4}
LR rejimi	aktör-konservatif	aktör 3×10^{-5} , eleştirmen 3×10^{-4} , değer 3×10^{-4}
IQL ayarı	güvenli	expectile 0.7, temperature 1.0
IQL ayarı	referans	expectile 0.7, temperature 3.0
IQL ayarı	iyimser	expectile 0.8, temperature 3.0

Tablo V
SABİT EĞİTİM PARAMETRELERİ.

Parametre	Değer
Algoritma	IQL
Epoch	200
Yığın boyutu	256
İskonto	0.99
Politika gizli katman boyutları	[256, 256]
Değer gizli katman boyutları	[256, 256]
Eleştirmen gizli katman boyutları	[256, 256]
Polyak tau	0.005
Hedef güncelleme sıklığı	10
Gradyan kırpması	10.0
Cihaz	auto




Şekil 2. Final seçili IQL politikası ve baselines için WIS ve ESS teşhisleri. Behavior Cloning WIS değeri yüksek görünse de ESS=1.6 olduğu için güvenilir politika üstünlüğü kanıtı olarak yorumlanmaz.


ağırlıklı yörünge yüksek WIS değerini güvenilir gösterebilirdi. Clinician agreement olmasaydı politika davranış verisinden gereğinden fazla uzaklaşabilirdi. Bu kurala göre final konfigürasyon, SOFA-biçimli ödül, konservatif öğrenme oranı ve güvenli IQL ayarına sahip final modeldir.

XIV. AKSIYON VE GÜVENLİK TEŞHİSLERİ

Değer metriği tek başına klinik politika güvenliği göstermez. Bir politika iyi FQE üretebilir, fakat gözlemsel veride nadir görülen sıvı-vazopresör kombinasyonlarına kayabilir. Bu yüzden action heatmap, behavior support mass, low-support rate, clinician agreement ve action entropy aynı anda okunur.



Şekil 3. Aşama 2 finalistleri için tekrarlı-seed FQE değişkenliği. Daha düşük değer, aynı konfigürasyonun seed'ler arasında daha stabil olduğunu gösterir.



Şekil 4. Aşama 2 finalistleri için değer, destek ve güvenlik ödünleşimini gösteren Pareto frontier. Final seçimi tek bir metriktir değil, bu ödünleşimin destek-duyarlı yorumundan elde edilir.

Teşhis okuması somut sorulara dayanır: politika sürekli yüksek sıvı veya yüksek vazopresör mü öneriyor, 'no-treatment' bini'ne çöküyor mu, low-support action'ları sık seçiyor mu, yüksek riskli alt gruplarda uyarılar artıyor mu, ödül varyantı değişince aksiyon dağılımı dramatik biçimde değişiyor mu? Protokol bu sorular için clinician action distribution, IQL policy action distribution, difference heatmap, low-support action oranı, subgroup'a göre clinician agreement, high-risk subgroup policy action frequency, eğitim kaybı eğrileri, doğ-

Tablo VI
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.

Sıra	Yuva	Ödül	LR	IQL	FQE	WIS	support mass	agreement
1	en iyi bileşik	SOFA	konservatif	güvenli	3.169	8.616	0.965	0.418
2	en iyi bileşik	SOFA	konservatif	referans	2.280	7.009	0.973	0.401
3	en iyi seyrek	sparse	konservatif	güvenli	1.954	8.740	0.971	0.411
4	güvenlik desteği	sparse	referans	referans	1.421	6.768	0.973	0.410
5	referans çapa	sparse	referans	güvenli	2.345	8.125	0.963	0.416
6	çeşitlilik tamamlama	sparse	konservatif	referans	2.012	7.782	0.969	0.407

Tablo VII
AŞAMA 2 ÜÇ-SEED FINALIST DEĞERLENDİRMESİ. SKOR; FQE, WIS, ESS, SUPPORT MASS, EXACT-BIN AGREEMENT VE LOW-SUPPORT CEZASINI BİRLEŞTİREN SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	support mass	agreement
1	SOFA konservatif güvenli	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif referans	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif güvenli	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif referans	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline güvenli	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline referans	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo VIII
FINAL SEÇİLİ IQL POLİTİKASININ SEED-DÜZEYİ TEST SONUÇLARI. BU SATIRLAR TABLO X'DEKİ ÜÇ-SEED ORTALAMASININ KAYNAĞINI GÖSTERİR.


Seed	FQE	WIS	ESS	agreement
123	2.806	7.116	31.97	0.417
42	3.217	10.218	28.73	0.414
456	2.520	8.160	27.52	0.410
Ortalama	2.848	8.203	29.41	0.414

Tablo IX
BASELINE POLİTİKA WIS TEŞHİSLERİ. FQE YALNIZ ÖĞRENİLMİŞ IQL KONTROL NOKTASI İÇİN RAPORLANIR; BASELINES İÇİN WIS/ESS VE CLINICIAN AGREEMENT AYNI TEST REPLAY DATASET ÜZERİNDE HESAPLANMIŞTIR.

Politika	WIS	ESS	agreement
Clinician replay	8.774	2585.0	1.000
No-treatment	7.464	34.2	0.354
Behavior Cloning	9.194	1.6	0.405
Seçili IQL	8.203	29.4	0.414

Tablo X
KAZANAN KONFIGÜRASYONUN TEST DIAGNOSTICS. WIS CONFIDENCE INTERVAL, 50 HASTA-DÜZEYİ PATIENT-LEVEL BOOTSTRAP İLE HESAPLANMIŞTIR.

Metrik	Sonuç
FQE	2.848
WIS	8.203
WIS 95% CI	4.963–10.817
ESS	29.410
Behavior support mass	0.991
Clinician exact-bin agreement	0.414
Clinician exact-bin disagreement	0.586
Low-support action deviation	0.009



Şekil 5. OPE metriklerine göre finalist sıralaması. Grafik, Tablo VII'deki bileşik skorun FQE, WIS, ESS ve destek göstergeleriyle birlikte okunması gerektiğini gösterir.


rulama metrik eğrileri, ödül varyantı kutu grafiği, LR rejimi karşılaştırması ve expectile-temperature karşılaştırması grafiklerini çıktı olarak üretir.

Aşama 2 finalistlerinde behavior support mass 0.990–0.991, clinician exact-bin agreement 0.401–0.418 aralığındadır. Kazanan politikanın exact-bin agreement değeri 0.414'tür; yani kararların 0.586'luk kısmı klinisyen davranışıyla birebir aynı değildir. Buna rağmen low-support action deviation değeri 0.009'da kalır. Bu ayrım önemlidir: politika klinisyeni kopyalamaz, fakat çoğu sapma veri desteği bulunan komşu tedavi yörüngelerinde kalır. ESS ise tüm finalistlerde 50 eşliğinin altındadır. Bu uyarı, az sayıda etkili yörüngenin taşıdığı WIS tahmininin kesin klinik sonuç gibi yorumlanmasını engeller.


Bu nedenle final karar “klinik üstünlük” değil, destek kısıtı belirtilmiş retrospektif OPE sonucudur.

XV. YENİDEN ÜRETİLEBİLİRLİK VE TEKNOLOJİ YİĞİNİ

İş akışı protokoldeki ana boşlukları kapatır: nihai IQL deney taraması, 18 konfigürasyonlu grid, workflow seviyesinde orkestrasyon, ön denetim, final-altı seçim mantığı, tekrarlı-seed Aşama 2 birleştirmesi, baseline karşılaştırması ve final grafik değerlendirmeleri. Çıktı seti ön denetim sonucunu, Aşama 1 seçim tablosunu, Aşama 2 seed özetini, final metrik paketini, baseline politika gösterimini ve behavior support mass, seed varyansı, Pareto frontier, OPE sıralaması, aksiyon, bootstrap,



Şekil 6. Final politika analizi için üretilmiş action distribution heatmap'i. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.




Şekil 7. Final seçili IQL politikasının üç seed için patient-level bootstrap WIS CI. Güven aralıkları 50 patient-level bootstrap ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.


clinician agreement, subgroup safety ve sapma şiddeti grafiklerini içerir. Aşama 2 değerlendirmesi 18 finalist-seed satırı olarak saklanır.

Teknoloji yığını Python ve 'uv' tabanlı ortam yönetimi, yüksek hızlı 'Polars' ve 'PyArrow' tabanlı Parquet veri dönüşümü ve 'PyTorch' tabanlı RL eğitiminden oluşur. Hardware-agnostic execution layer sayesinde eğitim kodu MPS, CUDA veya otomatik cihaz seçimiyle çalışabilir. Bu altyapı ayrıştırılmasaydı deney sonuçları belirli bir donanıma veya elle değiştirilmiş konfigürasyonlara bağımlı hale gelirdi.

Her çalıştırma için git commit özeti, konfigürasyon dosyası, ödül varyantı, LR rejimi, expectile, temperature, seed, veri seti yolu, metadata yolu, bölme manifestosu seed'i, action bin çıktısı, eğitim günlükleri, kontrol noktası yolu, değerlendirme çıktısı ve figür yolları kaydedilmelidir. Çalıştırma isimlendirme şablonu ödül, LR rejimi, IQL ayarı ve seed bilgisini birlikte taşıyan 'iql_reward_lr_setting_seed' biçimindedir. Örneğin SOFA-biçimli, actor-conservative, baseline ve seed 42 bilgileri aynı çalıştırma adında saklanır. Bu sözleşme



Şekil 8. Finalist politikalar için clinician exact-bin agreement. Bu metrik, politikanın davranış verisinden ne kadar uzaklaştığını gösterir; tek başına performans kanıtı değildir, destek ve OPE metrikleriyle birlikte yorumlanır.




Şekil 9. Yüksek riskli alt gruplarda clinician agreement ve low-support action oranı. Bu teşhis, final politikanın ortalama hasta dışındaki daha kırılgan alt gruplarda da destek sınırlarını koruyup korumadığını inceler.

tutulmasaydı sonradan hangi kontrol noktasının hangi veri ve konfigürasyonla üretildiği izlenemezdi.

XVI. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve gözlemseldir; öğrenilen politika yatak başı tedavi önerisi değildir. Durum vektörü gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen karıştırıcılık etkilerini tam kapsamaz. Gerçek klinik süreç POMDP'ye daha yakındır; model hekimin tüm yatak başı bilgisini görmez. Klinisyen aksiyonları da karıştırıcılık taşıır; daha ağır hastalara daha agresif vazopresör verilmesi, tedaviyi zararlı gösterebilir veya yanlış fayda atfı üretebilir.

MIMIC-IV verisi PhysioNet credentialing, CITI training ve Data Use Agreement kapsamındaki yükümlülüklerle tabidir; hasta verileri kimliksizleştirilmiş olsa da raporlama akademik ve etik sınırlar içinde kalmalıdır. FQE ve WIS prospektif klinik kanıt değildir; fonksiyon yaklaşımı, davranış politikası tahmini, destek varsayımları ve varyans profiline bağlıdır. ESS değerinin 50 eşliğinin altında kalması ve patient-level bootstrap sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.



Şekil 10. Politika aksiyonlarının klinisyen aksiyonlarından sapma şiddeti. Sapma analizi, exact-bin disagreement'ın klinik grid üzerinde küçük komşu hareketlerden mi yoksa daha büyük dozaj değişimlerinden mi kaynaklandığını gösterir.

XVII. SONUÇ

IQL nihai deney taraması, sepsis dozaj politikalarını tek seferlik bir model çıktısı olarak değil, denetlenebilir bir çevrimdışı değerlendirme protokolü olarak ele alır. Kohort seçimi, zaman penceresi, state/action/reward mühendisliği, sızıntısız ön işleme, IQL eğitimi, hyperparameter grid, Aşama 1 finalist seçimi ve Aşama 2 çoklu-seed değerlendirmesi aynı raporda izlenebilir hale gelir. Aşama 0 ön denetim geçilmiştir; Aşama 1 altı destek-duyarlı finalist üretmiştir. Aşama 2 sonucunda SOFA-biçimli ödül, konservatif öğrenme oranı ve güvenli IQL ayarına sahip final model seçilir. Model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 verir; ancak ESS=29.41 ile güvenilirlik eşiğinin altındadır. Bu nedenle sonuç klinik performans kanıtı değil, metodolojik ve retrospektif OPE kanıtıdır.

KAYNAKLAR

- [1] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Annane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, “The third international consensus definitions for sepsis and septic shock (sepsis-3),” *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.
- [2] K. E. Rudd, S. C. Johnson, K. M. Agesa, K. A. Shackelford, D. Tsoi, D. R. Kievlan, D. V. Colombara, K. S. Ikuta, N. Kissoon, S. Finfer *et al.*, “Global, regional, and national sepsis incidence and mortality, 1990–2017: analysis for the global burden of disease study,” *The Lancet*, vol. 395, no. 10219, pp. 200–211, 2020.
- [3] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” *arXiv preprint arXiv:2005.01643*, 2020.
- [4] C. Voloshin, H. M. Le, N. Jiang, and Y. Yue, “Empirical study of off-policy policy evaluation for reinforcement learning,” in *NeurIPS Datasets and Benchmarks*, 2021.
- [5] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, “The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care,” *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [6] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, “Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach,” in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [7] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, “Guidelines for reinforcement learning in healthcare,” *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [8] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, “Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021,” *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.

- [9] J. Peng and R. J. Williams, “Incremental multi-step q-learning,” *Machine Learning*, vol. 22, no. 1–3, pp. 283–290, 1996.
- [10] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, “Mimic-iv, a freely accessible electronic health record dataset,” *Scientific Data*, vol. 10, no. 1, p. 1, 2023.
- [11] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018.
- [12] S. Liu, K. C. See, K. Y. Ngiam, L. A. Celi, X. Sun, and M. Feng, “Reinforcement learning for clinical decision support in critical care: Comprehensive review,” *Journal of Medical Internet Research*, vol. 22, no. 7, p. e18477, 2020.
- [13] I. Kostrikov, A. Nair, and S. Levine, “Offline reinforcement learning with implicit q-learning,” in *International Conference on Learning Representations*, 2022.
- [14] A. Kumar, A. Zhou, G. Tucker, and S. Levine, “Conservative q-learning for offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, 2020.
- [15] D. Precup, R. S. Sutton, and S. P. Singh, “Eligibility traces for off-policy policy evaluation,” in *Proceedings of the Seventeenth International Conference on Machine Learning*, 2000, pp. 759–766.