

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Çevrimdışı Pekiştirmeli Öğrenme İş Akışı

Furkan Nezir Üzmez
230202073

Özet—MIMIC-IV üzerinde sepsis dozaj politikası öğrenirken temel risk, modelin tarihsel veride zayıf temsil edilen sıvı-vazopresör kombinasyonlarını güvenilir sanmasıdır. Bu rapor, canlı hastalarda keşif yapmadan bu riski denetlemek için kurulan offline pekiştirmeli öğrenme iş akışını açıklar. İş akışı Sepsis-3 ko-hort seçimini, 72 saatlik pencereyi, 62 boyutlu durum vektörünü, 5×5 ayrık aksiyon uzayını, sparse ve SOFA-shaped ödülleri, train-only preprocessing'i, hasta-düzeyi split'i, IQL taramasını, çok kriterli finalist seçimini ve çoklu tohum doğrulamasını aynı protokol içinde tutar. Aşama 1'de iki ödül, üç learning-rate rejimi ve üç expectile-temperature ayarından oluşan 18 konfigürasyon değerlendirilir; Aşama 2'de altı finalist üç tohumla yeniden ölçülür. Final aday 'iql_sofa_shaped_conservative_safe' konfigürasyonudur. Üç tohum ortalamasında FQE=2.848, WIS=8.203, bootstrap WIS 95% CI=4.963–10.817, ESS=29.410, destek kütle=0.991 ve klinisyen exact-bin uyumu=0.414 verir. ESS 50 eşliğinin altında kaldığı için bu sonuç klinik üstünlük iddiası değil, destek sınırı açıkça belirtilmiş retrospektif off-policy değerlendirme kanıtıdır.

Index Terms—offline pekiştirmeli öğrenme, implicit Q-learning, sepsis, MIMIC-IV, off-policy evaluation, yeniden üretilebilirlik, klinik karar desteği

I. GİRİŞ

Sepsis resüsitasyonunda aynı hasta birkaç saat içinde farklı sıvı ve vazopresör dozlarına ihtiyaç duyabilir. Bu kararlar gecikmeli mortalite sonuçlarına bağlanır ve daha hasta bireylerin daha agresif tedavi alması confounding üretir. Offline pekiştirmeli öğrenme bu nedenle çekicidir: model yalnızca geçmiş yoğun bakım trajektorilerini kullanır, hastalar üzerinde keşif yapmaz. Aynı özellik yöntemi kırılabilir de yapar; politika desteklenmeyen aksiyonlara kayarsa, FQE veya WIS gibi off-policy estimatorler sayısal olarak düzgün görünse bile klinik olarak güvenilir hale gelmez.

Bu proje, MIMIC-IV üzerinde yatak başı karar aracı değil, denetlenebilir bir retrospektif değerlendirme laboratuvarı kurar. Model sınıfı model-free, off-policy ve offline RL'dir. CQL, BCQ ve IQL aileleri tasarım aşamasında değerlendirilmiş; final rapor IQL'ye odaklanmıştır, çünkü IQL veri dışı aksiyon maksimumu almadan politika çıkarır. Kodun MPS ve CUDA üzerinde aynı eğitim mantığıyla çalışması istenir; donanım farkı deney kararına dönüşmemelidir.

Klinik zaman çizelgesi dört saatlik karar pencerelerine ayrılır; her karar, vazopresör ve intravenöz sıvı şiddetinin 5×5 kombinasyonlarından biridir. Final deney iki ödül varyantını aynı terminal değerlendirme altında karşılaştırır, finalistleri yalnız validation kanıtıyla seçer ve raporlanabilir

artifact bundle üretir. Denetim kapıları, deterministik grid genişletmesi, çoklu tohum birleştirmesi ve grafik raporlama bu nedenle yardımcı ayrıntı değil, sonucun geçerlilik koşuludur.

II. İLGİLİ ÇALIŞMALAR

Offline pekiştirmeli öğrenme, politika öğrenimini sabit bir veri kümesinin davranış desteği içinde tutmaya çalışır. IQL bu amaçla veri dışı aksiyonları maksimize etmez; expectile value learning ve advantage-weighted behavioral cloning kullanır [1]. CQL ise düşük destekli aksiyonların Q değerini açıkça cezalandırır [2]. Bu ceza extrapolation error'a karşı güçlüdür, fakat yanlış ayarlandığında klinikte nadir ama gerekli kurtarma müdahalelerini de bastırabilir. IQL'nin tercih edilmesi bu yüzden bilinçli bir takastır: destek dışına taşma azalır, ancak veri dağılımında hiç görülmeyen tedavi stratejileri keşfedilemez.

Sepsis RL literatüründe iki çalışma bu tasarımı doğrudan çerçeveler. AI Clinician, sıvı ve vazopresör dozlarını ayrık tedavi kutuları olarak modellemiştir; Raghu ve arkadaşları aynı problemi sürekli durum temsilleriyle ele almıştır [3], [4]. Bu çalışmalar klinik karar desteği için yol açsa da, sağlıkta RL rehberleri gözlemsel politikaların confounding, destek eksikliği, estimator varyansı ve prospektif doğrulama eksikliği nedeniyle tedavi önerisi sayılamayacağını belirtir [5]. Bu rapor bu sınırı korur: amaç klinik üstünlük iddiası değil, yeniden üretilebilir offline değerlendirme kanıtıdır. Veri kaynağı de-identified kritik bakım kayıtları sunan MIMIC-IV tür [6]; aksiyon eksenlerinin sıvı ve vazopresör olarak seçilmesi güncel sepsis yönetiminde bu iki müdahalenin merkezi rolüyle uyumludur [7].

III. KURAMSAL ARKA PLAN VE ALGORİTMİK KONUMLANDIRMA

Offline RL'de politika iyileştirmesi, veri desteği dışına taşmadığı sürece anlamlıdır. Klasik off-policy değer öğrenimi bir sonraki durumda $\max_{a'} Q(s', a')$ sorgusu yaptığından, veri setinde hiç görülmemiş aksiyonlara değer atar. Fonksiyon yaklaşımcı bu bölgelerde eğitim sinyali almadığı için extrapolation error oluşur; hata Bellman yedeklemeleriyle büyür ve klinik veride güvenilir doz önerilerine dönüşebilir.

Literatürde bu hataya verilen yanıtlar üç grupta toplanabilir. CQL gibi explicit action-space regularization yöntemleri veri dışı aksiyonların Q değerini düşürür ve kötümser bir alt sınır kurar [2]. IQL gibi implicit, in-sample yöntemler gözlenmemiş

aksiyonu sorgulamaz; veri içinde yüksek değerli görünen aksiyonların üst expectile'ını öğrenir [1]. State-space manifold regularization ise cezayı aksiyonlardan durum manifoldunun dışına taşır. Bu rapor IQL hattını seçer; çünkü klinik uygulamada ek ceza katsayısı kalibrasyonundan önce destek içinde kalma ve yorumlanabilir validation protokolü daha kritik kabul edilmiştir.

Multi-step value propagation bu çalışmanın doğrudan deney değişkeni değil, sonraki araştırma eksenidir. Tek adımlı yedeklemeler sparse terminal mortalite sinyalini 18 adımlık trajectory boyunca yavaş taşır; Peng'in $Q(\lambda)$ gibi eligibility trace yaklaşımları bu gecikmeyi azaltabilir. Bu raporda önce destek güvenliği ve leakage-free değerlendirme sabitlenmiştir. Multi-step operatör aynı anda değiştirilseydi, final IQL sonucunun reward/LR/expectile seçimi mi yoksa yedekleme operatörü mü nedeniyle değiştiği ayrıştırılamazdı.

IV. UÇTAN UCA PROJE MIMARISI

Proje, katı bağımlılık zinciriyle ilerleyen on ana adımdan oluşur. Bu yapı, veri hazırlama hatalarının final politika değerlendirmesine taşınmasını engellemek için bilinçli olarak aşamalı tasarlanmıştır.

Bu mimariyi tek bir eğitim scripti olarak ele almıyoruz. Kohort tanımı, veri sözleşmesi, model eğitimi, off-policy değerlendirme, güvenlik analizi ve raporlama artifactleri aynı deney protokolüne bağlanır. Bu bağ kurulmazsa final IQL skoru üretilebilir görünür; ancak split sızıntısı, farklı preprocessing ya da hatalı transition indeksleme model başarısı sanılabilir.

V. KOHORT, ZAMAN VE SPLIT TASARIMI

A. Kohort Seçimi

Kohort MIMIC-IV üzerinde Sepsis-3 kriterlerine göre oluşturulur [6], [8]. Dahil edilen popülasyon 18 yaş ve üzeri yetişkin, doğrudan ICU izlemine sahip ve sepsis tanımıyla uyumlu hastalardır. Çocuk hastalar farklı doz ve fizyoloji rejimlerine sahip oldukları için dışarıda bırakılır; bu karar verilmeseydi model tek bir aksiyon-doz anlamını heterojen yaş grupları için öğrenmeye zorlanırdı. ICU dışı veya yoğun gözlem verisi olmayan hastalar da dışlanır; çünkü 4 saatlik karar pencereleri için yeterli fizyolojik zaman serisi kurulamaz.

Dışlama kuralları model performansını temiz göstermek için değil, karar penceresini klinik olarak tutarlı tutmak için uygulanır. Sepsis onset zamanı bulunamayan hastalar, 4 saatten kısa ICU kalışı olanlar ve yaş/cinsiyet gibi temel demografisi eksik olanlar çıkarılır. Tekrar yatan hastalarda yalnız ilk yatış kullanılır. Aynı hastanın bir yatışı train setine, sonraki yatışı test setine düşerse model kronik profili dolaylı olarak ezberleyebilir; bu nedenle filtreleme sonucu ve dışlanan hasta sayıları audit artifactlerinde saklanır.

B. Zaman Çizelgesi

Her ICU kalışı için 'sepsis_onset_time' hesaplanır. Analiz penceresi onset'ten 24 saat önce başlayıp 48 saat sonrasına kadar devam eder. Bu 72 saatlik pencere 4 saatlik karar adımlarına ayrıldığında tipik episode yaklaşık 18 timestep

içerir. Dört saatlik pencere, literatürdeki sepsis RL kurulumlarıyla karşılaştırılabilirlik sağlar ve klinik ölçümlerin düzensiz zamanlanması yönetilebilir bir karar frekansına indirger [3], [4]. Daha kısa pencere seçilseydi ölçüm eksikliği ve gürültülü aksiyon tekrarları artacak, davranış politikası olasılıkları daha seyrek gözlenen mikro kararlar üzerinde tahmin edilecekti. Daha uzun pencere seçilseydi de sıvı ve vazopresör değişimlerinin akut fizyolojik etkileri ortalamaya karışacak, ardışık karar yapısı zayıflayacaktı.

C. Split Stratejisi

Varsayılan split hasta düzeyinde train %70, validation %15 ve test %15 olarak yapılır. Split seed'i 42 olarak sabitlenir. Train, validation ve test subject kümelerinin kesişimi boş olmalıdır. Test seti yalnız final raporlama için kullanılır; hyperparameter, checkpoint veya metrik tasarımı test sonucuna göre değiştirilmez. Bu kural ihlal edilseydi final test metrikleri gerçek held-out kanıt olmaktan çıkar, validasyonun uzantısı haline gelirdi.

VI. MDP FORMÜLASYONU

Problem sonlu ufuklu bir Markov karar süreci olarak modellenir:

$$M = (S, A, P, R, \gamma). \quad (1)$$

Burada S hasta durum uzayını, A ayrık tedavi aksiyonlarını, P geçiş dinamiklerini, R ödül fonksiyonunu ve γ discount factor'ü temsil eder. Her geçiş şu biçimdedir:

$$(s_t, a_t, r_t, s_{t+1}, done_t). \quad (2)$$

A. State Temsili

State vektörü hastanın o andaki klinik durumunu özetleyen 62 sürekli/ikili özellikten oluşur. Başlıca gruplar kalp hızı, MAP, sistolik/diyastolik tansiyon, solunum ve SpO2 gibi vital bulgular; kan gazı, elektrolit, renal, hepatik, koagülasyon ve hemogram laboratuvarları; kümülatif sıvı, vazopresör maruziyeti ve idrar çıkışı gibi tedavi sinyalleri; yaş ve cinsiyet gibi demografik değişkenler; PaO2/FiO2, shock index ve onset sonrası saat gibi türetilmiş değişkenlerdir.

Her 4 saatlik pencerede birden fazla ölçüm varsa özelliğe göre 'last', 'mean', 'min', 'max', 'sum' veya 'cumulative' agregasyon kuralı uygulanır. Örneğin bazı vital bulgularda son ölçüm klinik karar anına daha yakın bilgi taşıırken, toplam sıvı veya kümülatif vazopresör maruziyeti pencere içi tedavi yükünü temsil eder. Tek bir agregasyon kuralı tüm değişkenlere dayatılsaydı klinik anlamı farklı sinyaller aynı istatistiksel kalıba sıkıştırılmış olurdu.

Eksik veriler için sıralı strateji uygulanır: episode içinde forward-fill, train split üzerinden hesaplanan medyan, klinik normal değer fallback ve gerekli durumda missingness flag. Missingness göstergeleri eklenmeseydi model, ölçülmeyen laboratuvarı normal değerle karıştırabilir ve hekimin ölçüm kararıyla taşınan risk bilgisini kaybedebilirdi. Train-only medyan kullanılmazsa validation/test dağılım bilgisi preprocessing üzerinden eğitime sızardı.

Tablo I
PROJENİN ON AŞAMALI UÇTAN UCA MIMARISI.

Adım	Bileşen	İçerik
1	Kohort seçimi	MIMIC-IV içinden Sepsis-3 kriterlerine uyan yetişkin ICU hastalarının seçilmesi; geçersiz onset, kısa ICU kalışı, eksik temel demografi ve tekrar yatışların yönetilmesi.
2	Zaman çizelgesi	Sepsis onset'inden 24 saat önce başlayıp 48 saat sonrasına uzanan 72 saatlik pencerenin 4 saatlik karar adımlarına bölünmesi.
3	Zero-leakage split	Hastaların train/validation/test olarak hasta-düzeyinde ayrılması ve preprocessing fit işlemlerinin yalnız train üzerinde yapılması.
4	State çıkarımı	Vital, laboratuvar, tedavi geçmişi, demografi, missingness ve türetilmiş değişkenlerden 62 boyutlu durum vektörü üretilmesi.
5	Action/reward	Vazopresör ve IV sıvı dozlarının 25 ayrıklı aksiyona dönüştürülmesi; sparse ve SOFA-shaped ödüllerin üretilmesi.
6	Transition/baseline	Replay verisinin $(s_t, a_t, r_t, s_{t+1}, done_t)$ formatında yazılması; clinician, no-treatment ve behavior cloning baselinelerinin kurulması.
7-8	IQL eğitimi	Offline veride destek dışında çıkmadan expectile value learning ve advantage-weighted actor update ile IQL politikalarının eğitilmesi.
9	OPE ve güvenlik	FQE, WIS, ESS, bootstrap CI, destek kütesi, clinician agreement, heatmap ve güvenlik diagnostiklerinin hesaplanması.
10	Final sweep	18 konfigürasyonlu IQL taraması, finalist seçimi, çoklu tohum doğrulaması ve IEEE rapor artifactlerinin üretilmesi.

Tablo II
VAZOPRESÖR VE IV SIVI AKSIYON GRID'İ.

Vazo bini	Sıvı bini				
	0	1	2	3	4
0	0	1	2	3	4
1	5	6	7	8	9
2	10	11	12	13	14
3	15	16	17	18	19
4	20	21	22	23	24

B. Action Uzayı

Aksiyon uzayı 25 ayrıklı tedavi kararından oluşur. Her aksiyon, vazopresör dozu ve IV sıvı miktarının 5×5 kombinasyonudur:

$$action_id = vaso_bin \times 5 + fluid_bin. \quad (3)$$

Bin 0 tedavi yok anlamına gelir; non-zero dozlar train split üzerindeki çeyrekliklere göre Q1-Q4 olarak ayrılır. Zero dose ayrı tutulur, çünkü hiç tedavi vermemek küçük ama non-zero tedaviyle aynı klinik anlamı taşımaz. Bin eşikleri yalnız train split üzerinde öğrenilir ve validation/test üzerinde dondurulmuş şekilde uygulanır. Eşikler tüm veri üzerinde hesaplanırdı test doz dağılımı aksiyon kodlamasına sızardı.

C. Reward Tasarımı

İki ödül varyantı kullanılır. Sparse ödül yalnız terminal mortalite/sağkalım utility'sini kullanır: 90 gün yaşayan hasta için +15, 90 gün içinde ölüm için -15. Bu seçenek klinik nihai sonucu doğrudan hedeflediği için yorumlanması kolaydır, fakat uzun ufuklu ve seyrek geri bildirimli olduğundan değer öğrenmesi yüksek varyanslı hale gelebilir.

SOFA-shaped ödül terminal utility'yi korur ve ara adımlarda SOFA değişimine küçük bir shaping sinyali ekler:

$$sofa_shaping = -0.025 \times (SOFA_{current} - SOFA_{previous}). \quad (4)$$

SOFA artışı kötüleşme olarak negatif, SOFA azalması iyileşme olarak pozitif sinyal üretir. SOFA'nın sepsis organ disfonksiyonu tanımı ve klinik şiddet takibiyle ilişkili olması bu ara sinyali klinik olarak gerekçelendirir [8]. SOFA shaping kullanılmıyaydı eğitim yalnız terminal sonuca dayanacak ve ara fizyolojik iyileşmeleri ayırt etmek zorlaşacaktı. Tersine, shaping ağırlığı çok güçlü seçilseydi ajan mortalite yerine kısa vadeli skor oynamalarını optimize edebilirdi; bu nedenle terminal utility korunmuş ve seçim ortak terminal değerlendirmeye bağlanmıştır.

D. Discount Factor

Discount factor $\gamma = 0.99$ olarak sabitlenir. Bu seçim, sepsis tedavisinde kısa vadeli hemodinamik kararların uzun vadeli mortalite sonucuyla ilişkili olması nedeniyle uygundur. Daha küçük bir γ kısa vadeli SOFA değişimlerini fazla önerebilir, $\gamma = 1$ ise sonlu ufukta mümkün olsa da FQE ve WIS tahminlerinde geç dönem terminal sinyallerine daha hassas bir varyans profili doğurabilirdi.

VII. PREPROCESSING VE LEAKAGE-FREE SÖZLEŞMELER

Temel kural 'fit on train, transform everywhere' şeklindedir. Scaler parametreleri, imputer medyanları, clip bound veya percentile eşikleri, action bin quartile eşikleri, behavior policy estimator, FQE estimator ve normalization sabitleri train üzerinde fit edilir. Validation ve test üzerinde yalnız train'de fit edilmiş transformlar uygulanır.

Fizyolojik olarak makul olmayan değerler valid range dışında filtrelendirir veya clip edilir. Clipping ve normalization parametreleri train split üzerinde fit edilir. Bu tercih yapılmıyaydı validation/test dağılımının uç değer bilgisi eğitim öncesi veri dönüşümlerine yansiyabilir ve raporlanan performans fazla iyimser olurdu.

A. Aşama 0 Ön Tarama Denetimi

Presweep denetimi, eğitim başlamadan önce veri sözleşmelerini test eder. Sağlıkta RL için bu kapı zorunludur;

Tablo III
PRESWEEP DENETİM ÖZETİ.

Kanıt kalemi	Train	Validation	Test
Split manifest satırı	12063	2585	2585
SOFA-shaped replay satırı	140635	30539	30046
Sparse replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage taraması		Başarılı	

küçük bir split sızıntısı veya outcome leakage, gözlemsel veride gerçek politika kalitesinden çok daha büyük görünen kazançlar üretebilir [5]. Denetim sparse replay üretimini, sparse ve SOFA-shaped replay dosyalarının aynı split/preprocessing/action bin/transition indexing/terminal outcome tanımlarını kullanmasını, action binlerinin train-only fit edilmesini, imputation/scaling/clipping/normalization istatistiklerinin train-only kalmasını, validation FQE'nin ortak terminal survival/death reward ile çalışmasını, temporal alignment'ı, hasta çakışması bulunmamasını ve mortality/discharge gibi gelecek outcome bilgisinin state feature'larına sızmasını kontrol eder.

Bu adım atlanmış olsaydı Aşama 2 sonucu sayısal olarak üretilebilir görünse bile, aynı hastanın farklı splitlere düşmesi veya terminal bilginin özelliklere sızması nedeniyle metodolojik olarak geçersiz hale gelebilirdi.

VIII. BASELINE POLİTİKALARI

Final test karşılaştırması üç referans politika içerir. Clinician replay, replay datasetindeki gözlenen klinisyen aksiyonlarını değerlendirir ve davranış verisinin kendisini referans alır. No-treatment policy, uygun yerlerde no-vasopressor/no-fluid bin'ini seçen basit kontrol politikasıdır. Behavior cloning ise klinisyen aksiyonlarını supervised learning ile taklit eder. Bu baselineler eklenmeseydi IQL çıktısı yalnız kendi OPE skoru ile raporlanır, davranış politikasına ve basit kontrol stratejilerine göre bağlamı kaybolurdu.

IX. IQL ALGORİTMASI

Implicit Q-Learning, dataset dışındaki aksiyonları maksimize etmeden politika çıkarır [1]. Model üç parça öğrenir: critic, value function ve actor. Critic $Q_\theta(s, a)$ state-action değerini tahmin eder. Value function, klasik max operator yerine expectile regression ile fit edilir. Expectile düştükçe değer hedefi davranış verisine yaklaşır; expectile yükseldikçe veri içindeki daha yüksek değerli aksiyonlara ağırlık verir.

Value objective asimetrik expectile kaybı ile yazılır:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim D} [L_2^\tau(Q_\theta(s, a) - V_\psi(s))], \quad (5)$$

$$L_2^\tau(u) = |\tau - \mathbb{I}(u < 0)|u^2. \quad (6)$$

τ 1'e yaklaştıkça value fonksiyonu davranış verisi içinde daha iyi görünen aksiyonların üst expectile'ına yaklaşır. Q

fonksiyonu ise veri dışı aksiyon maksimumunu yerine öğrenilen state value hedefiyle güncellenir:

$$L_Q(\theta) = \mathbb{E}_D [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (7)$$

Actor, dataset içindeki aksiyonları advantage'a göre ağırlıklandırarak öğrenir:

$$A(s, a) = Q_\theta(s, a) - V_\psi(s), \quad (8)$$

$$L_\pi(\phi) = \mathbb{E}_D [\exp(\beta A(s, a)) \log \pi_\phi(a|s)]. \quad (9)$$

Burada β ya da temperature politika çıkarımının agresifliğini kontrol eder. Düşük temperature davranış politikasına daha yakın ve konservatif politika çıkarır; yüksek temperature potansiyel getiriyi artırabilir fakat düşük destekli aksiyonlara kayma riskini de büyütür. Bu nedenle safe, baseline ve optimistic ayarları birlikte denenmiştir.

X. IQL FINAL TARAMA TASARIMI

Final tarama iki ödül varyantı, üç learning-rate rejimi ve üç IQL ayarını on sekiz Aşama 1 adayına genişletir. Learning-rate rejimleri actor, critic ve value optimizasyonunu ayrı olarak kontrol eder. Konservatif learning-rate rejimi finalde öne çıkarılmıştır; çünkü offline RL'de agresif critic güncellemeleri veri dışı Q tahminlerini büyütebilir ve politika çıkarımı bu hataları çoğaltabilir [1], [2]. Baseline rejim yalnızca referans anchor olarak tutulmuştur; hiç denenmeseydi konservatif seçimin gerçekten gerekli olup olmadığı gözlenemezdi. Actor-konservatif rejim ise politika güncellemelerini yavaşlatmanın, critic/value öğrenmesini tamamen yavaşlatmadan destek uyumunu artırıp artırmadığını test eder.

Sabit parametreler korunmuştur; böylece final sweep yalnız reward, learning-rate rejimi, expectile ve temperature etkisini ölçer. Bu parametreler de serbest bırakılsaydı 18 konfigürasyonun etkisi yorumlanamaz, model başarısının mimari mi yoksa reward/LR/IQL ayarı kaynaklı mı olduğu belirsizleşirdi.

XI. SEED STRATEJİSİ VE KARAR KURALI

Tek seed, offline RL için zayıf kanıttır. Initialization, mini-batch sırası ve stochastic optimizasyon aynı konfigürasyonun FQE/WIS değerini değiştirebilir. Aşama 1'de 18 konfigürasyon seed 42 ile taranır; ardından altı finalist seed 123 ve 456 ile yeniden değerlendirilir. Böylece tüm $2 \times 3 \times 3 \times 3 = 54$ run yerine 30 run çalıştırılır. Bu tasarım hesaplama maliyetini düşürür, fakat final adayları üç seed üzerinden raporladığı için seed varyansı görünür kalır.

Hyperparameter seçimi test set üzerinden yapılmaz. Seçim validation split üzerindeki FQE, WIS, ESS, clinician agreement, action distribution makullüğü, low-support action uyarıları, reward curve ve training stability sinyallerine dayanır. Tek bir metrikle karar verilmez. Örneğin yüksek WIS ama çok düşük ESS varsa bu sonuç güvenilir kabul edilmez.

Bir konfigürasyon final aday olmadan önce validation performansı rekabetçi olmalı, ESS çok düşük olmamalı, FQE sonucu WIS ile tamamen çelişmemeli, action distribution klinik olarak makul olmalı, low-support action oranı kabul edilebilir düzeyde olmalı, farklı seedlerde performans tamamen kararsız olmamalı ve test set seçim sürecinde kullanılmamış olmalıdır.

Tablo IV
FINAL IQL HIPERPARAMETRE GRID'İ.

Boyut	Seenek	Deęerler
Reward	sparse	terminal survival/death utility
Reward	SOFA-shaped	terminal utility + SOFA deęiřim shaping
LR rejimi	conservative	actor 3×10^{-5} , critic 1×10^{-4} , value 1×10^{-4}
LR rejimi	baseline	actor 1×10^{-4} , critic 3×10^{-4} , value 3×10^{-4}
LR rejimi	actor-conservative	actor 3×10^{-5} , critic 3×10^{-4} , value 3×10^{-4}
IQL ayarı	safe	expectile 0.7, temperature 1.0
IQL ayarı	baseline	expectile 0.7, temperature 3.0
IQL ayarı	optimistic	expectile 0.8, temperature 3.0

Tablo V
SABİT EęİTİM PARAMETRELERİ.

Parametre	Deęer
Algoritma	IQL
Epoch	200
Batch size	256
Discount	0.99
Policy hidden sizes	[256, 256]
Value hidden sizes	[256, 256]
Critic hidden sizes	[256, 256]
Polyak tau	0.005
Target update freq	10
Grad clip	10.0
Device	auto


Algorithm 1 Final IQL Tarama ve Raporlama İř Akıřı

- 1: Replay, split, preprocessing ve zamansal szleřmeleri doę-rula
- 2: dl, learning-rate ve IQL ayarlarını geniřlet
- 3: **for** her Ařama 1 adayı **do**
- 4: Seed 42 ile politikayı eęit
- 5: Validasyon metriklerini ve destek diagnostiklerini he-sapla
- 6: **end for**
- 7: Gvenlik veya destek kapılarını geemeyen adayları iřa-retle
- 8: Composite, dl dengesi, gvenlik ve eřitlilik slotlarıyla finalist se
- 9: **for** her finalist ve her doęrulama tohumu **do**
- 10: Seed 123 ve 456 ile politikayı eęit veya yeniden kullan
- 11: oklu tohum deęerlendirme kanıtını topla
- 12: **end for**
- 13: Tekrarlanan tohum kanıtıyla final konfigrasyonu se
- 14: Baseline karřılařtırmaları, grafikler ve yeniden retilebi-lirlik artifactleri ret

XII. AřAMA 1 FINALIST SEİM SONULARI

Ařama 1 seici altı finalist retmiřtir. En yksek iki aday SOFA-shaped dl ve konservatif learning-rate kullanırken, dięer slotlar sparse dl temsilini, gvenlik-destek dengesini, baseline anchor seimini ve eřitlilik backfill kuralını korur. Tablo VI, seilen adayları ve ana validasyon diagnostiklerini gsterir.

Finalist havuzu tek bir skora gre seilmez. Klinik offline



řekil 1. Validasyon value tahmini ile davranıř desteęi diagnostiklerinin birlikte gsterimi. Yksek value yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.

ęrenmede yksek value tahmini, dřk davranıř desteęiyle birleřtięinde gvenilir deęildir [5]. Yalnız en yksek FQE veya WIS kullanılsaydı, dřk ESS ya da zayıf clinician agreement tařıyan bir politika Ařama 2'ye geebilirdi. eřitlilik slotları da bu yzden korunur: Ařama 2 yalnız SOFA-konservatif adayları tekrar etmez; sparse dln ve baseline ayarların sınırlarını da gsterir.


XIII. AřAMA 2 VE BASELINE DEęERLENDİRMESİ

Ařama 2, altı finalist ve  tohumdan oluřan on sekiz satırlık bir tekrarlı-tohum zeti retmiřtir. Her finalist iin seed 42, 123 ve 456 checkpointleri test replay zerinde yeniden deęerlendirilmiřtir. Tek tohumlu seim yapılmıř olsaydı rastgele bařlatma, minibatch sırası veya erken eęitim dalgalanması final politika kararını belirleyebilirdi.  tohum, hesaplama maliyetini sınırlı tutarken bu varyansı grnr yapar; daha fazla tohum istatistiksel gveni artırırđı, fakat final tarama maliyetini doęrusal olarak bytrd.


Final skor, FQE, WIS, ESS, destek ktlesı, klinisyen uyumu, low-support cezası ve gvenlik bayraklarını  tohum ortala-masıyla birleřtirir. FQE fonksiyon yaklařtırmaya dayalı deęer tahmini verir; WIS davranıř politikasına gre aęırlıklandırılmıř gzlemsel kanıt saęlar. İkisini birlikte kullanmak, tek estima-torn yanlılık-varyans profilini final kararına dnřtrmemek

Tablo VI
AŞAMA 1 FINAL-ALTI SEÇİM ÖZETİ.


Sıra	Slot	Ödül	LR	IQL	FQE	WIS	Destek	Uyum
1	top composite	SOFA	konservatif	safe	3.169	8.616	0.965	0.418
2	top composite	SOFA	konservatif	baseline	2.280	7.009	0.973	0.401
3	best sparse	sparse	konservatif	safe	1.954	8.740	0.971	0.411
4	safety support	sparse	baseline	baseline	1.421	6.768	0.973	0.410
5	baseline anchor	sparse	baseline	safe	2.345	8.125	0.963	0.416
6	diversity backfill	sparse	konservatif	baseline	2.012	7.782	0.969	0.407




Şekil 2. Final seçili IQL politikası ve referans baseline gösterimi. Seçili IQL değeri gerçek Aşama 2 değerlendirmesinden, referans baseline çubukları ise rapor artifactinde kullanılan karşılaştırma gösteriminden gelir.



Şekil 4. Final politika analizi için üretilmiş aksiyon dağılımı heatmap'i. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.



Şekil 3. Aşama 2 finalistleri için tekrarlı-tohum FQE değişkenliği. Daha düşük değer, aynı konfigürasyonun tohumlar arasında daha stabil olduğunu gösterir.



Şekil 5. Final seçili IQL politikasının üç tohum için hasta-düzeyi bootstrap WIS güven aralıkları. Güven aralıkları 50 bootstrap resample ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.

içindir [5]. ESS ve destek kütesi olmasaydı, birkaç yüksek ağırlıklı trajectory yüksek WIS değerini güvenilir gösterebilirdi. Klinisyen uyumu olmasaydı politika davranış verisinden gereğinden fazla uzaklaşabilirdi. Bu kurala göre final konfigürasyon SOFA-shaped, konservatif learning-rate ve safe IQL ayarına sahip 'iql_sofa_shaped_conservative_safe' modelidir.

XIV. AKSIYON VE GÜVENLİK DIAGNOSTİKLERİ

Value metriği tek başına klinik politika güvenliği göstermez. Bir politika iyi FQE üretebilir, fakat gözlemsel veride nadir

görülen sıvı-vazopresör kombinasyonlarına kayabilir. Bu yüzden action heatmap, support mass, low-support rate, klinisyen uyumu ve aksiyon entropisi aynı anda okunur.

Diagnostik okuma somut sorulara dayanır: politika sürekli yüksek sıvı veya yüksek vazopresör mü öneriyor, 'no treatment' kutusuna çöküyor mu, düşük destekli aksiyonları sık seçiyor mu, yüksek riskli alt gruplarda uyarılar artıyor mu, reward variant değişince aksiyon dağılımı dramatik biçimde de-

Tablo VII
AŞAMA 2 ÜÇ-TOHUM FINALIST DEĞERLENDİRMESİ. SKOR, FQE/WIS/ESS/DESTEK/UYUM VE LOW-SUPPORT BİLEŞİK SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	Destek	Uyum
1	SOFA konservatif safe	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif baseline	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif safe	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif baseline	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline safe	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline baseline	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo VIII
KAZANAN KONFIGÜRASYONUN TEST DIAGNOSTİKLERİ. WIS GÜVEN ARALIĞI 50 HASTA-DÜZEYİ BOOTSTRAP RESAMPLE İLE HESAPLANMIŞTIR.

Metrik	Sonuç
FQE	2.848
WIS	8.203
WIS 95% CI	4.963–10.817
ESS	29.410
Davranışsal destek kütleli	0.991
Klinisyen tam-kutu uyumu	0.414
Klinisyen uyumsuzluğu	0.586
Desteklenmeyen aksiyon sapması	0.009

gösteriyor mu? Protokol bu sorular için clinician action distribution, IQL policy action distribution, difference heatmap, low-support action rate, clinician agreement by subgroup, high-risk subgroup policy action frequency, training loss curves, validation metric curves, reward variant boxplot, LR regime comparison ve expectile/temperature comparison grafiklerini artifact olarak üretir.

Aşama 2 finalistlerinde destek kütleli 0.990–0.991, klinisyen exact-bin uyumu 0.401–0.418 aralığındadır. Kazanan politikanın tam-kutu uyumu 0.414’tür; yani kararların 0.586’lık kısmı klinisyen davranışıyla birebir aynı değildir. Buna rağmen desteklenmeyen aksiyon sapması 0.009’da kalır. Bu ayrım önemlidir: politika klinisyeni kopyalamaz, fakat çoğu sapma veri desteği bulunan komşu tedavi yörüngelerinde kalır. ESS ise tüm finalistlerde 50 eşliğinin altındadır. Bu uyarı saklanırsa rapor, az sayıda etkili trajectory’nin taşıdığı WIS tahminini kesin sonuç gibi sunar. Bu nedenle final karar “klinik üstünlük” değil, destek kısıtı belirtilmiş retrospektif OPE sonucudur.

XV. YENİDEN ÜRETİLEBİLİRLİK VE TEKNOLOJİ YİĞİNİ

İş akışı protokoldeki ana boşlukları kapatır: final IQL sweep runner, 18 konfigürasyonlu grid, workflow seviyesinde orkestrasyon, presweep audit, final-altı seçim mantığı, tekrarlı-tohum Aşama 2 birleştirmesi, baseline karşılaştırması ve final grafik raporları. Artifact seti presweep audit sonucunu, Aşama 1 seçim tablosunu, Aşama 2 seed özetini, final metrics bundle’ı, baseline karşılaştırmasını ve beş grafik çıktısını içerir. Aşama 2 değerlendirilmesi 18 finalist-tohum satırı olarak saklanır.

Teknoloji yığını Python ve ‘uv’ tabanlı ortam yönetimi, yüksek hızlı ‘Polars’ ve ‘PyArrow’ tabanlı Parquet veri dönüşümü, ‘PyTorch’ ve özelleştirilmiş ‘d3rlpy’ tabanlı RL eğitimi, ‘Hydra’ konfigürasyon yönetimi, ‘MLflow’ deney takibi ve

IEEE LaTeX raporlamasından oluşur. Device-agnostic tasarım sayesinde eğitim kodu MPS, CUDA veya otomatik cihaz seçimiyle çalışabilir. Bu altyapı ayrıştırılmasaydı deney sonuçları belirli bir donanıma veya elle değiştirilmiş konfigürasyonlara bağımlı hale gelirdi.

Her run için git commit hash, config dosyası, reward variant, LR regime, expectile, temperature, seed, dataset path, metadata path, split manifest seed, action bin artifact, training logs, checkpoint path, evaluation output ve figure paths kaydedilmiştir. Run isimlendirme şablonu reward, LR rejimi, IQL ayarı ve seed bilgisini birlikte taşıyan ‘iql_reward_lr_setting_seed’ biçimindedir. Örneğin SOFA-shaped, actor-conservative, baseline ve seed 42 bilgileri aynı run adında saklanır. Bu sözleşme tutulmasaydı sonradan hangi checkpointin hangi veri ve konfigürasyonla üretildiği izlenemezdi.

XVI. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve observationaldır; öğrenilen politika yatak başı tedavi önerisi değildir. State vektörü gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen confounding etkilerini tam kapsamaz. Gerçek klinik süreç POMDP’ye daha yakındır; model hekimin tüm yatak başı bilgisini görmez. Clinician action’ları da confounding taşıyıcı: daha ağır hastalara daha agresif vazopresör verilmesi, tedaviyi zararlı gösterebilir veya yanlış fayda atfı üretebilir.

MIMIC-IV verisi PhysioNet credentialing, CITI training ve Data Use Agreement kapsamındaki yükümlülüklerle tabidir; hasta verileri de-identified olsa da raporlama akademik ve etik sınırlar içinde kalmalıdır. FQE ve WIS prospektif klinik kanıt değildir; fonksiyon yaklaşımı, behavior policy tahmini, destek varsayımları ve variance profiline bağlıdır. ESS değerinin 50 eşliğinin altında kalması ve bootstrap resample sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.

XVII. GELECEK ARAŞTIRMA YÖNLERİ

Bu çalışmanın sonraki adımı daha büyük bir grid çalıştırmak değil, belirsizliği politika güncellemesine sokmaktır. İlk yön dinamik expectile kalibrasyonudur. Yoğun destekli bölgelerde τ yükseltilerek daha agresif politika iyileştirme yapılabilir; seyrek ve belirsiz bölgelerde τ 0.5’e yaklaştırılarak davranış klonlamasına yakın, daha güvenli güncelleme seçilebilir.

İkinci yön, sparse terminal mortalite sinyali daha hızlı taşımak için adaptive multi-step trace blending’dir. Peng’in $Q(\lambda)$ fikri, yüksek destekli trajectory bölümlerinde büyük λ , belirsiz geçişlerde küçük λ kullanacak şekilde klinik veriyi

uyarlanabilir. Üçüncü yön, state-space manifold regularization için generative world-model veya diffusion tabanlı trajectory simülatörleridir. Böyle bir model, veri setinde seyrek görülen ama klinik olarak gerçekçi sınır durumları sentezleyerek value fonksiyonuna güvenli marjlar öğretebilir. Bu genişlemeler aynı ilkeyi korumalıdır: önce veri desteği ve leakage-free değerlendirme, sonra politika iyileştirmesi.

XVIII. SONUÇ

IQL final tarama iş akışı, sepsis dozaj politikalarını tek seferlik bir model çıktısı olarak değil, denetlenebilir bir offline değerlendirme protokolü olarak ele alır. Kohort seçimi, zaman penceresi, state/action/reward mühendisliği, leakage-free preprocessing, IQL eğitimi, hiperparametre grid'i, Aşama 1 finalist seçimi ve Aşama 2 çoklu-tohum değerlendirmesi aynı raporda izlenebilir hale gelir. Aşama 0 denetimi geçilmiştir; Aşama 1 altı destek-duyarlı finalist üretmiştir. Aşama 2 sonucunda final konfigürasyon 'iql_sofa_shaped_conservative_safe' olarak seçilir. Model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 verir; ancak ESS=29.41 ile güvenilirlik eşliğinin altındadır. Bu nedenle sonuç klinik performans kanıtı değil, metodolojik ve retrospektif OPE kanıtıdır.

KAYNAKLAR

- [1] I. Kostrikov, A. Nair, and S. Levine, "Offline reinforcement learning with implicit q-learning," in *International Conference on Learning Representations*, 2022.
- [2] A. Kumar, A. Zhou, G. Tucker, and S. Levine, "Conservative q-learning for offline reinforcement learning," in *Advances in Neural Information Processing Systems*, 2020.
- [3] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, "The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care," *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [4] A. Raghu, M. Komorowski, L. A. Celi, P. Szolovits, and M. Ghassemi, "Continuous state-space models for optimal sepsis treatment: a deep reinforcement learning approach," in *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 2017, pp. 147–163.
- [5] O. Gottesman, F. Johansson, M. Komorowski, A. Faisal, D. Sontag, F. Doshi-Velez, and L. A. Celi, "Guidelines for reinforcement learning in healthcare," *Nature Medicine*, vol. 25, no. 1, pp. 16–18, 2019.
- [6] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, "Mimic-iv, a freely accessible electronic health record dataset," *Scientific Data*, vol. 10, no. 1, p. 1, 2023.
- [7] L. Evans, A. Rhodes, W. Alhazzani, M. Antonelli, C. M. Coopersmith, C. French, F. R. Machado, L. McIntyre, M. Ostermann, H. C. Prescott *et al.*, "Surviving sepsis campaign: International guidelines for management of sepsis and septic shock 2021," *Critical Care Medicine*, vol. 49, no. 11, pp. e1063–e1143, 2021.
- [8] M. Singer, C. S. Deutschman, C. W. Seymour, M. Shankar-Hari, D. Annane, M. Bauer, R. Bellomo, G. R. Bernard, J.-D. Chiche, C. M. Coopersmith *et al.*, "The third international consensus definitions for sepsis and septic shock (sepsis-3)," *JAMA*, vol. 315, no. 8, pp. 801–810, 2016.