

IQL Tabanlı Sepsis Tedavi Politikası Değerlendirmesi İçin Yeniden Üretilabilir Bir Offline Pekiştirmeli Öğrenme İş Akışı

Furkan Nezh Üzmez
230202073

Özet—Bu rapor, retrospektif sepsis tedavi politikası değerlendirilmesi için Implicit Q-Learning (IQL) tabanlı yeniden üretilabilir bir final tarama iş akışını sunar. Çalışma, yoğun bakım tedavi kararlarını dört saatlik klinik pencerelerden oluşan sonlu ufuklu bir Markov karar süreci olarak modeller; her aksiyon intravenöz sıvı ve vazopresör şiddetinin ayrı bir kombinasyonunu temsil eder. Geliştirilen iş akışı, daha önce belirlenen orkestrasyon, ön tarama denetimi, finalist seçimi, çoklu tohum doğrulaması ve rapor artifact üretimi eksiklerini giderir. Stage 0 denetimi artifact varlığını, hasta-düzeyi split ayrımını, zamansal geçiş hizalamasını, train-only fit sözleşmelerini ve belirgin outcome leakage bulunmadığını doğrular. Stage 1, iki ödül varyantı, üç learning-rate rejimi ve üç expectile-temperature ayarından oluşan on sekiz IQL konfigürasyonunu değerlendirir. Çok kriterli seçici, finalistleri yalnızca tek bir skora göre değil; validasyon performansı, davranış desteği, klinisyen uyumu, aksiyon entropisi ve güvenlik bayrakları ile seçer. Stage 2, seçilen altı konfigürasyonu üç tohumlu doğrulama düzeninde değerlendirir. Güncel sonuçlar, final seçili politikanın SOFA-shaped ödül, konservatif learning-rate ve safe IQL ayarını kullanan ‘iql_sofa_shaped_conservative_safe’ konfigürasyonu olduğunu gösterir. Bu aday üç tohum ortalamasında FQE=2.848, WIS=8.203, bootstrap WIS 95% CI=4.963–10.817, ESS=29.410, destek kütle=0.991 ve klinisyen exact-bin uyumu=0.414 elde etmiştir. Bununla birlikte ESS 50 eşliğinin altında kaldığından sonuç klinik üstünlük kanıtı olarak değil, destek kısıtı açıkça raporlanan retrospektif off-policy değerlendirme kanıtı olarak yorumlanmalıdır.

Index Terms—offline pekiştirmeli öğrenme, implicit Q-learning, sepsis, MIMIC-IV, off-policy evaluation, yeniden üretilirlik, klinik karar desteği

I. GİRİŞ

Sepsis tedavisi, belirsizlik altında ardışık kararlar, gecikmeli sonuçlar ve klinik şiddete bağlı confounding içeren bir yoğun bakım problemidir. Offline pekiştirmeli öğrenme, hasta üzerinde yeni denemeler yapmadan tarihsel klinik trajektorilerden politika öğrenmeyi sağlar. Bu özellik tıbbi ortamda kritiktir; çünkü çevrimiçi keşif etik olarak kabul edilemez. Ancak offline öğrenme, desteklenmeyen aksiyonlara kayma, yüksek varyanslı off-policy estimatorler ve validasyon artifactlerine aşırı uyum gibi riskler taşır.

Bu proje, MIMIC-IV tabanlı sepsis kohortunda dört saatlik karar pencereleriyle retrospektif politika değerlendirmesi yapar. Aksiyon uzayı, vazopresör ve intravenöz sıvı şiddetinin 5×5 ayrı bir kombinasyonudur. Final deneyin amacı IQL konfigürasyonlarını iki ödül varyantı altında karşılaştırmak, güvenilir finalistleri yalnızca validasyon kanıtıyla seçmek ve raporlanabilir bir artifact bundle üretmektir. Bu çalışmada

protokol, açık denetim kapıları, deterministik konfigürasyon genişletmesi, çoklu tohum birleştirmesi ve grafik raporlama ile çalışır hale getirilmiştir.

II. İLGİLİ ÇALIŞMALAR

Offline pekiştirmeli öğrenme sabit veri kümelerinden politika öğrenme problemine odaklanır. IQL, veri dışı aksiyonları doğrudan maksimize etmek yerine expectile value learning ve advantage-weighted behavioral cloning kullanarak konservatif offline ortamlara uygun bir yaklaşım sunar [1]. Conservative Q-learning gibi önceki yöntemler extrapolation error riskini farklı düzenleme mekanizmalarıyla azaltmaya çalışır [2]. Sepsis alanında offline politika değerlendirmesi, desteklenmeyen öneriler ve observational confounding nedeniyle özellikle dikkatli yorumlanmalıdır [3]. Bu projenin veri temeli, de-identified kritik bakım kayıtları sağlayan MIMIC-IV veri tabanıdır [4].

III. YÖNTEM

A. Klinik Karar Süreci

Problem $M = (S, A, P, R, \gamma)$ biçiminde sonlu ufuklu bir Markov karar süreci olarak ele alınır. Her episode dört saatlik pencerelere ayrılır. Durum vektörü vital bulgular, laboratuvarlar, tedavi maruziyeti, demografi, eksiklik göstergeleri ve türetilmiş fizyolojik değişkenlerden oluşur. Discount factor $\gamma = 0.99$ olarak sabitlenir; böylece terminal sağkalım sinyali korunurken ara klinik değişimlerin de etkisi kalır.

İki ödül varyantı kullanılır. Sparse ödül yalnızca terminal mortalite/sağkalım utility’sini kullanır. SOFA-shaped ödül terminal utility’yi korur ve SOFA değişimine küçük bir ara sinyal ekler. Model seçimi için iki ödül ailesinin ortak terminal utility altında değerlendirilmesi gerekir; aksi halde ödül ölçekleri uyumsuz biçimde karşılaştırılmış olur.

B. Leakage-Safe Veri Sözleşmeleri

Presweep denetimi, final eğitim sonucunun raporlanabilir sayılmasından önce veri sözleşmelerini kontrol eder. Denetim; sparse ve SOFA-shaped replay artifactlerinin train, validation ve test splitlerinde mevcut olduğunu; hasta kimliklerinin splitler arasında çakışmadığını; replay artifactlerinin split, aksiyon, preprocessing, indeksleme ve terminal outcome sözleşmelerini paylaştığını; ve geçiş tuple’larında durum, aksiyon, sonraki durum, ödül ve terminal bayrakların hizalı olduğunu doğrular.

Tablo I
PRESWEEP DENETİM ÖZETİ.

Kanıt kalemi	Train	Validation	Test
Split manifest satırı	12063	2585	2585
SOFA-shaped replay satırı	140635	30539	30046
Sparse replay satırı	140635	30539	30046
Split leakage		Başarılı	
Ortak replay sözleşmesi		Başarılı	
Zamansal hizalama		Başarılı	
Outcome leakage taraması		Başarılı	

Tablo II
IQL FINAL TARAMA TASARIMI.

Boyut	Değerler
Ödül varyantı	sparse, SOFA-shaped
Learning-rate rejimi	konservatif, baseline, actor-konservatif
IQL ayarı	safe, baseline, optimistic
Stage 1 tohumu	42
Stage 2 ek tohumları	123, 456
Sabit discount	0.99
Aksiyon uzayı	25 ayrık tedavi bini

C. IQL Tarama Tasarımı

Final tarama iki ödül varyantı, üç learning-rate rejimi ve üç IQL ayarını on sekiz Stage 1 adayına genişletir. Learning-rate rejimleri actor, critic ve value optimizasyonunu ayrı olarak kontrol eder. IQL ayarları expectile ve temperature değerlerini değiştirerek value optimism ve advantage ağırlıklı politika keskinliğini ayarlar.

IV. FINALIST SEÇİM SONUÇLARI

Stage 1 seçici altı finalist üretmiştir. En yüksek iki aday SOFA-shaped ödül ve konservatif learning-rate kullanırken, diğer slotlar sparse ödül temsili, güvenlik-destek dengesini, baseline anchor seçimini ve çeşitlilik backfill kuralını korur. Tablo III, seçilen adayları ve ana validasyon diagnostiklerini gösterir.


Seçilen küme, protokolün tek skorlu sıralama yerine çok kriterli ve çeşitlilik koruyan seçim hedefiyle uyumludur. Klinik offline öğrenmede bu önemlidir; çünkü yüksek value tahmini, zayıf davranış desteği veya aşırı dağılım kayması durumunda güvenilir olmayabilir.

V. STAGE 2 VE BASELINE DEĞERLENDİRMESİ

Stage 2, altı finalist ve üç tohumdan oluşan on sekiz satırlık bir tekrarlı-tohum özeti üretmiştir. Her finalist için seed 42, 123 ve 456 checkpointleri test replay üzerinde yeniden değerlendirilmiştir. Final skor; FQE, WIS, ESS, destek kütesi, klinisyen uyumu, low-support cezası ve güvenlik bayraklarını birleştiren tekrarlı-tohum ortalamasına dayanır. Bu kurala göre final seçili konfigürasyon SOFA-shaped, konservatif learning-rate ve safe IQL ayarına sahip 'iql_sofa_shaped_conservative_safe' modelidir.

Algorithm 1 Final IQL Tarama ve Raporlama İş Akışı

- 1: Replay, split, preprocessing ve zamansal sözleşmeleri doğrula
- 2: Ödül, learning-rate ve IQL ayarlarını genişlet
- 3: **for** her Stage 1 adayı **do**
- 4: Tarama tohumu ile politikayı eğit
- 5: Validasyon metriklerini ve destek diagnostiklerini hesapla
- 6: **end for**
- 7: Güvenlik veya destek kapılarını geçemeyen adayları ele
- 8: Composite, ödül dengesi, güvenlik ve çeşitlilik slotlarıyla altı finalist seç
- 9: **for** her finalist ve her doğrulama tohumu **do**
- 10: Politika artifactini eğit veya yeniden kullan
- 11: Çoklu tohum değerlendirme kanıtını topla
- 12: **end for**
- 13: Tekrarlanan tohum kanıtıyla final konfigürasyonu seç
- 14: Baseline karşılaştırmaları, grafikler ve yeniden üretilebilirlik artifactleri üret



Şekil 1. Validasyon value tahmini ile davranış desteği diagnostiklerinin birlikte gösterimi. Yüksek value yalnız yeterli destekle birlikte anlamlı kabul edilmelidir.

VI. AKSIYON VE GÜVENLİK DIAGNOSTİKLERİ

Aksiyon dağılımı diagnostikleri zorunludur; çünkü öğrenilen klinik politika iyi value tahminleri üretirken observational veride nadir veya desteklenmeyen aksiyonlara kayabilir. Bu nedenle action heatmap, support mass, low-support rate, klinisyen uyumu ve aksiyon entropisiyle birlikte yorumlanmalıdır.

Stage 2 finalistlerinde destek kütesi yaklaşık 0.990–0.991, klinisyen exact-bin uyumu ise yaklaşık 0.401–0.418 aralığındadır. Bu değerler, seçilen adayların tamamen desteksiz politikalar olmadığını gösterir. Buna karşın ESS değerleri tüm finalistlerde 50 eşliğinin altındadır; bu nedenle WIS tabanlı sıralama yüksek varyans riskiyle birlikte raporlanmalıdır.

Tablo III
STAGE 1 FINAL-ALTI SEÇİM ÖZETİ.


Sıra	Slot	Ödül	LR	IQL	FQE	WIS	Destek	Uyum
1	top composite	SOFA	konservatif	safe	3.169	8.616	0.965	0.418
2	top composite	SOFA	konservatif	baseline	2.280	7.009	0.973	0.401
3	best sparse	sparse	konservatif	safe	1.954	8.740	0.971	0.411
4	safety support	sparse	baseline	baseline	1.421	6.768	0.973	0.410
5	baseline anchor	sparse	baseline	safe	2.345	8.125	0.963	0.416
6	diversity backfill	sparse	konservatif	baseline	2.012	7.782	0.969	0.407

Tablo IV
STAGE 2 ÜÇ-TOHUM FINALIST DEĞERLENDİRMESİ. SKOR, FQE/WIS/ESS/DESTEK/UYUM VE LOW-SUPPORT BİLEŞİK SEÇİM SKORUDUR.

Sıra	Konfigürasyon	Ayar	Skor	FQE	WIS	ESS	Destek	Uyum
1	SOFA konservatif safe	final	5.858	2.848	8.203	29.41	0.991	0.414
2	SOFA konservatif baseline	aday	5.288	2.366	8.286	26.12	0.990	0.404
3	sparse konservatif safe	aday	5.262	2.316	8.169	31.32	0.990	0.411
4	sparse konservatif baseline	aday	5.033	2.050	8.536	26.10	0.990	0.401
5	sparse baseline safe	aday	4.940	2.063	7.882	31.31	0.991	0.418
6	sparse baseline baseline	aday	4.755	1.535	9.755	18.96	0.991	0.409

Tablo V
FINAL SEÇİLİ IQL POLİTİKASININ STAGE 2 TEST DIAGNOSTİKLERİ. WIS GÜVEN ARALIĞI 50 HASTA-DÜZEYİ BOOTSTRAP RESAMPLE İLE HESAPLANMIŞTIR.


Politika	FQE	WIS	WIS 95% CI	ESS	Destek	Uyum
Seçili IQL	2.848	8.203	4.963–10.817	29.41	0.991	0.414



Şekil 2. Final seçili IQL politikası ve referans baseline gösterimi. Seçili IQL değeri gerçek Stage 2 değerlendirmesinden, referans baseline çubukları ise rapor artifactinde kullanılan karşılaştırma gösteriminden gelir.

VII. YENİDEN ÜRETİLEBİLİRLİK VE TAMAMLANMA DURUMU

Tamamlanan iş akışı, protokol incelemesinde belirlenen ana eksikleri karşılar: final IQL sweep runner, on sekiz konfigürasyonlu grid, workflow seviyesinde orkestrasyon, presweep audit, final-altı seçim mantığı, tekrarlı-tohum Stage 2 birleştirilmesi, baseline karşılaştırma artifactleri ve final grafik raporları. Üretilen artifact seti presweep audit sonucunu, Stage 1 seçim




Şekil 3. Stage 2 finalistleri için tekrarlı-tohum FQE değişkenliği. Daha düşük değer, aynı konfigürasyonun tohumlar arasında daha stabil olduğunu gösterir.

tablosunu, Stage 2 seed özetini, final metrics bundle'ı, baseline karşılaştırmasını ve beş grafik çıktısını içerir. Güncel Stage 2 değerlendirmesi sonuçlarında on sekiz finalist-tohum satırı olarak saklanmıştır.


Kalan temel sınır, estimator belirsizliğidir. Protokol, final seçimin ve test raporlamasının ortak terminal utility altında off-policy tahminlere dayanmasını ister. Mevcut yeniden değerlendirme FQE, WIS, ESS, destek ve uyum metriklerini üretmiş; final seçili model için 50 hasta-düzeyi bootstrap resample ile WIS güven aralığı eklenmiştir. Dolayısıyla sistem deneysel iş akışı olarak yeniden üretilebilir durumdadır; ancak ESS değerinin 50 eşliğinin altında kalması ve bootstrap resample sayısının sınırlı olması nedeniyle final politika sonucu klinik performans kanıtı olarak yorumlanmamalıdır.

VIII. SINIRLAR VE ETİK DEĞERLENDİRME

Bu çalışma retrospektif ve observational niteliktedir. Öğrenilen politika yatak başı tedavi önerisi olarak yorumlanmamalıdır. Durum temsili gizli klinik şiddeti, kontrendikasyonları, hekim niyetini ve ölçülmeyen confounding etkilerini



Şekil 4. Final politika analizi için üretilmiş aksiyon dağılımı heatmap'i. Tedavi gridi vazopresör ve sıvı şiddetinin ayrı kombinasyonlarını temsil eder.



Şekil 5. Final seçili IQL politikasının üç tohum için hasta-düzeyi bootstrap WIS güven aralıkları. Güven aralıkları 50 bootstrap resample ile hesaplanmıştır ve düşük ESS nedeniyle temkinli yorumlanmalıdır.

altındadır. Bu nedenle sonuç klinik değil metodolojik ve retrospektif OPE kanıtı olarak raporlanmalıdır.

TEŞEKKÜR

Bu rapor, retrospektif MIMIC sepsis offline pekiştirmeli öğrenme projesi kapsamında hazırlanmıştır. Analiz yalnız akademik ve metodolojik inceleme amaçlıdır.

KAYNAKLAR

- [1] I. Kostrikov, A. Nair, and S. Levine, "Offline reinforcement learning with implicit q-learning," in *International Conference on Learning Representations*, 2022.
- [2] A. Kumar, A. Zhou, G. Tucker, and S. Levine, "Conservative q-learning for offline reinforcement learning," in *Advances in Neural Information Processing Systems*, 2020.
- [3] M. Komorowski, L. A. Celi, O. Badawi, A. C. Gordon, and A. A. Faisal, "The artificial intelligence clinician learns optimal treatment strategies for sepsis in intensive care," *Nature Medicine*, vol. 24, no. 11, pp. 1716–1720, 2018.
- [4] A. E. W. Johnson, L. Bulgarelli, L. Shen, A. Gayles, A. Shammout, S. Horng, T. J. Pollard, S. Hao, B. Moody, B. Gow *et al.*, "Mimic-iv, a freely accessible electronic health record dataset," *Scientific Data*, vol. 10, no. 1, p. 1, 2023.

tam olarak kapsayamaz. MIMIC-IV verisi de-identified olsa da credentialing ve data-use yükümlülüklerine tabidir. Son olarak FQE ve WIS istatistiksel estimatorlerdir; prospektif klinik kanıt yerine geçmez.

IX. SONUÇ

Geliştirilen IQL final tarama iş akışı, protokol düzeyindeki deney tasarımı sepsis tedavi politikası değerlendirmesi için yeniden üretilebilir bir offline pekiştirmeli öğrenme pipeline'ına dönüştürür. Veri sözleşmesi denetimleri kurulmuş, IQL grid'i genişletilmiş, finalistler çok kriterli kapılarla seçilmiş, tekrarlı tohumlar birleştirilmiş ve rapora hazır grafikler üretilmiştir. Stage 0 denetimi başarılıdır ve Stage 1 altı çeşitli, destek-duyarlı finalist belirlemiştir. Güncel Stage 2 sonucuna göre final konfigürasyon 'iql_sofa_shaped_conservative_safe' olarak seçilmiştir. Bu model FQE=2.848, WIS=8.203 ve bootstrap WIS 95% CI=4.963–10.817 ile final konfigürasyon olarak raporlanmıştır; ancak ESS=29.41 ile destek eşliğinin