

Destek Sınırlı Klinik Koşullar Altında Sepsis Dozaj Politikaları İçin Orkestre Edilmiş Bir Çevrimdışı Pekıştirmeli Öğrenme İş Akışı

Medikal Bilişim Kıdemli Yapay Zeka Araştırmacısı

Abstract—Bu çalışma, MIMIC-IV veri seti üzerinde klinik sepsis dozaj politikalarının yeniden üretilebilir şekilde değerlendirilmesi amacıyla orkestre edilmiş bir çevrimdışı pekıştirmeli öğrenme (offline reinforcement learning) çerçevesi sunmaktadır. Yoğun bakım ünitesindeki terapötik müdahaleleri dört saatlik aralıklarla sonlu ufuklu bir Markov karar süreci olarak modelleyerek, intravenöz sıvı ve vazopresör dozajlarının ortak kombinasyonunu temsil eden 25 boyutlu bir aksiyon uzayı tanımlıyoruz. Doğrulama aşamasında aşırı uyum (overfitting) ve veri sızıntısı (data leakage) gibi kronikleşen sorunları çözmek amacıyla, hasta düzeyinde katı izolasyonu, zamansal yörünge hizalamasını ve veri bütünlüğü sınırlandırmalarını doğrulayan bir Aşama 0 Ön Tarama Denetim Çerçevesi (Presweep Auditing Framework) geliştirilmiştir. Aşama 1, ödül yapılarını, öğrenme oranlarını ve ekspektik-sıcaklık sınırlarını birbirinden ayıran 18 farklı konfigürasyondan oluşan bir hiperparametre taraması yürütür. Sadece tekil metrik sıralamalarına güvenmek yerine, Aşama 2 çoklu tohum doğrulaması için altı farklı finalist politikayı belirlemek üzere çok kriterli bir seçim protokolü uygulamaktayız. SOFA skoruna göre şekillendirilmiş bir ödül işlevi, muhafazakar öğrenme oranları ve güvenli örtük Q-öğrenme (safe implicit Q-learning) ekspektilleri kullanan konfigürasyon ('iql_sofa_shaped_conservative_safe'), 2.848 ortalama Uydurulmuş Q-Değerlendirmesi (FQE), 8.203 Ağırlıklı Önem Örneklemesi (WIS) değeri (%95 bootstrap güven aralığı: 4.963–10.817) ve 0.991 destek kütleli üretirek en kararlı politika olarak öne çıkmaktadır. Önemli bir husus olarak, etkin örneklem büyüklüğü (ESS) standart güvenilirlik eşliğinin altına düştüğü için ($29.410 < 50$), bu bulguları klinik üstünlük kılavuzları olarak değil, kesin bir şekilde veri desteğiyle sınırlandırılmış politika dışı retrospektif değerlendirme (retrospective off-policy evaluation) kanıtları olarak sunuyoruz.

Index Terms—Çevrimdışı pekıştirmeli öğrenme, örtük Q-öğrenme, sepsis, MIMIC-IV, politika dışı değerlendirme, klinik karar destek sistemleri.

I. Giriş

Sepsis, yoğun bakım ünitelerinde (YBÜ) akut organ yetmezliğine yol açan ve vücutun enfeksiyona karşı geliştirdiği kontrolsüz sistemik yanıtla karakterize edilen birincil mortalite nedenidir.[1] Resüsitasyon protokolleri genellikle intravenöz sıvılar ve vazopresörlerin karmaşık ve ardışık dozajlanmasını gerektirir; bu tedavilerin hastanın değişen fizyolojik profiline göre dinamik olarak ayarlanması şarttır.[2] Ancak, fizyolojik heterojenlik, tedaviye verilen yanıtların gecikmeli ortaya çıkması ve klinisyen kararlarındaki karıştırıcı değişkenler (confounding) nedeniyle optimal tedavi yörüngelerini belirlemek oldukça güçtür. Pekıştirmeli öğrenme (reinforcement learning), dinamik tedavi rejimlerini keşfetmede önemli bir potansiyele sahip olsa da, kritik bakım süreçlerinde gerçek zamanlı (online)

keşif süreçleri etik açıdan kabul edilemez.[3, 4] Bu engel, politika optimizasyonunun tamamen MIMIC-IV gibi retrospektif gözlemsel veri tabanlarına dayanmasını gerektiren çevrimdışı pekıştirmeli öğrenmeyi (offline reinforcement learning) zorunlu kılmaktadır.[4, 5]

Çevrimdışı pekıştirmeli öğrenme etik avantajlarına rağmen, dağılım kayması (distribution shift), dağılım dışı (out-of-distribution) değer ekstrapolasyonu ve doğrulama aşamasında aşırı uyum gibi ciddi teknik engellerle karşı karşıyadır.[6] Politika optimizasyonu sabit veri setleri üzerinde gerçekleştirildiğinde, standart değer tabanlı algoritmalar, eğitim veri setinde zayıf temsil edilen aksiyonların durum-aksiyon değerlerini (Q-değerlerini) aşırı tahmin etme eğilimindedir.[6] Bu çalışma, matematiksel güvenliği sağlamak, yeniden üretilebilir kohort tanımları oluşturmak ve katı klinik veri desteği sınırlamaları altında çevrimdışı örtük Q-öğrenme (implicit Q-learning) politikalarının çok kriterli değerlendirilmesini mümkün kılmak amacıyla orkestre edilmiş bir iş akışı sunmaktadır.[5]

II. İlgili Çalışmalar ve Arka Plan

Mevcut literatürü taksonomik bir yaklaşımla ele alıyoruz. Sepsis tedavisinde klinik karar verme süreçleri, tarihsel olarak ayrıık pekıştirmeli öğrenme paradigmalarıyla modellenmiştir. Komorowski ve meslektaşları, "AI Clinician" modelini tabular bir Markov karar süreci kullanarak gerçekleştirmiş ve optimal dozaj stratejilerinin doğrudan retrospektif elektronik sağlık kayıtlarından türetilebileceğini göstermişlerdir.[3] Bu formülasyon, Raghu ve arkadaşları tarafından derin sinir ağları kullanılarak sürekli durumlara genişletilmiş ve hasta fizyolojisi daha yüksek bir doğrulukla yakalanmıştır.[7] Bu algoritmik gelişmelere rağmen, Gottesman ve arkadaşları tarafından formüle edilen sağlık hizmetlerinde pekıştirmeli öğrenme kılavuzları, gözlemsel pekıştirmeli öğrenmenin karıştırıcı etkenlere, tahminci varyansına ve değerlendirme yanlılığına karşı son derece savunmasız olduğu konusunda uyarıda bulunmakta ve sistemik bir doğrulama yapılmadan doğrudan klinik uygulamaya geçirilmesini engellemektedir.[4]

Dağılım kaymasına karşı geliştirilen algoritmik önlemler, açık düzenleme (explicit regularization) ve örtük değer öğrenimi (implicit value learning) olarak ikiye ayrılabilir. Muhafazakar Q-Öğrenme (Conservative Q-Learning - CQL), dağılım dışı aksiyonların durum-aksiyon değerlerini açıkça cezalandırarak eleştirmeni (critic) veri setinde düşük desteğe sahip bölgeleri eksik tahmin

etmeye zorlar.[8] Teorik olarak güçlü olmasına rağmen, CQL manuel olarak kalibre edilmesi gereken ağır bir düzenleme parametresi gerektirir.[8] Hatalı kalibrasyon riski, yüksek düzeyde heterojenlik gösteren hasta popülasyonlarında nadir fakat klinik açıdan hayati olan kurtarma müdahalelerini agresif bir şekilde bastırabilir. Buna karşılık, Örtük Q-Öğrenme (Implicit Q-Learning - IQL), ekspektik regresyonu yardımıyla örtük bir değer işlevi oluşturarak dağılım dışı aksiyon sorgulamalarından tamamen kaçınır.[9] Değer işlevini yalnızca veri setinde mevcut olan aksiyonlar üzerinden değerlendiren IQL, gözlemlenmemiş geçişleri parametreleştirme veya düzenleme ihtiyacını ortadan kaldırarak ekstrapolasyon hatalarını azaltır.[6] Bu strateji, tarihsel dağılımda bulunmayan klinik yolları keşfetmeme ödünlemesini kabul eder ve güvenli resüsitasyon kılavuzlarıyla uyumluluk gösterir.[1, 5]

III. Matematiksel Çerçeve ve Sepsis MDP Formülasyonu

Klinik karar süreci, $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$ bileşenlerinden oluşan sonlu ufuklu, iskonto edilmiş bir Markov karar süreci olarak modellenmiştir.[5, 10] Bir hastanın yoğun bakım kalış süresi, dört saatlik ayrık karar pencerelerine bölünmüştür.[5] Bu aralık, bilinçli bir klinik tavidir. Daha kısa aralıklar gürültülü fizyolojik dalgalanmalara ve seyrek ölçümlere yol açarken; daha uzun aralıklar akut fizyolojik yanıtları ortalama katarak dinamik ilaç ayarlamalarının klinik etkisini gölgelemektedir.

Durum vektörü $s \in \mathcal{S}$; demografik verileri, yaşamsal bulguları, laboratuvar ölçümlerini, tedavi maruziyetlerini ve eksik veri göstergelerini (missingness indicators) içerir.[5] Eksik veri göstergelerinin modele dahil edilmesi analitik açıdan temel bir gereksinimdir. Klinisyenler laboratuvar testlerini hastanın fizyolojik durumundaki kötüleşmeye yanıt olarak istedikleri için, bir ölçümün eksik olması rastgele gerçekleşmez. Eğer bir model, eksik veri göstergesini kaydetmeden normal fizyolojik değerler atarsa (imputation), ajan ölçülmeyen parametreleri sağlıklı durumlarla karıştırır. Bu durum, hekimin belirli fizyolojik yolları izleme yönündeki bilinçli kararında saklı olan örtük risk sinyallerinin kaybolmasına yol açar.[5]

Aksiyon uzayı $\mathcal{A}$, ortak intravenöz sıvı ve vazopresör dozaj yoğunluklarını eşleyen 5×5 boyutlarında ayrık bir ızgara şeklinde yapılandırılmıştır.[5] İskonto faktörünü, intermediate fizyolojik geçişlere olan duyarlılığı korurken terminal hayatta kalma sinyalini muhafaza etmek amacıyla $\gamma = 0.99$ olarak sabitliyoruz.[5] Daha düşük bir iskonto faktörü, ajanın aşırı derecede kısa vadeli organ skoru iyileşmelerine odaklanmasına neden olarak, gecikmeli kardiyovasküler yetmezliğe yol açabilecek agresif tedavileri teşvik edebilir.

Durum-değer işlevi $V_\psi(s)$, veri seti üzerinde ekspektik regresyonu ile tahmin edilir:

$$L_V(\psi) = \mathbb{E}_{(s,a) \sim \mathcal{D}} [L_2^\tau(Q_\theta(s, a) - V_\psi(s))] \quad (1)$$

Burada $L_2^\tau(u) = |\tau - \mathbb{I}(u < 0)|u^2$ asimetrik kaybı temsil eder.[6, 9] $\tau \in (0.5, 1.0)$ parametresi değer iyimserliğini

düzenler.[9] Durum-aksiyon değer işlevi, ortalama karesel Bellman hatası üzerinden eğitilir:

$$L_Q(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} [(r + \gamma V_\psi(s') - Q_\theta(s, a))^2] \quad (2)$$

Hedef politika, avantaj ağırlıklı regresyon (advantage-weighted regression) yoluyla çıkarılır:

$$L_\pi(\phi) = \mathbb{E}_{(s,a) \sim \mathcal{D}} [\exp(\beta(Q_\theta(s, a) - V_\psi(s))) \log \pi_\phi(a|s)] \quad (3)$$

Burada β parametresi politika çıkarım sıcaklığını kontrol eder.[9]

İki farklı ödül formülasyonunu karşılaştırıyoruz. Seyrek ödül (sparse reward), hastanın taburculuk durumuna göre ikili bir değer atayarak terminal hayatta kalma faydasını doğrudan yansıtır.[5] Klinik faydayı doğrudan temsil etse de, bu formülasyon uzun karar ufuklarında kredi atama (credit assignment) problemini zorlaştırır. Bunu hafifletmek amacıyla, SOFA-şekilli ödül fonksiyonu, Ardışık Organ Yetmezliği Değerlendirmesi (SOFA) skorundaki adım adım değişimleri dahil eder [5]:

$$R_{\text{SOFA}}(s_t, a_t) = R_{\text{sparse}}(s_t, a_t) + \lambda (\text{SOFA}_{t-1} - \text{SOFA}_t) \quad (4)$$

Burada λ dengeleyici bir katsayıdır. SOFA takibi ara geri bildirimler sağlasa da, güçlü ödül şekillendirme (reward shaping) süreçleri, ajanın nihai hayatta kalma yerine geçici organ skoru iyileşmelerini optimize ettiği patolojik döngülere yol açma riski taşır.

IV. Veri Bütünlüğü ve Ön Tarama Denetimi

Sıkı veri protokolleri oluşturmak amacıyla, analiz süreçlerinden önce veri seti özetlerini doğrulayan bir Aşama 0 Ön Tarama Denetim Çerçevesi (Phase 0 Pre-sweep Auditing Framework) tanımlıyoruz.[5] Retrospektif EHR analizleri, eğitim ve doğrulama setleri arasındaki çakışan hasta yörüngelerinin yapay olarak yüksek değerlendirme skorlarına yol açtığı bölüntü kontaminasyonuna (split contamination) karşı son derece hassastır.[4] Denetim katmanı, hasta kohortlarının hasta düzeyinde izole edildiğini kontrol eder, durum-aksiyon-sonraki durum geçişlerinin zamansal hizalamasını doğrular ve veri sözleşmelerini zorunlu kılar. En önemlisi, özniteliklerin terminal taburculuk durumuna dair herhangi bir gösterge içermediğini doğrulamak için kapsamlı bir sonuç sızıntısı (outcome leakage) taraması gerçekleştirir. Tablo I, Aşama 0 denetim parametrelerini detaylandırmaktadır.

TABLE I
Aşama 0 Ön Tarama Denetimi ve Veri Protokolü Doğrulaması

Denetim Parametresi	Eğitim Seti	Doğrulama Seti	Test
Kohort Bölüntüleri (Hasta Sayısı)	12,063	2,585	2,585
SOFA-Biçimli Deneyim Geçişleri	140,635	30,539	30,539
Seyrek Ödüllü Deneyim Geçişleri	140,635	30,539	30,539
Bölüntü Sızıntı Denetimi	Başarılı	Başarılı	Başarılı
Ortak Deneyim Protokolü	Başarılı	Başarılı	Başarılı
Zamansal Geçiş Hizalaması	Başarılı	Başarılı	Başarılı
Sonuç Sızıntısı Doğrulaması	Başarılı	Başarılı	Başarılı

Doğrulanmış veri setleri kullanılarak Aşama 1 kapsamında 18 adaylı bir hiperparametre taraması gerçekleştirilir (Tablo II). Değer öğrenimi, politika öğrenimi ve ödül gösterimlerini birbirinden bağımsız hale getiriyoruz. Muhafazakar öğrenme oranları, referans ve aktör-muhafazakar rejimlerle birlikte değerlendirilmektedir. Muhafazakar öğrenme oranı kritik öneme sahiptir: eleştirmenin hızlı güncellemelerle dağılım dışı Q-değeri aşırı tahminlerini yaymasını engeller ve politika çıkarımını stabilize eder.[11] Güvenli, referans ve iyimser IQL ayarları, politika çıkarım güvenliğinin sınırlarını haritalamak için ekspektıl τ ve avantaj sıcaklığı β değerlerini çeşitlendirir.[5, 11]

TABLE II
IQL Hiperparametre Tarama Izgarası (Aşama 1)

Hiperparametre Boyutu	Değerlendirilen Ayarlar
Ödül Formülasyonu	Seyrek, SOFA-Biçimli
Öğrenme Oranı Rejimi	Muhafazakar, Referans, Aktör-Muhafazakar
IQL Parametre Kurulumu	Güvenli ($\tau = 0.7, \beta = 0.5$), Referans ($\tau = 0.8, \beta = 1.0$), İyimser ($\tau = 0.9, \beta = 2.0$)
Aşama 1 Referans Tohumu	42
Aşama 2 Doğrulama Tohumları	123, 456
Sabit İskonto Faktörü (γ)	0.99
Aksiyon Uzaı Boyutları	25 Ayrıık Tedavi Kutusu (5×5 Ortak Bugün)

V. Çok Kriterli Seçim ve Sonuçların Tartışılması

Klinik uygulamalarda, politikaları yalnızca en yüksek FQE veya WIS skorlarına göre seçmek tehlikelidir.[4] Yüksek WIS tahminleri, az sayıda yörünge tarafından domine edilebilir; bu durum tahminci varyansını artırır ve etkin örneklem büyüklüğünü (ESS) düşürür.[12] Bu sorunu çözmek için, dengeli bir finalist havuzu oluşturmak üzere altı adet önceden tanımlanmış metrik yuvası genelinde çok kriterli bir seçim protokolü uyguluyoruz (Tablo III). Bu seçim, aday setini yapısal olarak farklı modellerle beslemek için çeşitlilik odaklı tahsisatı (diversity-driven allocation) içerir ve seyrek ödül varyantları ile muhafazakar konfigürasyonların Aşama 2’de değerlendirilmesini garanti altına alır.

Aşama 2, değerlendirme varyansını kantitatif olarak belirlemek amacıyla altı finalistı üç rastgele tohum (42, 123, 456) üzerinde değerlendirir (Tablo IV). SOFA-şekilli ödül, muhafazakar öğrenme oranı ve güvenli IQL ekspektıl-sıcaklık ayarımı birleştiren konfigürasyon (‘iql_sofa_shaped_conservative_safe’), 5.858 bileşik skor, 2.848 ortalama FQE ve 8.203 ortalama WIS değerlerine ulaşarak optimal politika olarak öne çıkmaktadır.

VI. Aksiyon ve Güvenlik Teşhisleri

Klinik karar politikalarını değerlendirmek, değer tahmininin ötesinde kapsamlı teşhisler gerektirir.[4] Kazanan politikanın test performansı Tablo V’te özetlenmiştir.

Politika yüksek davranışsal destek kütle (0.991) ve 0.414 klinisyen tam kutu uyumu sergilese de, etkin örneklem büyüklüğü (ESS) 29.410’dur ve bu değer klinik güvenilirlik eşiği olan 50’nin altındadır.[5] 29.410 düzeyindeki bir

ESS değeri, politikanın WIS tahminlerinin dar bir yörünge kümesi tarafından domine edildiğini ve bunun sonucunda 4.963 ila 10.817 arasında geniş bir %95 bootstrap güven aralığı oluştuğunu göstermektedir. Bu yüksek tahminci varyansı nedeniyle, elde edilen bulgular standart tedaviye göre klinik bir üstünlük iddiası olarak yorumlanmamalıdır. Bunun yerine, destek sınırlı retrospektif koşullar altında politika dışı optimizasyon kararlılığının bir kanıtı olarak değerlendirilmelidir.

Ayrıca, tam kutu uyumu 0.414 seviyesinde olmasına rağmen, desteklenmeyen aksiyon sapması (non-support action divergence) son derece düşüktür (0.009). Bu durum, ajanın klinisyenin tam tercihiyle uyuşmadığı anlarda (durumların %58.6’sında klinik bir kaymayı temsil eder), yine de ampirik veriler tarafından güçlü şekilde desteklenen alternatif aksiyonlar önerdiğini göstermektedir. Politika, düzensiz veya dağılım dışı müdahaleler önermek yerine, veri desteğiyle uyumlu komşu yörüngeleri seçmektedir. Bu muhafazakar davranış, güvenli IQL konfigürasyonunun gerçek dünya klinik veri sınırlamaları altında ekstrapolasyon hatalarını etkili bir şekilde sınırlandırdığını doğrulamaktadır.

VII. Sonuç

Bugün, sepsis tedavisi politikası tasarımı yeniden üretilebilirliği ve veri güvenliğini zorunlu kılan orkestre edilmiş bir çevrimdışı pekiştirmeli öğrenme iş akışı sunmaktadır. Geliştirilen Aşama 0 denetim çerçevesi, çok kriterli seçim protokolü ve çoklu tohum doğrulaması sayesinde, klinik pekiştirmeli öğrenmenin temel hata modları hafifletilmiştir. ‘iql_sofa_shaped_conservative_safe’ konfigürasyonunun seçilmesi, muhafazakar öğrenme güncellemelerinin güvenli ekspektıl sınırlarıyla birleştirilmesinin kararlı değer tahminleri sağladığını doğrulamaktadır. En önemlisi, ESS sınırlamasının açık bir şekilde raporlanması, şeffaf ve risk bilincine sahip klinik politika raporlaması için metodolojik bir şablon sunmaktadır.

TABLE III
Çok Kriterli Sınırlamalar Altında Aşama 1 En İyi Altı Adayın Seçimi

Derece	Yuva Ataması	Ödül	Öğrenme Oranı	IQL Ayarları	FQE Değeri	WIS Değeri	Destek Kütleli	Klinisyen Uyumu
1	En İyi Bileşik	SOFA	Muhafazakar	Güvenli	3.169	8.616	0.965	0.418
2	En İyi Bileşik	SOFA	Muhafazakar	Referans	2.280	7.009	0.973	0.401
3	En İyi Seyrek	Seyrek	Muhafazakar	Güvenli	1.954	8.740	0.971	0.411
4	Güvenlik Desteği	Seyrek	Referans	Referans	1.421	6.768	0.973	0.410
5	Referans Çapa	Seyrek	Referans	Güvenli	2.345	8.125	0.963	0.416
6	Çeşitlilik Odaklı	Seyrek	Muhafazakar	Referans	2.012	7.782	0.969	0.407

TABLE IV
Aşama 2 Çok Tohumlu Finalist Değerlendirmesi ve Birleştirilmiş Teşhisler

Derece	Konfigürasyon Adayı	Tür	Skor	FQE Ort.	WIS Ort.	ESS	Destek Kütleli	Klinisyen Uyumu
1	SOFA Muhafazakar Güvenli	Final	5.858	2.848	8.203	29.410	0.991	0.414
2	SOFA Muhafazakar Referans	Aday	5.288	2.366	8.286	26.120	0.990	0.404
3	Seyrek Muhafazakar Güvenli	Aday	5.262	2.316	8.169	31.320	0.990	0.411
4	Seyrek Muhafazakar Referans	Aday	5.033	2.050	8.536	26.100	0.990	0.401
5	Seyrek Referans Güvenli	Aday	4.940	2.063	7.882	31.310	0.991	0.418
6	Seyrek Referans Referans	Aday	4.755	1.535	9.755	18.960	0.991	0.409

TABLE V
Kazanan Konfigürasyonun Test Teşhisleri

Değerlendirme Metriği	Deneyisel Sonuç
Ortalama Uydurulmuş Q-Değerlendirmesi (FQE)	2.848
Ağırlıklı Önem Örnekleme (WIS)	8.203
WIS %95 Bootstrap Güven Aralığı	4.963 – 10.817
Etkin Örneklem Büyüklüğü (ESS)	29.410
Davranışsal Destek Kütleli	0.991
Klinisyen Tam Kutu Uyumu	0.414
Klinisyen Uyuşmazlığı (Kaydırılmış Aksiyonlar)	0.586
Desteklenmeyen Aksiyon Sapması	0.009